



João Gabriel de Araújo Vasconcelos

**MODELOS PARA DADOS TABULARES NA ERA DOS FOUNDATION
MODELS: UM BENCHMARK MULTICRITÉRIO, UM ARCABOUÇO
DE DECISÃO VALIDADO E A DESTILAÇÃO DISTRIBUCIONAL**

Dissertação de Mestrado



Universidade Federal de Pernambuco
posgraduacao@cin.ufpe.br
www.cin.ufpe.br/~posgraduacao

RECIFE

2026



Universidade Federal de Pernambuco
Pós-graduação em Ciência da Computação

João Gabriel de Araújo Vasconcelos

**MODELOS PARA DADOS TABULARES NA ERA DOS FOUNDATION
MODELS: UM BENCHMARK MULTICRITÉRIO, UM ARCABOUÇO
DE DECISÃO VALIDADO E A DESTILAÇÃO DISTRIBUCIONAL**

*Trabalho apresentado ao Programa de Pós-graduação em
Ciência da Computação do Centro de Informática da Uni-
versidade Federal de Pernambuco como requisito parcial
para obtenção do grau de Mestre em Ciência da Computa-
ção.*

Orientador: *Germano Crispim Vasconcelos*

Agradecimentos

[Agradecimentos — a preencher pelo autor.]

A escolha de modelos para dados tabulares foi guiada, por uma década, pela máxima de que o *gradient boosting* sempre vence; a chegada dos *foundation models* tabulares — redes pré-treinadas que predizem sem treinamento na tarefa — tornou essa orientação obsoleta sem lhe dar um substituto apoiado em evidência neutra. Esta dissertação ataca o problema em três frentes encadeadas. Primeiro, um benchmark multicritério avalia 14 modelos de três famílias (*gradient boosting*, aprendizado profundo e *foundation models*) em 18 conjuntos de dados públicos do OpenML (250 das 252 células possíveis; duas exclusões estruturais declaradas), sob validação cruzada aninhada com *hold-out* intocado e inferência estatística frequentista e bayesiana. Na geração anterior a 2026, o topo da acurácia é um empate estatístico — 8 dos 10 modelos não líderes são praticamente equivalentes ao líder sob região de equivalência prática de um ponto percentual de AUC —, e a geração 2026 o quebra: o TabFM, avaliado *zero-shot*, lidera o rank médio nas três tarefas (2,7 na classificação binária, 1,0 na multiclasse e 1,2 na regressão) e é o melhor modelo em 13 dos 18 conjuntos, ao custo de quatro a cinco ordens de magnitude em latência de inferência; as redes de Kolmogorov–Arnold, testadas de forma independente, terminam no último terço nas três tarefas. Segundo, um arcabouço de decisão é validado por *leave-one-dataset-out*: o roteamento por meta-características não generaliza (taxa de acerto de 0,11 contra 0,44 do *baseline* trivial), a política fixa “*foundation model* primeiro” é ótima em *regret* na métrica primária (*regret* mediano de 0,000 na geração 2026) e um experimento pré-registrado de *regret* multicritério mostra que basta deslocar 10 a 20 por cento do peso da acurácia para a latência (cruzamento entre os pesos 0,9 e 0,8) para a recomendação se inverter em favor do *gradient boosting* — justificando o fluxograma de quatro restrições verificáveis a priori que consolida o arcabouço. Terceiro, a destilação distribucional de *foundation models* — recorte verificado como inédito — transfere as curvas de quantis do professor TabPFN para alunos que servem em microssegundos: a destilação pontual falha de forma robusta em escala realista de dados, mas a distribucional retém mediana de 19 por cento da vantagem distribucional do professor, positiva em 16 de 20 conjuntos (teste de sinal com valor-p de 0,006), vence *baselines* distribucionais clássicos em 17 de 20 conjuntos no experimento pré-registrado E1 e se condensa numa regra de decisão prática cujas pré-condições se verificam em minutos. O conjunto — evidência sob protocolo único, arcabouço validado e destilação seletiva — substitui a máxima por um procedimento; e o que o *foundation model* sabe e os dados brutos não ensinam ao aluno é a distribuição preditiva — é isso que se destila.

Palavras-chaves: dados tabulares; foundation models; benchmark; destilação de conhecimento; regressão distribucional.

For a decade, model choice for tabular data was guided by the maxim that gradient boosting always wins; the arrival of tabular foundation models — pre-trained networks that predict with no task-specific training — made that guidance obsolete without replacing it with neutral evidence. This dissertation attacks the problem on three chained fronts. First, a multi-criteria benchmark evaluates 14 models from three families (gradient boosting, deep learning, and foundation models) on 18 public OpenML datasets (250 of the 252 possible cells; two declared structural exclusions), under nested cross-validation with an untouched hold-out and both frequentist and Bayesian statistical inference. In the pre-2026 generation, the top of the accuracy ranking is a statistical tie — 8 of the 10 non-leading models are practically equivalent to the leader under a region of practical equivalence of one percentage point of AUC — and the 2026 generation breaks it: TabFM, evaluated zero-shot, leads the average rank in all three tasks (2.7 in binary classification, 1.0 in multiclass, and 1.2 in regression) and is the best model on 13 of the 18 datasets, at the cost of four to five orders of magnitude in inference latency; Kolmogorov–Arnold networks, independently tested, finish in the bottom third across all three tasks. Second, a decision framework is validated by leave-one-dataset-out: meta-feature routing does not generalize (hit rate of 0.11 against 0.44 for the trivial baseline), the fixed “foundation model first” policy is regret-optimal on the primary metric (median regret of 0.000 in the 2026 generation), and a pre-registered multi-criteria regret experiment shows that shifting just 10 to 20 percent of the weight from accuracy to latency (crossover between weights 0.9 and 0.8) flips the recommendation in favor of gradient boosting — quantitatively justifying the flowchart of four a priori verifiable constraints that consolidates the framework. Third, the distributional distillation of foundation models — a scope verified as novel — transfers the quantile curves of the TabPFN teacher to students that serve in microseconds: point distillation fails robustly at realistic data scales, but distributional distillation retains a median of 19 percent of the teacher’s distributional advantage, positive on 16 of 20 datasets (sign test with a p-value of 0.006), beats classical distributional baselines on 17 of 20 datasets in the pre-registered experiment E1, and condenses into a practical decision rule whose preconditions can be verified in minutes. Together — evidence under a single protocol, a validated framework, and selective distillation — these results replace the maxim with a procedure; and what the foundation model knows that raw data cannot teach the student is the predictive distribution — that is what gets distilled.

Keywords: tabular data; foundation models; benchmarking; knowledge distillation; distributional regression.

Lista de Figuras

1.1	Perguntas de pesquisa e capítulos que as respondem	18
2.1	Uma árvore de decisão responde por partições sucessivas do espaço de atributos. Árvore ilustrativa de profundidade 2 sobre o exemplo da Tabela 2.1; em cada folha, $\hat{p}$ é a fração de exemplos de treino daquela região com renda $> 50K$ (valores fictícios, para ilustração). Para classificar uma linha nova, percorre-se o caminho ditado pelas respostas e lê-se a predição na folha alcançada.	25
2.2	No aprendizado em contexto, o conjunto de treino entra como entrada do modelo, não como alvo de otimização. Na fase 1, o Transformer é pré-treinado uma única vez sobre milhões de tarefas sintéticas amostradas de um prior. Na fase 2, diante de uma tarefa real, o conjunto de treino e a linha de consulta são concatenados na entrada e um único passe direto, sem qualquer atualização de gradiente, produz a distribuição preditiva.	31
2.3	A perda <i>pinball</i> penaliza os dois lados do erro com inclinações diferentes, e é essa assimetria que aponta o minimizador para o quantil τ. Para $\tau = 0,9$ (linha sólida), subestimar o alvo custa nove vezes mais que superestimar, de modo que a predição ótima se posiciona no ponto em que o alvo só a excede 10% das vezes — o quantil 0,9. Em $\tau = 0,5$ (tracejada), a perda é simétrica e recupera o erro absoluto, cujo minimizador é a mediana.	35
4.1	O benchmark cobre três ordens de grandeza em amostras e mais de uma ordem em atributos. Cada ponto é um conjunto de dados, posicionado pelo número de amostras (eixo vertical, escala logarítmica) e de atributos (eixo horizontal, escala logarítmica), colorido pelo tipo de tarefa (binária, multiclasse, regressão). A dispersão sem aglomeração em um único quadrante é a condição estrutural para a análise condicional da QP2. Fonte: <code>results/figures/dataset_landscape.p</code> gerado a partir de <code>configs/datasets.yaml</code>	54
4.2	Separação estrita entre seleção e medição. O <i>hold-out</i> de 20% é separado antes de qualquer validação cruzada e só é tocado uma única vez, na avaliação final; a seleção de hiperparâmetros ocorre exclusivamente no laço interno da validação cruzada aninhada, sobre a partição de desenvolvimento. Caixas sombreadas marcam os dados e a etapa que nenhum estágio de seleção observa.	57
5.1	Paisagem dos 18 conjuntos de dados: amostras vs. atributos	68
5.2	Diagrama de distância crítica (Nemenyi) — classificação binária	70
5.3	Mapa de calor da classificação: métrica por modelo e conjunto	72
5.4	Latência de inferência no <code>adult</code> (μs /linha, escala logarítmica)	74
5.5	Fronteira de Pareto: rank binário médio vs. tempo de treino	75

5.6	Robustez ao desbalanceamento: rank por família e faixa de severidade	76
5.7	Curvas de aprendizado: 6 modelos, 5 conjuntos, 500 amostras ao pool completo	77
5.8	Ranks médios por tarefa, grade completa	79
6.1	Matriz de decisão multicritério (14 modelos)	83
6.2	Regret multicritério ponderado das políticas fixas (E2)	87
6.3	Fluxograma de decisão validado (14 modelos)	89
7.1	Pipeline de destilação distribucional	97
7.2	Fronteira destilar $\mathcal{C}_E$ comprimir $\mathcal{C}_E$ reduzir ensemble	101
7.3	Curvas de confiabilidade dos quantis no hold-out	103

Lista de Tabelas

2.1	Fragmento <i>ilustrativo</i> de um conjunto tabular no estilo do <code>adult</code> . As linhas são fictícias, porém plausíveis; servem apenas para fixar o formato: atributos numéricos e categóricos convivem na mesma tabela, há valores ausentes (“?”) e a última coluna é o alvo a prever.	24
3.1	Mapa de lacunas por eixo da literatura. Caracterizações conforme verificações online datadas (13–20/07/2026; re-varredura em 04/10/2026), registradas nos memorandos citados na abertura do capítulo.	49
4.1	Os 18 conjuntos de dados OpenML do benchmark (tamanhos aproximados antes do teto; as execuções limitam cada conjunto a 100 mil amostras). Fonte: <code>configs/datasets.yaml</code>	53
4.2	Os 14 modelos do benchmark, por família, com a proveniência de cada implementação. “Própria” indica reimplementação a partir do artigo original, motivada pela ausência de pacote maduro.	55
4.3	Métricas por tipo de tarefa. Setas indicam a direção de otimização. A acurácia é reportada por convenção, mas nunca fundamenta conclusões.	59
5.1	Rank médio por tarefa — geração 2026 vs. referências	78
6.1	Regret normalizado das políticas fixas sob LODO	85
6.2	Regret mediano por política e peso da acurácia (E2)	88
7.1	Retenção do gap de CRPS do aluno destilado (20 conjuntos)	99
7.2	Os três reveses do E1: CRPS onde a QRF vence o aluno destilado	105
A.1	Classificação binária — resultados completos	130
A.2	Classificação multiclasse — resultados completos	131
A.3	Regressão — resultados completos	132
B.1	Espaços de busca — GBDTs	134
B.2	Espaços de busca — MLPs e <i>ensembles</i> paramétricos	135
B.3	Espaços de busca — arquiteturas de atenção	136
B.4	Espaços de busca — redes KAN	137
C.1	Ablação OOF vs. <i>in-sample</i> — desagregada	139
C.2	Ablação log-target — desagregada	139

Lista de Acrônimos

1	Introdução	15
1.1	Contexto e motivação	15
1.2	Problema de pesquisa	16
1.3	Objetivos	17
1.4	Perguntas de pesquisa	18
1.5	Resumo das contribuições	19
1.6	Produção bibliográfica	20
1.7	Como ler esta dissertação	20
1.8	Estrutura da dissertação	21
2	Fundamentação Teórica	23
	2.0.0.0.1 Roteiro.	23
2.1	Dados tabulares e aprendizagem supervisionada	24
	2.1.0.0.1 A heterogeneidade é constitutiva.	24
	2.1.0.0.2 Por que as revoluções de visão e linguagem não transferiram?	24
	2.1.0.0.3 O problema da aprendizagem supervisionada.	24
	2.1.0.0.4 As três tarefas.	25
2.2	Das árvores de decisão ao <i>gradient boosting</i>	25
2.2.1	Uma árvore, um exemplo guiado	25
2.2.2	Por que uma árvore só não basta?	26
	2.2.2.0.1 Caminho 1: reduzir a variância em paralelo.	26
	2.2.2.0.2 Caminho 2: reduzir o viés em sequência.	26
2.2.3	XGBoost, LightGBM e CatBoost: uma diferença concreta cada	27
	2.2.3.0.1 Os botões de ajuste.	27
	2.2.3.0.2 Por que o <i>boosting</i> domina dados tabulares?	27
2.3	Aprendizado profundo para dados tabulares	27
2.3.1	O perceptron multicamadas	28
	2.3.1.0.1 O gargalo do encoding categórico.	28
	2.3.1.0.2 A receita importa: RealMLP e TabM.	28
	2.3.1.0.3 Por que insistir em redes para tabelas?	28
2.3.2	Atenção e Transformers	29
	2.3.2.0.1 Por que dados tabulares usam só o <i>encoder</i> ?	29
	2.3.2.0.2 As arquiteturas de atenção do benchmark.	30
2.3.3	Redes de Kolmogorov–Arnold	30
	2.3.3.0.1 Uma recepção controversa.	30
2.4	<i>Foundation models</i> tabulares e aprendizado em contexto	31

2.4.0.0.1	O mecanismo: treinar virou condicionar.	31
2.4.0.0.2	De onde vem a capacidade de “aprender” sem gra- diente?	31
2.4.0.0.3	Cabeça distribucional vs. cabeça escalar.	32
2.4.0.0.4	O <i>trade-off</i> constitutivo.	32
2.5	Destilação de conhecimento	32
2.5.0.0.1	<i>Soft targets</i> : por que imitar é mais fácil que aprender.	33
2.5.0.0.2	Destilar para árvores.	33
2.5.0.0.3	Destilar <i>foundation models</i> tabulares.	33
2.6	Regressão distribucional: quantis, CRPS e calibração	34
2.6.1	Quantis e a perda <i>pinball</i>	34
2.6.1.0.1	A intuição assimétrica.	34
2.6.1.0.2	Um efeito colateral da grade: o cruzamento de quan- tis.	34
2.6.2	CRPS: uma régua para distribuições	35
2.6.2.0.1	O estimador de grade.	35
2.6.3	Calibração e afiação	36
2.6.4	Dois <i>baselines</i> distribucionais nativos	36
2.7	Comparação estatística de algoritmos	36
2.7.0.0.1	Por que não uma ANOVA sobre as métricas?	36
2.7.0.0.2	Qual é a unidade de análise?	37
2.7.0.0.3	Friedman: o teste <i>omnibus</i>	37
2.7.0.0.4	Nemenyi e o diagrama de diferença crítica.	37
2.7.0.0.5	Wilcoxon pareado com correção de Holm.	38
2.7.0.0.6	O que significa “praticamente equivalente”? O teste bayesiano com ROPE.	38
2.7.0.0.7	Tamanho de efeito e decomposição de variância.	38
3	Trabalhos Relacionados	40
3.1	Benchmarks tabulares e a controvérsia GBDT vs. aprendizado profundo	41
3.1.0.0.1	Os benchmarks de referência.	41
3.1.0.0.2	A tradição de comparação estatística.	41
3.1.0.0.3	A controvérsia como afirmação condicional.	42
3.1.0.0.4	Lacuna.	42
3.2	<i>Foundation models</i> tabulares e sua avaliação	42
3.2.0.0.1	A linhagem PFN/ICL.	42
3.2.0.0.2	TabFM.	43
3.2.0.0.3	Como esses modelos vêm sendo avaliados.	43
3.2.0.0.4	Lacuna.	43

3.3	A família Kolmogorov–Arnold em dados tabulares	43
3.3.0.0.1	Proponentes.	43
3.3.0.0.2	Avaliações independentes.	44
3.3.0.0.3	Registro de um lapso nosso.	44
3.3.0.0.4	Lacuna.	44
3.4	Aceleração e <i>serving</i> de <i>foundation models</i> tabulares	45
3.4.0.0.1	Compressão de contexto.	45
3.4.0.0.2	Amortização e transferência.	45
3.4.0.0.3	Quantização e calibração pós-hoc.	45
3.4.0.0.4	Engenharia simples, raramente medida.	45
3.4.0.0.5	Lacuna.	45
3.5	Destilação de <i>foundation models</i> tabulares	46
3.5.0.0.1	A linhagem clássica.	46
3.5.0.0.2	Pocket FM: a formulação para classificação.	46
3.5.0.0.3	Variantes e vizinhos.	46
3.5.0.0.4	As peças distribucionais existem — separadas.	47
3.5.0.0.5	Trabalho contemporâneo.	47
3.5.0.0.6	Lacuna.	47
3.6	Seleção de algoritmos e <i>meta-learning</i>	48
3.6.0.0.1	A tradição.	48
3.6.0.0.2	Lacuna.	48
3.7	Síntese das lacunas	48
4	Metodologia Experimental	51
4.1	Visão geral e princípios de desenho	52
4.2	Conjuntos de dados	52
4.2.0.0.1	Teto de 100 mil amostras.	54
4.2.0.0.2	Declaração sobre os dados.	54
4.3	Modelos avaliados	55
4.4	Protocolo experimental	56
4.5	Pré-processamento por família	58
4.6	Métricas por tipo de tarefa	58
4.7	Protocolo de inferência estatística	59
4.7.0.0.1	Política para células faltantes.	60
4.8	Eixos de custo e experimentos complementares	61
4.9	Infraestrutura computacional e reprodutibilidade	62
4.10	Contrato de conduta científica	62
4.11	Limitações do desenho experimental	63

5	O Benchmark Multicritério	66
5.1	Cobertura e organização da evidência	67
5.1.0.0.1	O núcleo de 11 modelos e a extensão de 2026.	67
5.1.0.0.2	O protocolo em uma frase (e suas assimetrias declaradas).	67
5.2	Ato I — o empate estatístico do núcleo de 11 modelos	69
5.2.0.0.1	O teste global rejeita a igualdade; o <i>post-hoc</i> não separa o topo.	69
5.2.0.0.2	A leitura bayesiana: equivalência prática, não ausência de poder.	69
5.2.0.0.3	O escopo do empate: onde há poder para afirmá-lo.	71
5.2.0.0.4	A anatomia do empate: a família é uma abstração fraca.	71
5.2.0.0.5	O que o agregado esconde: a visão por conjunto.	71
5.2.0.0.6	O único sinal robusto do desempenho bruto está no fundo.	72
5.3	Ato II — os eixos de custo	72
5.3.0.0.1	Treino: duas ordens e meia de magnitude.	72
5.3.0.0.2	Ajuste de hiperparâmetros: o custo escondido.	73
5.3.0.0.3	Inferência: cinco ordens de magnitude.	73
5.3.0.0.4	O cruzamento: a fronteira de Pareto.	73
5.4	Ato III — reversões condicionais e o eixo do tamanho	76
5.4.0.0.1	Multiclasse: o DL recente assume o topo clássico.	76
5.4.0.0.2	Desbalanceamento severo: vantagem relativa dos GBDTs.	76
5.4.0.0.3	O eixo do tamanho: curvas de aprendizado.	77
5.5	Ato IV — a quebra do empate: a geração 2026	78
5.5.0.0.1	A entrada do TabFM reorganiza a narrativa.	78
5.5.0.0.2	O contrapeso: o líder de acurácia é o pior em latência.	79
5.5.0.0.3	O resultado negativo das redes de Kolmogorov–Arnold.	79
5.6	Síntese do capítulo	80
6	O Arcabouço de Decisão Validado	82
6.1	Do descritivo ao validado	83
6.2	O resultado negativo: roteamento por meta-features não generaliza	84
6.3	O resultado positivo: a política “FM primeiro” e sua evolução	85
6.4	Regret multicritério ponderado: quando a recomendação vira	86
6.4.1	Desenho pré-registrado	86
6.4.2	Resultados: o cruzamento	87

6.5	O arcabouço resultante: decisão por restrições	89
6.6	Limitações do arcabouço	90
7	Destilação Distribucional de Foundation Models	92
7.1	Motivação e checagem de novidade	93
7.1.1	O preço do novo líder	93
7.1.2	Checagem de novidade datada — e a colisão parcial de outubro	94
7.2	Desenho pré-registrado: hipóteses, critérios e conduta	94
7.3	Método	95
7.3.1	Teachers: um distribucional, um pontual — por verificação, não por suposição	95
7.3.2	Rotulagem out-of-fold e famílias de alunos	96
7.3.3	Métricas	96
7.3.4	Conjuntos de dados e infraestrutura	97
7.4	A destilação pontual é refutada — com qualquer teacher	98
7.5	A destilação distribucional funciona — onde o teacher tem vantagem	99
7.6	A fronteira de serving: destilar, comprimir ou reduzir ensemble	100
7.7	Por que rotular out-of-fold: calibração, não acurácia	102
7.8	E1 — baselines distribucionais clássicos: o nativo forte posto à prova	104
7.8.1	Desenho pré-registrado	104
7.8.2	Resultados: 17 de 20 para o aluno destilado — com três reverses instrutivos	105
7.9	Quando destilar: duas hipóteses refutadas e a regra de decisão	106
7.10	Discussão, limitações e síntese	107
7.10.1	O que a destilação transfere — e o que isso diz sobre os teachers	107
7.10.2	Limitações	108
7.10.3	Síntese do capítulo	108
8	Conclusão	110
8.1	Considerações finais	110
8.1.0.0.1	Re-respondendo as perguntas de pesquisa.	111
8.2	Contribuições	112
8.3	Conselhos ao praticante	114
8.4	Limitações e ameaças à validade	116
8.4.1	Validade interna	116
8.4.2	Validade externa	117
8.4.3	Validade de construto	117
8.5	Trabalhos futuros	118
	Referências Bibliográficas	120

Apêndice	127
A Tabelas Completas de Resultados por Dataset	128
B Espaços de Busca de Hiperparâmetros	133
C Resultados Suplementares e Registro de Processo	138
C.1 Ablações da destilação: tabelas desagregadas	138
C.1.1 Rotulagem OOF <i>vs. in-sample</i>	138
C.1.2 Transformação logarítmica do alvo	139
C.2 Cemitério de hipóteses e desvios	139
C.2.0.0.1 1. H1 — destilação pontual.	140
C.2.0.0.2 2. Cauda pesada como moderador de falha (log- target).	140
C.2.0.0.3 3. Roteamento por meta-features.	140
C.2.0.0.4 4. A claim retratada do OOM “determinístico” no year_prediction.	140
C.2.0.0.5 5. Errata diamonds/kin8nm.	141
C.2.0.0.6 6. Troca year_prediction → cpu_activity na figura de calibração.	141

1

Introdução

1.1 Contexto e motivação

“Em dados tabulares, *gradient boosting* sempre vence.” Poucas máximas da prática de aprendizado de máquina foram tão repetidas na última década — e, ao contrário da maioria, esta chegou a receber forma quantitativa: em 2022, um estudo sistemático identificou os vieses indutivos que explicam por que comitês de árvores superam redes neurais em tabelas típicas (GRINSZTAJN; OYALLON; VAROQUAUX, 2022), e avaliações subsequentes em escala maior matizaram, sem derrubar, o veredito (MCELFRESH et al., 2023). Para o praticante, a máxima virou atalho de decisão: diante de uma tabela, use XGBoost e siga em frente.

Considere, porém, a decisão concreta que essa máxima pretende resolver. Um time de ciência de dados precisa escolher o modelo que decidirá, em produção, aprovações de crédito — um problema da família dos conjuntos `credit_g` e `give_me_some_credit` deste estudo — ou o que estimará preços de imóveis com intervalos de confiança, como no `california_housing`. Em 2026, esse time encontra um cardápio que a máxima não previa: além dos três *gradient boostings* consolidados, há uma dúzia de arquiteturas profundas que alegam tê-los alcançado, duas redes de Kolmogorov–Arnold com alegações fortes de superioridade e, no centro das atenções, os *foundation models* tabulares — redes pré-treinadas que dispensam qualquer treinamento na tarefa: o conjunto de treino entra como contexto no momento da predição (HOLLMANN et al., 2025; Google Research, 2026). Cada proponente publica números a seu favor, medidos sob protocolos distintos, com orçamentos de ajuste distintos e, com frequência crescente, sem revisão por pares. O que falta ao time não é mais um modelo: é evidência neutra, produzida sob um protocolo único, e um procedimento defensável para converter essa evidência em escolha.

Esta dissertação produz as duas coisas — e o retrato que emerge dela justifica o esforço, porque contraria a máxima duas vezes. Primeiro, na geração de modelos anterior a 2026, o topo da acurácia é um *empate estatístico*: sob região de equivalência prática de um ponto percentual de AUC, 8 dos 10 modelos não-líderes são praticamente equivalentes ao líder, e 80% da variância de desempenho está *dentro* das famílias, não entre elas — “*boosting* sempre vence”

não encontra margem de acurácia que a sustente (Capítulo 5). Segundo, a geração 2026 quebra o empate em direção inesperada: não foi o aprendizado profundo ajustado que alcançou as árvores, foi o pré-treino que atropelou ambos — o TabFM, avaliado *zero-shot*, sem qualquer ajuste, é o melhor modelo em **13 dos 18 conjuntos** do benchmark e lidera o rank médio nas três tarefas. O preço, contudo, muda a natureza da decisão: o líder de acurácia custa cerca de **43 milissegundos por linha** para servir predições, contra **0,33 microssegundos** do XGBoost — quatro a cinco ordens de magnitude, um fator de aproximadamente 131 mil vezes no conjunto de referência. A pergunta prática deixou de ser “qual família vence?” e passou a ser “a latência do líder cabe no meu caso de uso — e, se não cabe, o que fazer?”.

É essa segunda pergunta que dá à dissertação sua terceira frente. Se o obstáculo à adoção do líder é um custo de arquitetura — o conjunto de treino que viaja com o modelo a cada predição —, custos de arquitetura podem, em princípio, ser transferidos: a destilação de conhecimento (HINTON; VINYALS; DEAN, 2015) treina um aluno de microssegundos nas saídas do professor caro. Para *foundation models* tabulares, a literatura estabeleceu essa rota em classificação (TANNA et al., 2026a); o que ela transfere em *regressão* — em particular quando o que se quer preservar não é um número, mas a distribuição preditiva completa, com quantis e intervalos calibrados — permanecia, até as verificações datadas deste estudo, sem resposta pública. A resposta que encontramos é seletiva e, por isso mesmo, útil: a destilação *pontual* falha de forma robusta, a destilação *distribucional* funciona onde o professor tem vantagem genuína, e a fronteira entre as duas condições é verificável em minutos (Capítulo 7).

1.2 Problema de pesquisa

O problema que esta dissertação enfrenta pode ser enunciado em três camadas, cada uma herdando a anterior. Na primeira camada, há um *vácuo de evidência comparável*: as famílias de modelos tabulares disponíveis em 2026 — *gradient boosting*, aprendizado profundo em suas três linhagens e *foundation models* de aprendizado em contexto — não haviam sido medidas sob um protocolo único que combinasse validação honesta (seleção de hiperparâmetros estritamente separada da medição), inferência estatística capaz de *afirmar* equivalências além de rejeitá-las, e eixos de custo — tempo de treino, custo de ajuste e latência de serviço — medidos nas mesmas condições que a acurácia. Os benchmarks de referência são anteriores à geração 2026 (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; MCELFRESH et al., 2023), e os números dessa geração provinham majoritariamente dos próprios proponentes.

Na segunda camada, mesmo com a evidência produzida, resta o problema da *decisão*: benchmarks descrevem, mas times precisam escolher. A literatura de seleção de algoritmos sugere aprender um roteador a partir de meta-características do problema (RICE, 1976); a honestidade exige testar se tal roteador generaliza no regime real — poucas dezenas de conjuntos de dados — antes de recomendá-lo, e a literatura raramente reporta esse teste. Um artefato de decisão que nunca foi validado contra dados que não participaram de sua construção é uma

hipótese, não um instrumento.

Na terceira camada, a evidência e o artefato de decisão apontam juntos para um único obstáculo operacional: a latência do novo líder de acurácia. O problema torna-se, então, de engenharia dirigida por ciência: determinar o que a destilação de conhecimento pode e não pode transferir de um *foundation model* tabular em regressão, a que custo de serviço, e sob quais condições verificáveis *a priori* — com a regressão distribucional, eixo em que o professor carrega informação que os dados brutos não entregam ao aluno, como recorte central.

1.3 Objetivos

Objetivo geral. Estabelecer, sob protocolo experimental único e estatisticamente honesto, a evidência comparativa das três famílias de modelos tabulares na era dos *foundation models*, e convertê-la em instrumentos validados de decisão — incluindo a avaliação, por destilação de conhecimento, de até que ponto o principal obstáculo operacional da família líder pode ser removido.

Objetivos específicos.

- Executar um benchmark multicritério de 14 modelos sobre 18 conjuntos de dados públicos do OpenML, sob validação cruzada aninhada com *hold-out* intocado, orçamentos de ajuste equalizados por custo e inferência estatística frequentista e bayesiana com região de equivalência prática;
- Medir, sob o mesmo protocolo, os eixos de custo que a literatura raramente reporta — tempo de treino, custo total de ajuste de hiperparâmetros e latência de inferência — e cruzá-los com o desempenho em fronteiras de Pareto;
- Incluir e adjudicar, com verificação de novidade datada, as duas adições de 2026: a comparação neutra entre os dois *foundation models* (TabPFN e TabFM) e o primeiro teste independente da família Kolmogorov–Arnold contra a grade completa de famílias;
- Construir um arcabouço de decisão orientado a restrições e validá-lo por *leave-one-dataset-out*, confrontando o roteamento aprendido por meta-características com políticas fixas sob métrica de *regret* — incluindo a extensão pré-registrada ao *regret* multicritério ponderado por preferências de latência;
- Investigar o que a destilação de conhecimento transfere de *foundation models* tabulares em regressão — pontual e distribucional —, medir a fronteira de estratégias de serviço (destilar, comprimir contexto, reduzir *ensemble*) nos mesmos *hold-outs*, testar o aluno destilado contra *baselines* distribucionais clássicos em experimento pré-registrado, e condensar as condições de valor numa regra de decisão prática;

- Sustentar todas as conclusões em infraestrutura reprodutível — sementes, versões e dados fixados, artefatos versionados — sob um contrato explícito de conduta científica (pré-registro de hipóteses, verificação datada de novidade, reporte de resultados negativos e correção por retificação).

1.4 Perguntas de pesquisa

Três perguntas de pesquisa organizam a dissertação; cada uma é respondida por um capítulo de resultados, e as três são retomadas, com a evidência acumulada, na conclusão.

QP1. *O empate de acurácia entre as famílias de modelos tabulares sobrevive a um protocolo rigoroso — validação aninhada, equivalência prática bayesiana, eixos de custo — e à chegada da geração 2026 de foundation models?* (Capítulo 5)

QP2. *Que artefato de decisão um benchmark com N realista de conjuntos consegue, honestamente, sustentar — um roteador aprendido ou uma política por restrições — e como essa resposta muda quando a decisão pondera acurácia e custo?* (Capítulo 6)

QP3. *O que a destilação de conhecimento transfere de um foundation model tabular em regressão, a que custo de serviço, e sob quais condições verificáveis a priori?* (Capítulo 7)

A Figura 1.1 resume o encadeamento: a resposta de cada pergunta cria a pergunta seguinte — o empate e sua quebra (QP1) tornam a decisão multicritério inevitável (QP2), e a política de decisão validada esbarra num único obstáculo, cuja remoção é o objeto da QP3.




Figura 1.1: Cada pergunta de pesquisa é respondida por um capítulo, e a resposta de cada uma cria a seguinte. As setas sólidas ligam cada pergunta ao capítulo que a responde; as tracejadas marcam o encadeamento lógico: o empate de acurácia e sua quebra pela geração 2026 (QP1) deslocam a decisão para o terreno multicritério (QP2), e a política validada que de lá emerge tem na latência seu único obstáculo — precisamente o que a destilação ataca (QP3). Os Capítulos 2 a 4 fornecem, respectivamente, o vocabulário, o posicionamento na literatura e o protocolo comuns às três frentes.

1.5 Resumo das contribuições

As contribuições desta dissertação são de *medição sob protocolo uniforme* e de *validação honesta* — não se reivindica mecanismo novo de aprendizado; reivindica-se, com verificações de novidade datadas, o recorte e a evidência que faltavam. Em ordem de apresentação:

1. **Um benchmark multicritério da era dos foundation models** — 14 modelos $\times$ 18 conjuntos (250 das 252 células; duas exclusões estruturais declaradas), com validação cruzada aninhada, inferência frequentista e bayesiana e três eixos de custo sob o mesmo protocolo. Dele saem os dois fatos que estruturam a dissertação: o empate estatístico da geração anterior (8 de 10 modelos praticamente equivalentes ao líder; 80% da variância de rank intrafamília) e a quebra do empate pela geração 2026 (TabFM líder nas três tarefas e melhor modelo em 13 de 18 conjuntos, *zero-shot*, ao preço de quatro a cinco ordens de magnitude em latência). Inclui a primeira comparação neutra TabPFN $\times$ TabFM sob protocolo idêntico, até onde alcançam as verificações datadas (Capítulo 5).
2. **Um resultado negativo independente sobre as redes de Kolmogorov–Arnold** — no primeiro teste da família contra a grade completa GBDT/aprendizado profundo/*foundation models* em benchmark multicritério (verificação datada), KAN e TabKAN terminam no último terço nas três tarefas, embora baratas de servir: sob protocolo uniforme com ajuste equalizado, as alegações dos artigos originais não se sustentam (Capítulo 5).
3. **Um arcabouço de decisão validado, não apenas descrito** — três estudos sob *leave-one-dataset-out* elevam o fluxograma de decisão de descritivo a validado: o roteamento por meta-características não generaliza (taxa de acerto 0,11 contra 0,44 do *baseline* trivial no estudo com 11 modelos; 0,72 contra 0,78 com 14); a política fixa “*foundation model* primeiro” é *regret*-ótima na métrica primária, com *regret* mediano zero na geração 2026; e o experimento pré-registrado E2, contribuição exclusiva desta dissertação, localiza o ponto de inversão — basta deslocar 10 a 20% do peso da acurácia para a latência para a recomendação virar —, justificando quantitativamente a arquitetura do fluxograma (Capítulo 6).
4. **A destilação distribucional de foundation models tabulares** — o recorte verificado como inédito: sob desenho pré-registrado em 20 conjuntos, a destilação *pontual* falha de forma robusta com qualquer professor (um resultado negativo reportado com proeminência integral), enquanto a transferência das curvas de quantis retém mediana de 19% da vantagem distribucional do professor, positiva em 16 de 20 conjuntos (teste de sinal $p = 0,006$), a latências de microssegundos; a primeira fronteira medida de ponta a ponta entre destilar, comprimir contexto e reduzir *ensemble*;

a ablação que mostra que a rotulagem *out-of-fold* protege calibração, não acurácia; o experimento pré-registrado E1, também exclusivo desta dissertação, em que o aluno destilado vence *baselines* distribucionais clássicos em 17 de 20 conjuntos ($p = 0,0013$); e a regra de decisão prática que converte as refutações em instrução verificável em minutos (Capítulo 7).

5. **Infraestrutura e conduta reutilizáveis** — o protocolo, os artefatos versionados (cada número do texto rastreia a um CSV, JSON ou notebook executado), os pré-registros com adendos datados, as verificações de novidade registradas e o rito de errata pública constituem, em conjunto, uma contribuição metodológica de reprodutibilidade, descrita no Capítulo 4 e exercitada ao longo de toda a parte empírica.

1.6 Produção bibliográfica

A pesquisa gerou, até o depósito desta dissertação, dois relatórios técnicos do programa de pós-graduação, correspondentes às disciplinas de trabalho individual, ambos em inglês e disponíveis no repositório público do projeto:

- **AI-1** — *Does “GBDT Always Win”? A Multi-Criteria Benchmark of 14 Tabular Models — From a Statistical Tie to the 2026 Break — and a Validated Decision Framework* (VASCONCELOS; VASCONCELOS, 2026): relatório técnico do Trabalho Individual (`latex/ai1/` no repositório), que condensa o material dos Capítulos 5 e 6.
- **AI-2** — *Distilling Tabular Foundation Models Beyond Classification: Distributional Regression and the Distill/Compress/Shrink Pareto Frontier* [REF-NOVA: entrada bibliográfica do relatório AI-2, espelhando o formato da entrada do AI-1 (`companion2026`)]: relatório técnico da Atividade de Orientação Individual (`latex/ai2/`), que condensa o material do Capítulo 7; um preprint derivado dele está em preparação para submissão ao arXiv.

Os dois relatórios são trabalhos avaliativos do programa, sem revisão por pares externa até a data desta escrita; os capítulos correspondentes desta dissertação indicam, em suas aberturas, a relação exata com cada relatório — incluindo os dois experimentos (E1 e E2) que são contribuições novas da dissertação, inéditas em relação aos relatórios.

1.7 Como ler esta dissertação

A dissertação foi escrita para três perfis de leitor, e nem todos precisam percorrê-la linearmente. O **praticante** — quem precisa escolher e servir um modelo tabular — pode ir

diretamente aos Capítulos 5 e 6 (a evidência e o fluxograma de decisão) e à regra de decisão que encerra o Capítulo 7 (Seção 7.9): os três pontos foram escritos para serem autocontidos, com os pré-requisitos mínimos recapitulados no início de cada capítulo. O **leitor de formação estatística** interessado no rigor das comparações deve começar pela Seção 2.7 do Capítulo 2 (a teoria dos testes, incluindo a camada bayesiana de equivalência prática) e pelo Capítulo 4 (o protocolo de aplicação, a política para células faltantes e as limitações declaradas antes dos resultados). O **replicador** — quem quer reproduzir ou estender os experimentos — encontra no Capítulo 4 o protocolo completo com sementes, versões e justificativas, e nos apêndices o restante: as tabelas completas por conjunto (Apêndice A), os espaços de busca de hiperparâmetros (Apêndice B) e os resultados suplementares e ablações; todos os artefatos citados têm caminho explícito no repositório público do projeto. Por fim, os recursos didáticos recorrentes — caixa de resumo na abertura de cada capítulo, nota de material associado, achados numerados nos capítulos de resultados e caixa de transição ao final — permitem reconstruir o argumento central folheando apenas as caixas.

1.8 Estrutura da dissertação

O restante da dissertação está organizado em sete capítulos e três apêndices. O **Capítulo 2** constrói, do concreto ao abstrato, o vocabulário técnico do trabalho: dados tabulares e sua heterogeneidade constitutiva, árvores e *gradient boosting*, as três linhagens do aprendizado profundo tabular, os *foundation models* e o mecanismo de aprendizado em contexto, a destilação de conhecimento, o ferramental da regressão distribucional (quantis, CRPS, calibração) e a teoria dos testes estatísticos para comparação de algoritmos — com profundidade matemática proporcional à proximidade das contribuições. O **Capítulo 3** posiciona o trabalho em seis eixos da literatura, de benchmarks tabulares à destilação de *foundation models*, fechando com uma tabela-síntese que liga cada lacuna — caracterizada por verificações online datadas — ao capítulo que a ataca. O **Capítulo 4** especifica o protocolo experimental comum a toda a parte empírica: conjuntos, modelos, validação cruzada aninhada com *hold-out* intocado, métricas, protocolo de inferência estatística, medição de custo, infraestrutura de reprodutibilidade e o contrato de conduta científica, com as limitações do desenho declaradas antes de qualquer resultado. O **Capítulo 5** apresenta o benchmark em quatro atos — o empate estatístico do núcleo de 11 modelos, os eixos de custo em que os empatados diferem por ordens de magnitude, as reversões condicionais e o eixo do tamanho amostral, e a quebra do empate pela geração 2026, com o resultado negativo das redes de Kolmogorov–Arnold — respondendo à QP1. O **Capítulo 6** eleva o arcabouço de decisão de descritivo a validado por três estudos sob *leave-one-dataset-out* — o resultado negativo do roteamento por meta-características, o positivo da política “*foundation model* primeiro” e o experimento pré-registrado de *regret* multicritério ponderado — consolidando o fluxograma de quatro restrições que responde à QP2. O **Capítulo 7** apresenta a contribuição de destilação distribucional sob desenho pré-registrado: a refutação da

destilação pontual, o sucesso da transferência de curvas de quantis, a fronteira de três estratégias de serviço, a ablação da rotulagem *out-of-fold*, o experimento E1 contra *baselines* clássicos e a regra de decisão final que responde à QP3. O **Capítulo 8** confronta cada pergunta de pesquisa com a evidência acumulada, consolida as contribuições, declara as limitações e ameaças à validade do programa como um todo e aponta os trabalhos futuros. Os **apêndices** reúnem as tabelas completas de resultados por conjunto, os espaços de busca de hiperparâmetros e os resultados suplementares e ablações.

Transição. Antes dos resultados, o vocabulário. O Capítulo 2 parte de uma tabela concreta e constrói, camada a camada, tudo o que a leitura dos capítulos empíricos pressupõe — por que árvores dominaram dados tabulares por uma década, o que exatamente um *foundation model* tabular faz num único passe de inferência, o que significa destilar uma distribuição e como se afirma, com honestidade estatística, que dois modelos empatam.

2

Fundamentação Teórica

Resumo do capítulo. Este capítulo constrói, do concreto ao abstrato, todo o vocabulário técnico de que a dissertação precisa: o que são dados tabulares e por que eles resistem às arquiteturas que revolucionaram visão e linguagem (§2.1); como uma única árvore de decisão aprende e por que *ensembles* de árvores com *boosting* se tornaram o padrão da área (§2.2); as três linhagens da resposta do aprendizado profundo, do MLP aos Transformers e às redes de Kolmogorov–Arnold (§2.3); os *foundation models* tabulares e o mecanismo de aprendizado em contexto que dispensa treinamento na tarefa (§2.4); a destilação de conhecimento (§2.5); o ferramental da regressão distribucional — perda *pinball*, CRPS, calibração — que sustenta a contribuição do Capítulo 7 (§2.6); e os testes estatísticos com que o Capítulo 5 compara os modelos (§2.7). A profundidade matemática cresce com a proximidade das contribuições: o *boosting* é apresentado verbalmente, a atenção com suas equações completas, e a regressão distribucional e a inferência estatística com o detalhe necessário para ler os resultados sem consultar as fontes.

Material associado. As formulações de CRPS, PICP, perda *pinball* e aprendizado em contexto das Seções 2.4 e 2.6 seguem as glosas auditadas dos dois artigos que acompanham esta dissertação (`latex/ai1` e `latex/ai2` no repositório), aqui traduzidas e expandidas didaticamente.

2.0.0.0.1 Roteiro. O leitor já familiarizado com *gradient boosting* e redes neurais pode saltar diretamente para a Seção 2.4, onde começa o material menos difundido (aprendizado em contexto e cabeças distribucionais); quem conhece os *foundation models* tabulares, para as Seções 2.6 e 2.7, que são pré-requisito direto dos Capítulos 5 e 7. As demais seções foram escritas para que um leitor com formação geral em computação acompanhe toda a dissertação sem fontes externas.

2.1 Dados tabulares e aprendizagem supervisionada

Começemos pelo objeto. Um *conjunto de dados tabular* é uma tabela em que cada linha é uma observação e cada coluna um atributo — o formato de um extrato bancário, de um prontuário ou de um cadastro de clientes. A Tabela 2.1 ilustra o formato com linhas no estilo do conjunto `adult`, um clássico da área em que se deseja prever, a partir de atributos socio-demográficos de um censo, se a renda anual de uma pessoa excede 50 mil dólares (KOHAVI, 1996).

Tabela 2.1: Fragmento *ilustrativo* de um conjunto tabular no estilo do `adult`. As linhas são fictícias, porém plausíveis; servem apenas para fixar o formato: atributos numéricos e categóricos convivem na mesma tabela, há valores ausentes (“?”) e a última coluna é o alvo a prever.

idade	escolaridade	ocupação	horas/semana	renda > 50K?
39	superior	gerência	45	sim
23	ensino médio	serviços	40	não
51	pós-graduação	especialista	50	sim
34	ensino médio	?	38	não
28	superior	técnico	44	não

2.1.0.0.1 A heterogeneidade é constitutiva. A Tabela 2.1 já exhibe tudo o que torna o formato difícil: `idade` e `horas/semana` são números em escalas distintas; `escolaridade` é uma categoria com ordem natural; `ocupação` é uma categoria *nominal*, sem ordem nem distância entre valores, e de cardinalidade arbitrária; e o “?” é um valor ausente cuja ausência pode, ela própria, carregar informação. Uma mesma tabela mistura, portanto, variáveis contínuas, contagens, categorias e lacunas — e cada coluna é um eixo semântico independente: trocar duas colunas de lugar não altera o problema, mas trocar dois pixels de uma imagem, sim.

2.1.0.0.2 Por que as revoluções de visão e linguagem não transferiram? Redes convolucionais exploram a estrutura espacial das imagens (pixels vizinhos são correlacionados; padrões se repetem em qualquer posição); Transformers de linguagem exploram a estrutura sequencial do texto. Dados tabulares não oferecem nenhuma invariância universal análoga que uma arquitetura possa explorar *por construção* — não há noção de vizinhança entre `idade` e `ocupação`. Essa ausência de estrutura compartilhada é a explicação usual para um fato empírico persistente: por mais de uma década, o estado da arte em tabelas pertenceu a outra família de modelos, os *ensembles* de árvores de decisão (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; MCEL-FRESH et al., 2023). As Seções 2.2 e 2.3 desenvolvem os dois lados dessa disputa.

2.1.0.0.3 O problema da aprendizagem supervisionada. Formalizemos o mínimo necessário. Dado um conjunto de treino $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ de pares observação–alvo, assumidos amostras independentes de uma distribuição desconhecida, o objetivo é aprender uma função f que

prediga bem o alvo de observações *novas* — isto é, que minimize o erro esperado sob a distribuição geradora, não o erro no próprio conjunto de treino. A distinção é o coração do problema: um modelo suficientemente flexível pode zerar o erro de treino simplesmente memorizando D (*sobreajuste*), sem generalizar. Por isso toda avaliação honesta mede o desempenho em dados que o modelo — e, igualmente importante, o processo de *escolha* do modelo — jamais viu; o Capítulo 4 traduz esse princípio em protocolo (conjunto de teste separado antes de tudo, validação cruzada aninhada para a seleção de hiperparâmetros).

2.1.0.0.4 As três tarefas. Este trabalho considera os três tipos canônicos de tarefa supervisionada sobre tabelas: *classificação binária* (prever uma de duas classes, como na Tabela 2.1), *classificação multiclasse* (prever uma entre K classes) e *regressão* (prever um valor contínuo). A regressão admite duas leituras que esta dissertação distingue com cuidado: a leitura *pontual*, em que o modelo devolve um único número (uma estimativa da média condicional), e a leitura *distribucional*, em que o modelo devolve uma distribuição preditiva completa — quantis, intervalos, densidades — da qual se exige calibração. A distinção parece sutil agora, mas é o eixo da contribuição do Capítulo 7, e a Seção 2.6 lhe dedica o ferramental próprio.

2.2 Das árvores de decisão ao *gradient boosting*

2.2.1 Uma árvore, um exemplo guiado

Uma *árvore de decisão* prediz por meio de uma sequência de perguntas sobre os atributos, cada uma com resposta binária, até chegar a uma folha que contém a predição (BREIMAN et al., 1984). A Figura 2.1 mostra uma árvore pequena, de profundidade dois, treinada (ilustrativamente) sobre dados como os da Tabela 2.1.




Figura 2.1: **Uma árvore de decisão responde por partições sucessivas do espaço de atributos.** Árvore ilustrativa de profundidade 2 sobre o exemplo da Tabela 2.1; em cada folha, $\hat{p}$ é a fração de exemplos de treino daquela região com renda $> 50K$ (valores fictícios, para ilustração). Para classificar uma linha nova, percorre-se o caminho ditado pelas respostas e lê-se a predição na folha alcançada.

Siga a terceira linha da Tabela 2.1 pela árvore: a pessoa tem pós-graduação (escolaridade $\geq$ superior: *sim*, ramo direito) e 51 anos (idade > 30 : *sim*), caindo na folha com $\hat{p} = 0,61$

— a árvore estima 61% de probabilidade de renda alta, e, com limiar de 50%, prediz “sim”. O treinamento constrói essas perguntas de cima para baixo, escolhendo em cada nó, por busca gulosa, o atributo e o ponto de corte que melhor separam as classes (segundo um critério de impureza como entropia ou índice de Gini); em regressão, as folhas guardam médias e o critério é a redução de variância.

Duas propriedades dessa construção merecem registro desde já, porque reaparecerão como explicação de resultados empíricos. Primeiro, as partições são *alinhadas aos eixos*: cada pergunta envolve um único atributo, o que casa com a natureza tabular em que cada coluna tem semântica própria. Segundo, a árvore é *invariante a transformações monótonas* de cada atributo — perguntar “idade > 30” é equivalente a perguntar “ $\log(\text{idade}) > \log 30$ ” — de modo que normalizar colunas, etapa obrigatória para redes neurais, é irrelevante para árvores.

2.2.2 Por que uma árvore só não basta?

Uma árvore única enfrenta um dilema. Se for rasa, é estável porém grosseira: o exemplo da Figura 2.1 reduz toda a população a quatro grupos. Se for profunda, torna-se expressiva porém instável: memoriza particularidades da amostra de treino, e uma pequena perturbação nos dados produz uma árvore muito diferente. Na linguagem clássica da decomposição *viés-variância*, árvores rasas sofrem de viés alto e árvores profundas, de variância alta (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Os *ensembles* — comitês de árvores — atacam cada chifre do dilema por um caminho distinto.

2.2.2.0.1 Caminho 1: reduzir a variância em paralelo. O *bagging* e seu refinamento mais célebre, as florestas aleatórias, treinam muitas árvores profundas em réplicas perturbadas dos dados (reamostragem com reposição e sorteio de atributos por nó) e tiram a média das predições: os erros idiossincráticos de cada árvore, aproximadamente independentes, cancelam-se na média, e a variância do comitê despenca sem elevar o viés (BREIMAN, 2001).

2.2.2.0.2 Caminho 2: reduzir o viés em sequência. O *boosting* inverte a lógica: parte de árvores *rasas* (viés alto, variância baixa) e as treina em sequência, cada nova árvore concentrada em corrigir os erros que o comitê acumulado ainda comete. A predição final é a soma ponderada de todas as correções. A cada rodada, os exemplos mal preditos ganham protagonismo, e o comitê refina exatamente as regiões em que ainda erra — o viés cai passo a passo, enquanto a rasura de cada árvore e um passo de aprendizado pequeno seguram a variância.¹

¹Tecnicamente, o *gradient boosting* formaliza essa intuição como uma descida de gradiente no espaço de funções: a cada rodada m , ajusta-se uma árvore h_m ao gradiente negativo da função de perda avaliada nas predições correntes (no caso do erro quadrático, aos resíduos $y_i - F_{m-1}(x_i)$), e atualiza-se $F_m = F_{m-1} + \nu h_m$ com taxa de aprendizado ν pequena (FRIEDMAN, 2001). O corpo do texto permanece verbal de propósito: nenhum resultado desta dissertação exige manipular essa formulação.

2.2.3 XGBoost, LightGBM e CatBoost: uma diferença concreta cada

Três implementações modernas de *gradient boosting* sobre árvores (GBDTs, de *gradient-boosted decision trees*) dominam a prática, e o benchmark do Capítulo 5 avalia as três. Para os fins desta dissertação, basta reter uma diferença concreta de cada uma. O **XGBoost** (CHEN; GUESTRIN, 2016) consolidou o paradigma com uma formulação regularizada do objetivo — penalidades explícitas sobre o número de folhas e a magnitude dos pesos — que disciplina o crescimento de cada árvore. O **LightGBM** (KE et al., 2017) muda a ordem de crescimento: em vez de expandir a árvore nível a nível, expande sempre a *folha* de maior ganho (crescimento folha-a-folha), com histogramas de atributos que tornam o treino substancialmente mais rápido em dados grandes. O **CatBoost** (PROKHORENKOVA et al., 2018) distingue-se pelo tratamento nativo de variáveis categóricas via *ordered boosting*: as estatísticas de alvo usadas para codificar categorias são computadas apenas sobre exemplos “anteriores” numa permutação aleatória, evitando o vazamento de alvo das codificações ingênuas.

2.2.3.0.1 Os botões de ajuste. Na prática, o comportamento de um GBDT é governado por um punhado de hiperparâmetros com papéis interpretáveis à luz do dilema viés–variância: a *profundidade* das árvores controla a ordem das interações que cada correção pode capturar; o *número de árvores* e a *taxa de aprendizado* formam um par acoplado (passos menores exigem mais passos, mas regularizam); e as frações de *subamostragem* de linhas e colunas por árvore injetam a descorrelação que o *bagging* ensinou. Nenhuma configuração domina todos os conjuntos de dados — razão pela qual qualquer comparação justa entre modelos precisa otimizar os hiperparâmetros de cada um sob o mesmo orçamento, como especifica o Capítulo 4.

2.2.3.0.2 Por que o *boosting* domina dados tabulares? Reunindo os fios: as partições alinhadas aos eixos capturam não-linearidades e interações por atributo sem supor qualquer geometria entre colunas; a invariância a transformações monótonas dispensa normalização e absorve escalas heterogêneas; a seleção gulosa de cortes ignora com naturalidade atributos irrelevantes; e o *boosting* compõe essas virtudes num redutor sistemático de viés. O resultado é um desempenho consistente, com pouco ajuste, exatamente no regime de dados heterogêneos de tamanho pequeno a médio — diagnóstico corroborado por avaliações independentes em larga escala (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; MCELFRESH et al., 2023). Por isso, nesta dissertação os GBDTs cumprem o papel de *hipótese nula*: toda proposta nova em dados tabulares deve ser medida contra eles.

2.3 Aprendizado profundo para dados tabulares

A resposta do aprendizado profundo ao domínio dos GBDTs organizou-se em três linhas: modernizar o MLP, importar a atenção dos Transformers e, mais recentemente, repensar

o próprio neurônio com as redes de Kolmogorov–Arnold. Esta seção as percorre em ordem.

2.3.1 O perceptron multicamadas

O *perceptron multicamadas* (MLP) é a rede neural mais simples: camadas de unidades que combinam linearmente as entradas e aplicam uma não-linearidade. Com entrada $\mathbf{h}^{(0)} = \mathbf{x}$, cada camada l computa

$$\mathbf{h}^{(l)} = \phi(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (2.1)$$

em que $\mathbf{W}^{(l)}$ e $\mathbf{b}^{(l)}$ são parâmetros aprendidos e ϕ é uma função de ativação fixa (tipicamente a ReLU, $\phi(z) = \max(0, z)$), e a saída da última camada é lida como predição,

$$f(\mathbf{x}) = \mathbf{W}^{(L)}\mathbf{h}^{(L-1)} + \mathbf{b}^{(L)}, \quad (2.2)$$

seguida de uma *softmax* em classificação. Os parâmetros são ajustados por descida de gradiente sobre uma função de perda, com gradientes computados por retropropagação (RUMELHART; HINTON; WILLIAMS, 1986). Em uma frase: com largura suficiente, um MLP pode aproximar qualquer função contínua (HORNIK; STINCHCOMBE; WHITE, 1989) — a questão em dados tabulares nunca foi expressividade, e sim se o treinamento encontra, com dados finitos e heterogêneos, soluções tão boas quanto as dos GBDTs.

2.3.1.0.1 O gargalo do encoding categórico. Antes de qualquer camada, há uma decisão incômoda: como entregar `ocupação` a uma rede que só consome números? A codificação *one-hot* — uma coluna binária por categoria — explode a dimensionalidade quando a cardinalidade é alta: no benchmark desta dissertação, o conjunto `amazon_employee` atingiria cerca de 6,9 mil colunas sem um teto de cardinalidade, penalizando especialmente os modelos de atenção, cujo custo cresce com o número de colunas. A alternativa padrão são *embeddings* aprendidos: cada categoria é mapeada a um vetor denso de baixa dimensão, treinado junto com a rede — solução que todas as arquiteturas a seguir adotam de alguma forma.

2.3.1.0.2 A receita importa: RealMLP e TabM. Duas propostas recentes mostram que boa parte da desvantagem histórica do MLP era de *receita*, não de arquitetura. O **RealMLP** (HOLZMÜLLER; GRINSZTAJN; STEINWART, 2024) demonstra que um MLP com um conjunto cuidadoso de melhorias — *embeddings* numéricos, agendamento de taxa de aprendizado, regularização e pré-processamento afinados — compete com GBDTs ajustados. O **TabM** (GORISHNIY; KOTELNIKOV; BABENKO, 2025) ataca outro flanco: obtém o efeito estabilizador de um *ensemble* de MLPs com custo próximo ao de um modelo único, parametrizando eficientemente múltiplas “sub-redes” que compartilham a maior parte dos pesos.

2.3.1.0.3 Por que insistir em redes para tabelas? Se os GBDTs dominam, por que a área continua investindo em redes? Por três promessas que árvores não fazem. Primeiro, redes

aprendem *representações*: *embeddings* de categorias e camadas intermediárias reutilizáveis, porta de entrada para transferência entre tarefas e para dados mistos (tabela junto a texto ou imagem). Segundo, redes são treináveis por gradiente de *qualquer* perda diferenciável, o que permite cabeças de saída flexíveis — multi-alvo, multi-quantil, distribucionais — com mudança mínima de arquitetura; essa plasticidade é explorada diretamente pelos alunos de destilação do Capítulo 7. Terceiro, e decisivo para esta dissertação: toda a família de *foundation models* da Seção 2.4, que redefine o custo de entrada em novas tarefas, só é possível sobre redes.

2.3.2 Atenção e Transformers

A segunda linhagem importa o mecanismo que revolucionou o processamento de linguagem: a *atenção* (VASWANI et al., 2017). Aqui a profundidade matemática se justifica: metade dos modelos do benchmark e todos os *foundation models* da Seção 2.4 são construídos sobre essas equações.

Dada uma sequência de n vetores de entrada empilhados em $\mathbf{X} \in \mathbb{R}^{n \times d}$, a atenção projeta cada vetor em três papéis — *consulta* (*query*), *chave* (*key*) e *valor* (*value*):

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V, \quad (2.3)$$

com matrizes de projeção aprendidas, e produz, para cada posição, uma média dos valores ponderada pela afinidade entre sua consulta e todas as chaves:

$$\text{Ateno}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}, \quad (2.4)$$

em que d_k é a dimensão das chaves e a divisão por $\sqrt{d_k}$ estabiliza as magnitudes antes da *softmax*. A intuição: cada elemento da sequência “pergunta” (via $\mathbf{Q}$) quais outros elementos lhe são relevantes (via $\mathbf{K}$) e agrega a informação deles (via $\mathbf{V}$) na proporção dessa relevância — pesos que são *computados dos dados*, não fixados pela arquitetura. A atenção *multi-cabeça* executa h atenções em paralelo com projeções independentes e concatena os resultados,

$$\text{MultiHead}(\mathbf{X}) = \text{concat}(\text{cabeça}_1, \dots, \text{cabeça}_h) \mathbf{W}_O, \quad (2.5)$$

permitindo que cabeças distintas capturem padrões de interação distintos. Um *bloco Transformer* empilha atenção multi-cabeça e um MLP posição-a-posição, com conexões residuais e normalização de camada; a arquitetura completa original empilha esses blocos em um *encoder* (que processa a entrada inteira de uma vez, com atenção irrestrita) e um *decoder* (que gera texto token a token, com atenção causal).

2.3.2.0.1 Por que dados tabulares usam só o *encoder*? Porque não há nada a *gerar* sequencialmente: a predição sobre uma linha é um único rótulo ou valor, não uma sequência. Os

Transformers tabulares tratam as *colunas* de uma linha como a “sequência” de entrada — cada atributo vira um token — e usam apenas a pilha de *encoder*: a atenção entre tokens-atributo aprende interações entre colunas, e a predição é lida de um token especial agregador. O *decoder* e sua máscara causal, feitos para a ordem temporal do texto, não têm contraparte numa linha de tabela.

2.3.2.0.2 As arquiteturas de atenção do benchmark. O **TabNet** (ARIK; PFISTER, 2021) foi pioneiro em levar atenção a tabelas, combinando-a com seleção *esparsa* de atributos: a cada passo de processamento, uma máscara aprendida elege poucos atributos relevantes, o que confere ao modelo interpretabilidade nativa. O **FT-Transformer** (GORISHNIY et al., 2021) é a destilação mais limpa da ideia: um *Feature Tokenizer* converte cada atributo (numérico ou categórico) em um token-*embedding* e um Transformer padrão processa a linha; é a referência arquitetural da linhagem. O **SAINT** (SOMEPELLI et al., 2021) acrescenta à atenção entre colunas uma atenção *entre linhas* (*intersample*): ao classificar uma linha, o modelo pode consultar outras linhas do lote — um antecipo, em miniatura, da ideia de usar exemplos como contexto que a Seção 2.4 leva ao extremo. O **S**Tab**** (VOSKOU; CHRISTOFOROU; CHATZIS, 2024) completa a linhagem com um mecanismo distinto: em vez de ativações determinísticas, suas camadas usam unidades de *competição estocástica local* (LWTA, *local winner-takes-all*), em que blocos de neurônios competem e um vencedor é sorteado por amostragem Gumbel-softmax diferenciável; na inferência, a predição é a média bayesiana de 64 passadas estocásticas. O custo dessa inferência por amostragem aparece com destaque no eixo de latência do Capítulo 5.

2.3.3 Redes de Kolmogorov–Arnold

A terceira linhagem, mais recente, muda o lugar da não-linearidade. O teorema da representação de Kolmogorov–Arnold garante que toda função contínua de várias variáveis pode ser escrita como composição de somas de funções contínuas de *uma* variável (KOLMOGOROV, 1957; ARNOLD, 1957). As *Kolmogorov–Arnold Networks* (KANs) (LIU et al., 2025) tomam o teorema como inspiração arquitetural e invertem o desenho do MLP: em vez de ativações fixas nos nós e pesos escalares nas arestas (Eq. 2.1), colocam *funções univariadas aprendíveis* nas arestas — parametrizadas por B-splines — e meras somas nos nós. Cada conexão deixa de ser um número e passa a ser uma pequena curva ajustável. Variantes trocam a base das funções de aresta (polinômios de Chebyshev no ChebyKAN, funções de base radial no FastKAN), e o **Tab-KAN** (ESLAMIAN; Afzal Aghaei; CHENG, 2025) organiza essas variantes num arcabouço voltado a dados tabulares.

2.3.3.0.1 Uma recepção controversa. A promessa das KANs — mais expressividade por parâmetro e interpretabilidade das curvas aprendidas — encontrou ceticismo empírico: sob comparação com paridade de parâmetros e de FLOPs, o MLP vence as KANs na maioria das

tarefas de aprendizado de máquina (YU; YU; WANG, 2024), e avaliações independentes em tabelas chegaram a quadro semelhante (POETA et al., 2024). Nenhuma dessas avaliações, porém, inclui GBDTs e *foundation models* no mesmo protocolo — a lacuna que o Capítulo 5 preenche, adjudicando a controvérsia sob protocolo neutro.

2.4 *Foundation models* tabulares e aprendizado em contexto

Tudo o que foi visto até aqui compartilha uma premissa tão básica que passa despercebida: para cada novo conjunto de dados, treina-se um modelo novo. Os *foundation models* tabulares abandonam essa premissa, e é essencial entender o mecanismo — não apenas o efeito — porque tanto o custo de inferência medido no Capítulo 5 quanto a destilação do Capítulo 7 decorrem diretamente dele.

2.4.0.0.1 O mecanismo: treinar virou condicionar. Um modelo de *aprendizado em contexto* (*in-context learning*, ICL) é uma rede pré-treinada que condiciona no conjunto de treino como se fosse um *prompt*, no momento da predição, sem nenhuma atualização de gradiente na tarefa-alvo. Concretamente: apresenta-se ao Transformer, numa única entrada, o conjunto de treino inteiro — pares $(\mathbf{x}_i, y_i)$ — seguido da linha de consulta $\mathbf{x}_{\text{novo}}$; um único passe direto (*forward pass*) produz a predição, com os pesos da rede congelados. “Treinar” na tarefa reduz-se a montar o contexto; todo o aprendizado propriamente dito aconteceu antes, no pré-treinamento. A Figura 2.2 esquematiza as duas fases.




Figura 2.2: **No aprendizado em contexto, o conjunto de treino entra como entrada do modelo, não como alvo de otimização.** Na fase 1, o Transformer é pré-treinado uma única vez sobre milhões de tarefas sintéticas amostradas de um prior. Na fase 2, diante de uma tarefa real, o conjunto de treino e a linha de consulta são concatenados na entrada e um único passe direto, sem qualquer atualização de gradiente, produz a distribuição preditiva.

2.4.0.0.2 De onde vem a capacidade de “aprender” sem gradiente? Do pré-treinamento. As *prior-fitted networks* (PFNs) são pré-treinadas em milhões de pequenos conjuntos de dados *sintéticos*, amostrados de um prior sobre mecanismos geradores — tipicamente modelos causais

estruturais (SCMs): grafos causais aleatórios cujas variáveis se relacionam por funções e ruídos sorteados (MÜLLER et al., 2022). Em cada tarefa sintética, a rede vê um contexto rotulado e é treinada a prever os rótulos retidos; ao fazê-lo em escala, aprende um algoritmo genérico de inferência: a saída do passe direto aproxima a *distribuição preditiva posterior* sob o prior sintético, dado o contexto (NAGLER, 2023). O **TabPFN** (HOLLMANN et al., 2025) e suas versões v2/v2.5 (GRINSZTAJN et al., 2025) estabeleceram o paradigma na prática, com um limite nativo de contexto (50 mil linhas na v2.5) herdado do custo quadrático da atenção.

2.4.0.0.3 Cabeça distribucional vs. cabeça escalar. Um detalhe arquitetural do TabPFN é central ao Capítulo 7: em regressão, sua camada de saída não devolve um número, mas uma *bar distribution* — um histograma discretizado sobre o intervalo do alvo, do qual se leem quantis arbitrários da distribuição preditiva. O modelo entrega, nativamente, regressão *distribucional* (Seção 2.1). Em contraste, o **TabFM** (Google Research, 2026; KONG et al., 2026) — implementação independente do paradigma ICL, com arquitetura híbrida que combina atenção entre colunas, compressão de cada linha em tokens e um Transformer de ICL, e *checkpoints* separados por tarefa — decodifica em regressão um único escalar: é um professor exclusivamente *pontual*. Essa assimetria de cabeças de saída, e não qualquer diferença de acurácia média, é o que tornará o TabPFN o professor natural da destilação distribucional do Capítulo 7. Registre-se ainda que ambos os modelos carregam limites arquiteturais herdados do pré-treinamento — o TabFM, por exemplo, admite no máximo 10 classes em classificação, e até a escrita desta dissertação está documentado em relatório técnico, sem artigo revisado por pares (Google Research, 2026; KONG et al., 2026) — limites que se tornam células ausentes do benchmark e exigem a política estatística declarada no Capítulo 4.

2.4.0.0.4 O trade-off constitutivo. O mecanismo da Figura 2.2 tem um preço estrutural: *o conjunto de treino viaja com o modelo a cada predição*. O custo de treinamento é próximo de zero — montar o contexto —, mas cada passe de inferência reprocessa o contexto inteiro, o que coloca o custo por predição ordens de magnitude acima do de um GBDT, cuja inferência percorre algumas árvores. Em cenários de inferência intensiva, essa conta domina qualquer vantagem de acurácia — o Capítulo 5 a quantifica e o Capítulo 7 propõe uma saída.

2.5 Destilação de conhecimento

Se um modelo caro é bom demais para descartar e caro demais para servir, a resposta clássica é a *destilação de conhecimento*: treinar um modelo rápido (o *aluno*) para imitar as saídas de um modelo caro (o *professor*). A ideia nasce como *compressão de modelos* (BUCILĂ; CARUANA; NICULESCU-MIZIL, 2006) — um *ensemble* volumoso rotula uma grande massa de dados não rotulados, e uma rede pequena é treinada nesses rótulos — e ganha sua formulação moderna com HINTON; VINYALS; DEAN (2015).

2.5.0.0.1 *Soft targets: por que imitar é mais fácil que aprender.* A observação central de HINTON; VINYALS; DEAN (2015) é que as *probabilidades* que o professor atribui às classes erradas carregam informação que o rótulo verdadeiro não tem: ao classificar a quarta linha da Tabela 2.1, um professor que responde “não, com 85%” ensina mais do que o rótulo seco “não” — codifica o quão ambíguo é o caso. Para expor essa estrutura, amplifica-se a entropia da saída com uma *temperatura* T na *softmax*,

$$p_i(T) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}, \quad (2.6)$$

em que z_i são os *logits*; com $T > 1$, as probabilidades pequenas deixam de ser esmagadas. O aluno é treinado numa combinação de duas perdas: a entropia cruzada usual contra os rótulos verdadeiros e uma perda de imitação contra os *soft targets* do professor na mesma temperatura. Em regressão, a receita análoga substitui o rótulo pelo valor predito pelo professor — e, na extensão distribucional do Capítulo 7, pela *curva de quantis* inteira do professor.

2.5.0.0.2 Destilar para árvores. A linhagem *born-again* mostrou cedo que o aluno não precisa ser uma rede: BREIMAN; SHANG (1996) comprimem um *ensemble* de árvores numa única árvore treinada nas predições do comitê, com perda de fidelidade surpreendentemente pequena; VIDAL; SCHIFFER (2020) dão à compressão de *ensembles* tratamento exato moderno. Na direção inversa, FROSST; HINTON (2017) destilam uma rede profunda numa árvore de decisão suave em busca de interpretabilidade, e a destilação de redes em redes de mesma capacidade (*born-again networks*) revelou que até a auto-imitação pode melhorar o aluno (FURLANELLO et al., 2018). A lição transversal: a destilação é agnóstica ao par professor–aluno; o que se transfere é a *função* aprendida, exposta pelas saídas.

2.5.0.0.3 Destilar *foundation models* tabulares. Com professores ICL, a destilação ganha um atrativo adicional: ela remove exatamente o gargalo constitutivo da família (o contexto que viaja a cada predição), convertendo um professor de inferência cara num aluno de inferência barata. O *Pocket FM* (TANNA et al., 2026a) estabelece essa agenda para *classificação*, em escala, com uma salvaguarda metodológica que o Capítulo 7 herda: a rotulagem *out-of-fold* — o professor rotula cada exemplo condicionado apenas nas demais partições, nunca nele próprio — para que o aluno não aprenda dos vazamentos do professor. O que permanece em aberto nessa linha, e constitui a contribuição desta dissertação, é a extensão à *regressão distribucional*: destilar não a média, mas a distribuição preditiva — o que exige o ferramental da próxima seção. O Capítulo 3 situa esse recorte no estado da arte.

2.6 Regressão distribucional: quantis, CRPS e calibração

Prever um número é útil; prever um número *com a incerteza em volta* é o que decisões de risco exigem. Considere um modelo que avalia imóveis: dizer “este imóvel vale 500 mil” e dizer “vale 500 mil, e com 80% de probabilidade entre 430 e 580 mil” são produtos diferentes — o segundo permite precificar risco, definir margens e recusar decisões quando a incerteza é grande demais. Dois modelos com o mesmo erro pontual médio podem diferir radicalmente na qualidade dessa segunda resposta, e as métricas pontuais (RMSE, MAE) são cegas à diferença. Esta seção apresenta o instrumental que a enxerga — quantis e perda *pinball*, CRPS, calibração e afiação — na profundidade que o Capítulo 7 pressupõe: aqui a matemática é detalhada de propósito, pois estas são as grandezas da contribuição.

2.6.1 Quantis e a perda *pinball*

O quantil condicional $q_\tau(\mathbf{x})$ é o valor abaixo do qual o alvo cai com probabilidade τ , dado $\mathbf{x}$: o quantil $\tau = 0,5$ é a mediana condicional; os quantis 0,1 e 0,9 delimitam um intervalo central de 80%. A regressão de quantis (KOENKER; BASSETT, 1978) estima q_τ diretamente, minimizando a *perda pinball* (ou perda de quantil): com erro $u = y - \hat{q}_\tau$,

$$\rho_\tau(u) = \begin{cases} \tau u, & u \geq 0 \quad (\text{subestimou o alvo}), \\ (\tau - 1)u, & u < 0 \quad (\text{superestimou o alvo}). \end{cases} \quad (2.7)$$

2.6.1.0.1 A intuição assimétrica. A perda é uma rampa com duas inclinações (Figura 2.3): para $\tau = 0,9$, subestimar custa 0,9 por unidade de erro e superestimar custa apenas 0,1. O minimizador ótimo, portanto, prefere errar para cima — e erra para cima na medida exata: a predição que minimiza a perda esperada é precisamente o quantil 0,9 da distribuição condicional. É essa propriedade — o minimizador da perda *pinball* de nível τ é o quantil τ — que faz dela o instrumento canônico da regressão de quantis; com $\tau = 0,5$, ela se reduz (a um fator) ao erro absoluto, cujo minimizador é a mediana. Treinar um modelo numa *grade* de níveis $\tau \in \{0,05, \dots, 0,95\}$ produz uma curva de quantis — uma discretização da distribuição preditiva inteira.

2.6.1.0.2 Um efeito colateral da grade: o cruzamento de quantis. Quando os níveis da grade são estimados de forma independente, nada garante a monotonicidade que a definição exige — o modelo pode produzir $\hat{q}_{0,8} < \hat{q}_{0,7}$ para alguma linha, o chamado *cruzamento de quantis*, que torna a “distribuição” internamente inconsistente. O reparo pragmático padrão é reordenar os quantis preditos de cada linha em ordem crescente, operação que nunca piora a perda *pinball* total e restaura a validade da curva; é o reparo adotado nos alunos multi-quantil do Capítulo 7.




Figura 2.3: A perda *pinball* penaliza os dois lados do erro com inclinações diferentes, e é essa assimetria que aponta o minimizador para o quantil τ . Para $\tau = 0,9$ (linha sólida), subestimar o alvo custa nove vezes mais que superestimar, de modo que a predição ótima se posiciona no ponto em que o alvo só a excede 10% das vezes — o quantil 0,9. Em $\tau = 0,5$ (tracejada), a perda é simétrica e recupera o erro absoluto, cujo minimizador é a mediana.

2.6.2 CRPS: uma régua para distribuições

Como comparar duas distribuições preditivas? A régua desta dissertação é o *continuous ranked probability score* (CRPS): para uma distribuição preditiva com função de distribuição acumulada F e um alvo observado y ,

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} (F(z) - \mathbb{I}\{z \geq y\})^2 dz, \quad (2.8)$$

a distância quadrática integrada entre a CDF predita e a CDF degrau do valor observado. Duas propriedades o qualificam. Primeiro, o CRPS é uma *regra de pontuação própria* (*proper scoring rule*) (GNEITING; RAFTERY, 2007): seu valor esperado é minimizado quando o modelo reporta a verdadeira distribuição condicional — não há como ganhar pontuação “blefando” uma distribuição diferente da que o modelo de fato acredita, o que o torna o critério honesto para avaliar incerteza. Segundo, ele *generaliza o erro absoluto*: se F colapsa num ponto (predição pontual), a Eq. 2.8 reduz-se a $|\hat{y} - y|$ — de modo que o CRPS permite comparar, na mesma régua e na unidade do alvo, modelos pontuais e distribucionais. Menor é melhor.

2.6.2.0.1 O estimador de grade. Na prática, quando o modelo entrega uma grade de quantis em vez de uma CDF contínua, o CRPS é estimado como duas vezes a média da perda *pinball* sobre a grade de níveis (GNEITING; RANJAN, 2011),

$$\widehat{\text{CRPS}}(F, y) = \frac{2}{|\mathcal{T}|} \sum_{\tau \in \mathcal{T}} \rho_{\tau}(y - \hat{q}_{\tau}), \quad (2.9)$$

o estimador padrão da prática de previsão probabilística — e o elo formal entre as duas grandezas desta seção: minimizar a perda *pinball* em toda a grade é, a uma constante, otimizar o CRPS discretizado. Por ser uma discretização, o estimador carrega um viés dependente da grade; o Capítulo 7 reporta a validação desse viés no protocolo desta dissertação e a regra de leitura que dele decorre (comparações internas, nunca valores absolutos entre trabalhos).

2.6.3 Calibração e afiação

O CRPS resume a qualidade distribucional num número; os diagnósticos de *calibração* a decompõem. Um intervalo preditivo nominal de 80% está *calibrado* se cobre o alvo em cerca de 80% dos casos de teste. A métrica operacional é o PICP (*prediction interval coverage probability*): a fração dos alvos de teste que caem dentro do intervalo nominal — PICP80 muito abaixo de 80% denuncia um modelo *superconfiante* (intervalos estreitos demais), muito acima, um modelo *subconfiante* (intervalos largos demais). Cobertura, porém, é condição necessária e não suficiente: um intervalo absurdamente largo cobre sempre e não informa nada. Por isso a cobertura é lida junto com a *afiação* (*sharpness*) — a largura média dos intervalos: entre modelos igualmente calibrados, o de intervalos mais estreitos é o mais informativo (GNEITING; BALABDAOUI; RAFTERY, 2007).

2.6.4 Dois *baselines* distribucionais nativos

Fecham o instrumental dois modelos clássicos que produzem distribuições preditivas sem professor algum — os controles naturais de qualquer proposta de destilação distribucional. As *quantile regression forests* (QRF) estendem as florestas aleatórias guardando, em cada folha, não a média mas *todos* os valores de treino que ali caem; a distribuição preditiva de uma linha nova é a distribuição empírica ponderada desses valores, da qual se lê qualquer quantil (MEINSHAUSEN, 2006). O *NGBoost* segue a rota paramétrica: um *gradient boosting* cujas saídas são os *parâmetros* de uma distribuição (por exemplo, média e variância de uma gaussiana), treinado por gradientes naturais sobre uma regra de pontuação própria (DUAN et al., 2020). QRF representa a via não-paramétrica; NGBoost, a paramétrica — e ambos aparecem como competidores no Capítulo 7.

2.7 Comparação estatística de algoritmos

Resta o último instrumento: como afirmar, com honestidade estatística, que um modelo é melhor que outro — ou que dois modelos empatam — a partir de resultados em uma coleção de conjuntos de dados? Esta seção apresenta a teoria dos testes que o Capítulo 4 adota como protocolo e o Capítulo 5 aplica; a exposição segue o arcabouço canônico da área (DEMŠAR, 2006; BENAVIDI et al., 2017).

2.7.0.0.1 Por que não uma ANOVA sobre as métricas? Porque as métricas não são *comensuráveis* entre conjuntos de dados: uma AUC de 0,95 num conjunto fácil e uma de 0,75 num difícil não estão na mesma escala, e médias ou variâncias entre conjuntos misturam alhos com bugalhos — além de a normalidade, pressuposto da ANOVA, não ter por que valer. A solução de DEMŠAR (2006) é trabalhar com *ranks*: em cada conjunto de dados, ordenam-se os

k modelos do melhor (1) ao pior (k); os ranks, ao contrário das métricas, são comparáveis entre conjuntos por construção.

2.7.0.0.2 Qual é a unidade de análise? Uma segunda decisão precede qualquer teste: o que conta como uma observação independente? Quando cada modelo é avaliado por validação cruzada, é tentador tratar cada *fold* como uma réplica — mas os folds de um mesmo conjunto de dados compartilham a maior parte dos exemplos e não são independentes; usá-los como réplicas inflaria artificialmente o N efetivo e, com ele, o poder aparente dos testes (*pseudo-replicação*). A unidade correta é o *conjunto de dados*: cada um contribui com um único número por modelo (a média entre folds), e os folds alimentam apenas a descrição da variabilidade intra-conjunto. Todos os testes a seguir pressupõem essa escolha.

2.7.0.0.3 Friedman: o teste *omnibus*. O teste de Friedman pergunta se as diferenças entre os ranks médios R_j dos k modelos sobre os N conjuntos são explicáveis pelo acaso (FRIEDMAN, 1937). Sob a hipótese nula de equivalência entre todos os modelos, a estatística

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^k R_j^2 - \frac{k(k+1)^2}{4} \right] \quad (2.10)$$

segue aproximadamente uma distribuição qui-quadrado com $k - 1$ graus de liberdade. Essa aproximação é conservadora quando N é pequeno — o regime desta dissertação —, e por isso reporta-se também a correção de Iman–Davenport,

$$F_F = \frac{(N-1) \chi_F^2}{N(k-1) - \chi_F^2}, \quad (2.11)$$

que segue uma distribuição F e rejeita com mais poder (IMAN; DAVENPORT, 1980). Um Friedman significativo diz apenas que *alguma* diferença existe; localizá-la é tarefa dos testes *post-hoc*.

2.7.0.0.4 Nemenyi e o diagrama de diferença crítica. O *post-hoc* de Nemenyi compara todos os pares de modelos pelos ranks médios, com controle embutido do erro de família (NEMENYI, 1963): dois modelos diferem significativamente se seus ranks médios distam mais que a *diferença crítica*

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}}, \quad (2.12)$$

em que q_α vem da distribuição da amplitude studentizada (DEMŠAR, 2006). O resultado é usualmente apresentado num *diagrama de diferença crítica* (diagrama CD), e vale a pena aprender a lê-lo, pois o Capítulo 5 o utiliza repetidamente: os modelos são dispostos sobre um eixo horizontal na posição de seu rank médio (melhores de um lado, piores do outro); uma régua indica o comprimento do CD; e barras horizontais espessas conectam grupos de modelos cujos ranks

médios distam menos que o CD — *modelos ligados pela mesma barra não são estatisticamente distinguíveis* àquele nível. Duas leituras erradas a evitar: a barra não diz que os modelos conectados são iguais (apenas que o teste não os distingue — ausência de evidência não é evidência de ausência), e a Eq. 2.12 mostra que o CD cresce com k e encolhe lentamente com N : com muitos modelos e poucos conjuntos, barras largas são a consequência aritmética esperada, não uma anomalia.

2.7.0.0.5 Wilcoxon pareado com correção de Holm. Para pares específicos de modelos, o teste de postos sinalizados de Wilcoxon é mais poderoso que o Nemenyi, porque usa as *magnitudes* das diferenças por conjunto de dados, não apenas os ranks globais (WILCOXON, 1945). Ao testar muitos pares, porém, multiplica-se a chance de falsos positivos; o procedimento de Holm corrige isso ordenando os p-valores e exigindo limiares progressivamente mais frouxos — controle do erro de família menos conservador que a correção de Bonferroni simples (HOLM, 1979). Uma limitação aritmética importa no regime desta dissertação: com N conjuntos de dados, o menor p-valor bilateral que o Wilcoxon pode produzir é $2 \cdot (1/2^N)$ — com $N = 5$, o piso é 0,0625, e rejeitar a 0,05 é *matematicamente impossível*, antes de qualquer correção. O Capítulo 4 declara as consequências protocolares desse piso.

2.7.0.0.6 O que significa “praticamente equivalente”? O teste bayesiano com ROPE. O arcabouço frequentista tem uma assimetria incômoda: ele pode rejeitar a igualdade, mas não pode *afirmá-la* — não-rejeição não é evidência de equivalência, especialmente com N pequeno e pouco poder. BENA VOLI et al. (2017) oferecem o complemento bayesiano: o teste de postos sinalizados bayesiano estima a distribuição *posterior* da diferença média de desempenho entre dois modelos e introduz uma *região de equivalência prática* (ROPE, *region of practical equivalence*) — um intervalo em torno de zero, fixado *a priori* por juízo de domínio, dentro do qual diferenças são irrelevantes na prática. A posterior é então resumida em três probabilidades: a de o primeiro modelo ser praticamente melhor, a de o segundo ser praticamente melhor e a de os dois serem *praticamente equivalentes* (a massa da posterior dentro da ROPE). Dizer que dois modelos são praticamente equivalentes é, portanto, uma afirmação positiva e quantificada — “com probabilidade p , a diferença entre eles é menor do que o que declaramos irrelevante” — e não um não-resultado. É esse instrumento que autoriza as conclusões de empate do Capítulo 5; a escolha do raio da ROPE e sua análise de sensibilidade são decisões de protocolo, especificadas no Capítulo 4.

2.7.0.0.7 Tamanho de efeito e decomposição de variância. Significância não mede relevância, e dois complementos fecham o arcabouço. O tamanho de efeito de Cohen na variante pareada, $d_z = \bar{d}/s_d$ (média das diferenças por conjunto dividida pelo seu desvio-padrão), quantifica *quanto* dois modelos diferem na escala da própria variabilidade das diferenças. E a razão de correlação $\eta^2 = SQ_{\text{entre}}/SQ_{\text{total}}$ — aqui aplicada aos ranks, com os modelos agrupados por

família — decompõe a variância total dos ranks na parcela explicada pelo agrupamento: η^2 alto diria que a família (GBDT, aprendizado profundo, *foundation model*) determina o desempenho; η^2 baixo, que a variação dentro das famílias domina e a escolha do modelo individual importa mais que a do paradigma. O Capítulo 5 usa exatamente essa leitura.

Transição. Este capítulo montou o vocabulário: o objeto (dados tabulares), os competidores (GBDTs, aprendizado profundo, *foundation models* com ICL), as técnicas transversais (destilação, regressão distribucional) e a régua (testes estatísticos sobre ranks, com a camada bayesiana de equivalência). O próximo capítulo usa esse vocabulário para mapear o estado da arte — os benchmarks tabulares existentes e seus protocolos, a literatura de destilação de *foundation models* tabulares e as avaliações distribucionais independentes — e para demarcar, com datas e verificações explícitas, as lacunas que as três contribuições desta dissertação ocupam.

3

Trabalhos Relacionados

Resumo do capítulo. Este capítulo posiciona a dissertação em seis eixos da literatura: os benchmarks tabulares que consolidaram a comparação GBDT vs. aprendizado profundo; a avaliação dos *foundation models* tabulares; a família Kolmogorov–Arnold aplicada a dados tabulares; as estratégias de aceleração e *serving* desses modelos; a destilação de *foundation models* tabulares; e a seleção de algoritmos por *meta-learning*. Cada seção fecha com a lacuna específica que este trabalho ocupa, e a Seção 3.7 consolida o mapa de lacunas numa tabela-síntese que liga cada lacuna ao capítulo que a ataca. Como o campo avança em ciclos de poucos meses, toda caracterização de trabalho de terceiros neste capítulo provém de verificações online datadas — conduzidas entre 13 e 20 de julho de 2026 e revisadas em varredura completa em 4 de outubro de 2026 —, e os qualificadores de escopo dos trabalhos citados (“classificação apenas”, “sem metodologia pública”, “contemporâneo a este trabalho”) são preservados deliberadamente.

Material associado. As seções de *Related Work* dos dois artigos intermediários (`latex/ail/main.tex` e `latex/ai2/main.tex` no repositório do projeto) condensam este capítulo em inglês e foram auditadas contra as fontes primárias. Os registros canônicos das verificações de novidade, com datas e vereditos, estão em `docs/memo-novidade-destilacao.md` (15/07, 20/07 e 04/10/2026) e `docs/memo-novos-modelos-kan-tabkan-tabfm.md` (13/07 e 04/10/2026).

Uma nota de método antes do conteúdo. A literatura coberta por este capítulo move-se em ciclos de aproximadamente três meses — TabPFN-2.5 em novembro de 2025, Pocket FM em maio de 2026, TabFM em junho de 2026, o trabalho contemporâneo de JEONG et al. (2026) em outubro de 2026 — e boa parte dos trabalhos centrais ainda não passou por revisão por pares. Qualquer afirmação do tipo “nenhum trabalho faz X” é, portanto, perecível. O contrato de conduta científica deste projeto (Capítulo 4) exige que afirmações de novidade sejam sustentadas por verificação online datada; as datas relevantes são 13–20/07/2026 (antes de investir nas contribuições) e 04/10/2026 (re-varredura pré-entrega, que inclusive corrigiu um lapso nosso,

registrado na Seção 3.3). As lacunas enunciadas a seguir devem ser lidas como “abertas até onde verificamos, nas datas declaradas” — nunca como certezas atemporais.

O percurso do capítulo segue a ordem das contribuições. A Seção 3.1 revisa os benchmarks que definiram o estado da arte da comparação entre famílias e a controvérsia GBDT vs. aprendizado profundo; a Seção 3.2 cobre os *foundation models* tabulares e como vêm sendo avaliados; a Seção 3.3, as avaliações existentes da família Kolmogorov–Arnold em dados tabulares; a Seção 3.4, as estratégias de aceleração que competem com a destilação; a Seção 3.5, a linhagem de destilação — da compressão de modelos clássica aos trabalhos de 2026 sobre *foundation models* tabulares; e a Seção 3.6, a literatura de seleção de algoritmos que o nosso arcabouço de decisão confronta. A Seção 3.7 fecha com a tabela-síntese de lacunas.

3.1 Benchmarks tabulares e a controvérsia GBDT vs. aprendizado profundo

3.1.0.0.1 Os benchmarks de referência. O protocolo moderno de comparação entre *gradient boosting* e aprendizado profundo em dados tabulares foi estabelecido por dois trabalhos. GRINSZTAJN; OYALLON; VAROQUAUX (2022) deram forma quantitativa ao ditado “árvores vencem em tabelas”, identificando os vieses indutivos que explicam a vantagem: a irregularidade das funções-alvo tabulares e a presença de atributos não informativos favorecem métodos baseados em árvores sobre redes neurais. MCELFRESH et al. (2023) matizaram a conclusão em escala maior de conjuntos: redes vencem com frequência não trivial, e meta-características dos conjuntos predizem parcialmente quando isso ocorre. Antes de ambos, GORISHNIY et al. (2021) haviam padronizado os protocolos de comparação para o aprendizado profundo tabular — arquiteturas de referência, *tuning* equalizado, múltiplas sementes. Mais recentemente, o TabArena (ERICKSON et al., 2025) mantém um benchmark “vivo” com dezenas de conjuntos e ranking contínuo, atualizado à medida que novos modelos são lançados.

3.1.0.0.2 A tradição de comparação estatística. Paralela aos benchmarks corre a literatura sobre *como* comparar classificadores em múltiplos conjuntos de dados. O protocolo frequentista canônico — Friedman com *post-hoc* corrigido, operando sobre conjuntos e nunca sobre *folds* — foi fixado por DEMŠAR (2006); BENAVALI et al. (2017) argumentaram, uma década depois, que testes de hipótese nula respondem à pergunta errada (“há diferença?” em vez de “a diferença importa?”) e propuseram a alternativa bayesiana com região de equivalência prática (ROPE). Os benchmarks tabulares de referência adotam o primeiro arcabouço; a camada bayesiana, embora disponível há quase uma década, raramente aparece neles — e a sensibilidade das conclusões ao raio da ROPE quase nunca é analisada.

3.1.0.0.3 A controvérsia como afirmação condicional. As duas narrativas — “árvores vencem” (GRINSZTAJN; OYALLON; VAROQUAUX, 2022) e “o aprendizado profundo moderno alcançou” (HOLZMÜLLER; GRINSZTAJN; STEINWART, 2024; GORISHNIY; KOTELNIKOV; BABENKO, 2025) — são frequentemente tratadas como contraditórias. Nossa leitura, sustentada pelas curvas de aprendizado do Capítulo 5, é que ambas são afirmações condicionais ao tamanho amostral e à estrutura da tarefa, verdadeiras em regimes distintos: o cruzamento de liderança entre famílias é real, específico por conjunto, e mensurável quando se varre diretamente o tamanho do treino. A chegada dos *foundation models* desloca a controvérsia inteira: o novo eixo não é árvore vs. rede, mas pré-treinado vs. treinado do zero. Cabe registrar que os dois benchmarks de referência são anteriores à segunda geração de *foundation models* tabulares — não é defeito metodológico, é datação: nenhum deles poderia ter incluído modelos que ainda não existiam.

3.1.0.0.4 Lacuna. Nosso benchmark não compete em largura (18 conjuntos é menos do que o TabArena cobre); diferencia-se em três frentes que permaneciam abertas. Primeira, profundidade de protocolo por célula: validação cruzada aninhada com *tuning* uniforme por família, e inferência frequentista e bayesiana — esta última com a camada de equivalência prática via ROPE (BENAVOLI et al., 2017) e análise de sensibilidade do raio — sobre as mesmas células. Segunda, avaliação multicritério: latência de inferência, custo de treinamento e de *tuning*, robustez e interpretabilidade medidos sob o mesmo protocolo, e não apenas acurácia. Terceira, atualidade verificada: inclusão simultânea da geração 2026 de *foundation models* (TabFM, medido semanas após o lançamento) e da família Kolmogorov–Arnold, ambas ausentes dos benchmarks neutros à data das nossas verificações (13–15/07/2026). O Capítulo 5 executa esse desenho.

3.2 *Foundation models* tabulares e sua avaliação

3.2.0.0.1 A linhagem PFN/ICL. O TabPFN v2 (HOLLMANN et al., 2025) e sua atualização v2.5 (GRINSZTAJN et al., 2025) estabeleceram o aprendizado em contexto com redes ajustadas a *priors* (*prior-fitted networks*) para dados tabulares: uma rede pré-treinada em conjuntos sintéticos condiciona no conjunto de treino como *prompt* no momento da predição, sem atualização de gradientes na tarefa-alvo. A linha evoluiu rapidamente — TabPFN-3 e, mais recentemente, TabPFN-3.5 (GRINSZTAJN et al., 2026) — e inspirou variantes que exploram escala e velocidade: o TabICL (QU et al., 2025) estende o paradigma a conjuntos grandes; o TabFlex (ZENG et al., 2025) usa atenção linear para escalar a milhões de linhas; o MotherNet (MÜLLER; CURINO; RAMAKRISHNAN, 2023) amortiza o ajuste num hiperrede (*hyper-network*) que emite os pesos de um MLP em um único *forward*.

3.2.0.0.2 TabFM. O TabFM (Google Research, 2026) é uma implementação independente do mesmo paradigma pelo Google Research, com arquitetura híbrida de atenção sobre colunas e compressão de linhas, liberada com pesos em junho de 2026. À data da nossa integração (julho de 2026), não havia artigo: a citação possível era o blog oficial, o *model card* e o repositório. Desde o final de setembro de 2026 existe um relatório técnico oficial (KONG et al., 2026), ainda sem revisão por pares — que, entre outras coisas, confirma em fonte primária a cabeça de regressão escalar que havíamos verificado arquiteturalmente (fato que importa ao Capítulo 7). O enquadramento honesto, que adotamos em toda a dissertação, é o de *replicação inter-laboratórios* do paradigma PFN/ICL — Google vs. Prior Labs —, não o de um segundo paradigma.

3.2.0.0.3 Como esses modelos vêm sendo avaliados. Os números públicos do TabFM à data do lançamento provinham do próprio proponente (avaliação do Google sobre o TabArena), com verificação independente apenas parcial — prática padrão em lançamentos industriais, mas que deixa a comunidade sem evidência neutra justamente no período em que as decisões de adoção são tomadas. Em paralelo, uma linha recente avalia *foundation models* tabulares diretamente como estimadores de densidade condicional em regressão, com regras de pontuação próprias (IZBICKI; RODRIGUES, 2026; LANDSGESELL; KNOLL; WENZEL, 2026) — avaliação distribucional do *teacher*, sem qualquer componente de destilação ou de *serving*.

3.2.0.0.4 Lacuna. Até onde verificamos (13/07/2026, reconfirmado em 04/10/2026), não havia comparação neutra TabPFN $\times$ TabFM sob protocolo idêntico — mesmas partições, mesmo pré-processamento, mesma política de subamostragem de contexto. A exigência não é burocrática: num campo em que os modelos recebem atualizações mensais e os resultados publicados misturam versões, uma comparação só é interpretável com versões pinadas e políticas espelhadas (no nosso caso, o mesmo teto de 50 mil linhas de contexto e a mesma exclusão estrutural do conjunto de 100 classes para ambos os modelos). O Capítulo 5 fornece essa comparação, enquadrada como replicação inter-laboratórios do paradigma; e a avaliação distribucional dos *teachers* — complementar aos benchmarks de densidade condicional citados — reaparece no Capítulo 7 como insumo da destilação, eixo que nenhum dos trabalhos de avaliação cobre.

3.3 A família Kolmogorov–Arnold em dados tabulares

3.3.0.0.1 Proponentes. As redes de Kolmogorov–Arnold (KAN) (LIU et al., 2025) invertem o MLP: funções de ativação univariadas aprendíveis (B-splines) vivem nas arestas, e os nós apenas somam — um viés indutivo de aditividade suave. O trabalho teve recepção de alto impacto (apresentação oral na ICLR 2025), mas sua evidência original concentra-se em regressão simbólica e problemas científicos, não em dados tabulares heterogêneos. A extensão tabular mais direta é o TabKAN (ESLAMIAN; Afzal Aghaei; CHENG, 2025), um arcabouço modular

de variantes KAN cuja melhor configuração reportada (ChebyKAN) alega superar XGBoost e *transformers* tabulares em dez conjuntos — AUC média de 0,857 contra 0,814 do XGBoost nos oito binários. Há ainda o TabKANet (GAO et al., 2024), que usa camadas KAN apenas como módulo de *embedding* numérico dentro de um *transformer*.

3.3.0.0.2 Avaliações independentes. A literatura crítica aponta na direção oposta aos proponentes. YU; YU; WANG (2024) compararam KAN e MLP sob paridade simultânea de parâmetros e FLOPs e encontraram o MLP vencendo em seis de oito tarefas de aprendizado de máquina, com o KAN dominando apenas em regressão simbólica. POETA et al. (2024) conduziram o primeiro benchmark independente KAN-vs-MLP em dados tabulares, com resultados favoráveis ao KAN em acurácia mas custo computacional maior; é um estudo pioneiro e suas escolhas são defensáveis para uma primeira investigação, mas duas limitações de escopo importam aqui — não há *baselines* GBDT e o treino usa apenas dez épocas — de modo que o estudo não responde à pergunta que o praticante faz (“KAN compete com o XGBoost?”). Quanto ao TabKAN, as ressalvas devem-se menos aos autores — um grupo pequeno publicando em venue recém-criada, com orçamento computacional limitado — do que ao estado da evidência: seis dos dez conjuntos têm menos de 8 mil amostras, não há regressão, e o XGBoost de comparação parece subajustado (AUC de 0,726 em `credit_g`, quando nosso próprio *tuning* obtém acima de 0,77 no mesmo conjunto).

3.3.0.0.3 Registro de um lapso nosso. Nas checagens de julho de 2026 afirmáramos que nenhum benchmark independente de KANs tabulares existia; a re-varredura de 04/10/2026 identificou que POETA et al. (2024) é anterior (junho de 2024) e o registro foi corrigido em adendo datado, com a reivindicação reescopada nos artigos e nesta dissertação. O episódio ilustra por que este capítulo insiste em verificações datadas: o erro foi nosso, e o mecanismo de correção previsto no contrato de conduta funcionou.

3.3.0.0.4 Lacuna. O que permanecia aberto — e segue aberto até 04/10/2026, fora deste trabalho — é o teste da família Kolmogorov–Arnold contra o *slate* completo GBDT/DL/*foundation models* num benchmark multicritério de protocolo uniforme: POETA et al. (2024) não têm GBDTs, YU; YU; WANG (2024) não têm GBDTs nem *foundation models*, e nenhum dos dois mede eixos de custo. Nenhum benchmark tabular neutro de larga escala incluía KANs às datas verificadas. O Capítulo 5 fornece exatamente esse teste, com *sanity checks* contra os valores publicados pelos proponentes; o resultado é desfavorável às alegações fortes — KAN e TabKAN terminam no último terço nas três tarefas, com o TabKAN atrás do próprio TabNet em multi-classe e regressão — em linha com a literatura crítica e consistente com a hipótese de *baselines* subajustados nos artigos originais.

3.4 Aceleração e *serving* de *foundation models* tabulares

A principal fraqueza operacional dos *foundation models* tabulares é o custo de inferência: cada predição recondiciona no conjunto de treino inteiro. Uma literatura de aceleração *sem destilação* cresceu rapidamente em 2026, e é a concorrente direta da estratégia que estudamos no Capítulo 7.

3.4.0.0.1 Compressão de contexto. O TACO (ZABERGJA et al., 2026) aprende, de ponta a ponta, uma compressão do conjunto em contexto para cerca de 1% do tamanho original, com inferência até $94\times$ mais rápida. O CRUMB (HEREDGE et al., 2026) seleciona um contexto compacto por casamento distribucional (MMD), sem retreinamento do modelo — é o método representativo do braço “comprimir contexto” que usamos como referência conceitual (nossa fronteira mede a variante mais simples, por subamostragem). Na mesma direção geral, há propostas de *foundation models* tabulares eficientes em memória (LUO et al., 2026).

3.4.0.0.2 Amortização e transferência. O MotherNet (MÜLLER; CURINO; RAMAKRISHNAN, 2023) amortiza o ajuste num hiperrede que emite os pesos de um MLP em um único *forward* — elimina o custo de recondicionamento trocando-o por uma rede geradora. O TL-ANDI (LIN; LI, 2026) combina rótulos destilados e ancoragem para transferência a tarefas com contexto restrito — objetivo ortogonal ao nosso (não produz alunos rápidos nem trata o eixo distribucional), citado por completude do mapa.

3.4.0.0.3 Quantização e calibração pós-hoc. A quantização FP8 da atenção (KÜBLER et al., 2026) é uma quarta alavanca emergente de *serving*, que não medimos neste trabalho. E a calibração conformal pós-hoc do próprio *teacher* (PARK; PARK; CHANG, 2026) é a rota complementar para obter intervalos calibrados sem nenhum aluno rápido — paga-se a latência do *foundation model* em troca de garantias de cobertura.

3.4.0.0.4 Engenharia simples, raramente medida. Truncar o contexto, reduzir o ensemble de inferência e fazer *cache* do contexto processado são prática corrente — e, até onde verificamos, folclore: os trabalhos acima raramente comparam suas propostas contra essas alavancas baratas, e as alavancas baratas quase nunca são medidas entre si.

3.4.0.0.5 Lacuna. Cada trabalho citado avalia a própria estratégia contra o *teacher* cheio; nenhum mede as estratégias *entre si* — destilar vs. comprimir contexto vs. reduzir ensemble — nos mesmos conjuntos de *hold-out*, sob o mesmo protocolo e com os mesmos eixos de custo. Essa fronteira cruzada é uma das contribuições do Capítulo 7, que a executa e extrai dela dois achados próprios: a redução de ensemble é subestimada (um membro aproxima oito

a um sétimo da latência) e o último dobro de contexto é desproporcionalmente caro em GPUs de 16 GB.

3.5 Destilação de *foundation models* tabulares

3.5.0.0.1 A linhagem clássica. A mecânica de treinar um modelo pequeno nas saídas de um modelo grande é literatura estabelecida: a compressão de modelos via rótulos suaves e conjuntos de transferência remonta a BUCILÁ; CARUANA; NICULESCU-MIZIL (2006), a formulação moderna com temperatura é de HINTON; VINYALS; DEAN (2015), e a transposição para árvores tem linhagem própria — BREIMAN; SHANG (1996), as *born-again trees* de VIDAL; SCHIFFER (2020) e a destilação para árvores de decisão suaves de FROSST; HINTON (2017). É dessa mecânica que partimos; o que muda com os *foundation models* é o *teacher* (um modelo de aprendizado em contexto, cujo custo é na inferência) e, no nosso caso, o alvo (curvas de quantis, não rótulos).

3.5.0.0.2 Pocket FM: a formulação para classificação. O trabalho que estabelece a destilação de *foundation models* tabulares é o Pocket FM (TANNA et al., 2026a): alunos XGBoost/CatBoost/LightGBM/MLP treinados em rótulos suaves de múltiplos *teachers* (TabICLv2, TabPFNV2.6, LimiX, Orion-MSP) sobre 153 conjuntos, retendo 96,5% do AUC do *teacher* com acelerações de 38–860×. Duas contribuições metodológicas do Pocket FM importam diretamente a esta dissertação: a demonstração de que a rotulagem *out-of-fold* (OOF) estratificada é necessária — um *teacher* de aprendizado em contexto que pontua o próprio treino produz rótulos quase determinísticos, colapsando os alvos suaves — e a análise de quando a destilação funciona ou falha (ganhos concentrados em baixa dimensionalidade). O artigo-irmão clínico (TANNA et al., 2026b) estende a análise a 19 conjuntos de saúde, adicionando calibração e *fairness*, e reporta que múltiplos *teachers* não superam o melhor *teacher* único. Ambos os trabalhos são **exclusivamente de classificação**. Adotamos a rotulagem OOF do Pocket FM como base — reinventá-la seria pior, ignorá-la seria vazamento — e delimitamos nossa contribuição nesse eixo específico ao que o OOF protege *em regressão distribucional*: calibração, não acurácia (Capítulo 7).

3.5.0.0.3 Variantes e vizinhos. O GEAR (QIN et al., 2026) adiciona uma variante em dois estágios com expansão sintética do conjunto de transferência — classificação apenas. O Tab-Distill (DISSANAYAKE; DUTTA, 2025) destila *transformers* em MLPs minúsculos no regime *few-shot* de classificação (e ocupa o nome, razão pela qual não o usamos). Outra linha destila *foundation models* em modelos aditivos generalizados (GAMs) para interpretabilidade, não velocidade (JIA et al., 2026). E a Prior Labs comercializa, junto ao TabPFN-2.5, um motor de destilação fechado (GRINSZTAJN et al., 2025): proprietário, com comparações de acurácia–

latência no relatório técnico mas **sem metodologia nem código públicos** — evidência de demanda industrial pela estratégia, não evidência científica sobre ela.

3.5.0.0.4 As peças distribucionais existem — separadas. Vale registrar que nenhum ingrediente isolado da destilação distribucional é novo, e a lacuna está precisamente na composição. A regressão quantílica com perda *pinball* — a perda assimétrica cujo minimizador é o quantil τ — é clássica (KOENKER; BASSETT, 1978); o CRPS como regra de pontuação própria e seu estimador padrão em grade de quantis são padrão em previsão probabilística (GNEITING; RAFTERY, 2007; GNEITING; RANJAN, 2011); e o XGBoost (CHEN; GUESTRIN, 2016) suporta, desde a versão 2.0, objetivos multi-quantil nativos — o que faz de um GBDT quantílico um corpo de aluno natural para receber curvas de quantis. Do lado do *teacher*, o TabPFN v2.5 expõe quantis arbitrários da distribuição preditiva pela API nativa. As peças estavam todas sobre a mesa; nenhum trabalho público as havia conectado num protocolo de destilação avaliado por CRPS e cobertura.

3.5.0.0.5 Trabalho contemporâneo. Contemporâneo a este trabalho (01/10/2026, quando nossos experimentos já estavam concluídos), JEONG et al. (2026) estendem a destilação a **alvos pontuais** de regressão: transferência por erro quadrático das médias do *teacher*, avaliada apenas em RMSE, com *teachers* mais fortes (TabPFN v3 e TabICLv2) e protocolo distinto, reportando ganhos pontuais. O Capítulo 7 discute a reconciliação entre esses ganhos e o nosso resultado negativo de escopo delimitado — o moderador plausível é o regime de poucos dados, que nosso *sweep* de tamanho de treino varre diretamente, somado à diferença de *teacher* e protocolo. O ponto de posicionamento permanece: JEONG et al. (2026) não tocam quantis, CRPS, calibração nem fronteira de estratégias.

3.5.0.0.6 Lacuna. Às datas verificadas (13–20/07/2026; re-varredura em 04/10/2026, incluindo buscas dirigidas por destilação combinada com quantis/CRPS), nenhum trabalho público cobria: (i) destilação *distribucional* em regressão — transferência de curvas de quantis, avaliada por CRPS e cobertura de intervalos; (ii) uma fronteira entre estratégias de *serving* medidas nos mesmos *hold-outs*; (iii) o TabFM como *teacher* de destilação. As três permaneciam abertas; o Capítulo 7 ataca as três — a última fechando com um negativo arquitetural: a cabeça de regressão do TabFM é pontual (confirmado pelo relatório técnico oficial, KONG et al., 2026), e o espalhamento do seu ensemble é mensuravelmente inútil como distribuição preditiva. Por fim, registramos o que *não* reivindicamos: a formulação básica “destilar *foundation model* tabular em aluno rápido” é do Pocket FM, e em hipótese alguma reivindicamos a primeira destilação de *foundation models* tabulares.

3.6 Seleção de algoritmos e *meta-learning*

3.6.0.0.1 A tradição. A recomendação de algoritmo a partir de meta-características do problema remonta ao problema de seleção de algoritmos de RICE (1976) e tem literatura longa em *meta-learning*. O resultado de MSELFRESH et al. (2023) — de que meta-características predizem parcialmente quando redes vencem árvores — é a versão moderna dessa promessa. A experiência histórica, porém, é de fragilidade fora de grandes coleções de conjuntos: com poucas observações, roteadores aprendidos sobreajustam. Evidência contemporânea independente aponta na mesma direção na era dos *foundation models*: abordagens globais de meta-características não se mostram robustas para explicar ou selecionar entre modelos dessa geração (HERRE et al., 2026).

3.6.0.0.2 Lacuna. O que falta na prática não é mais um recomendador, e sim a validação honesta do recomendador no regime em que benchmarks reais operam: N pequeno de conjuntos. Com $N=18$, a honestidade exige validação explícita *leave-one-dataset-out* (LODO) — cada conjunto predito por um modelo treinado nos demais —, que a literatura de recomendação raramente reporta nesse regime. Nossa análise LODO (Capítulo 6) mostra que a árvore de meta-características não supera *baselines* triviais como preditor (taxa de acerto 0,11 contra 0,44 do *baseline* de classe majoritária, no estudo de 11 modelos), e que a política fixa “*foundation model* primeiro, desviar por restrições” domina por *regret*. O arcabouço resultante é deliberadamente orientado a restrições verificáveis (*constraint-driven*) em vez de roteamento aprendido — uma posição metodológica que registramos como contribuição de honestidade frente à tentativa de sobreajustar recomendadores a poucas observações.

3.7 Síntese das lacunas

A Tabela 3.1 consolida o capítulo: para cada eixo, o que a literatura já oferece, a lacuna identificada nas verificações datadas, e o capítulo desta dissertação que a ataca. A tabela também serve de mapa de leitura reverso — o leitor interessado numa única contribuição pode partir da linha correspondente.

Três observações fecham o capítulo. Primeira, nenhuma das lacunas é uma lacuna de formulação: a mecânica da destilação é clássica (Seção 3.5), os protocolos de benchmark são consolidados (Seção 3.1) — as lacunas são de *medição sob protocolo uniforme*, exatamente o tipo de contribuição que um benchmark neutro com infraestrutura reutilizável pode dar. Segunda, duas das lacunas foram parcialmente erodidas durante a execução do projeto — POETA et al. (2024) antecipou o teste independente de KANs em escopo estreito, e JEONG et al. (2026) alcançou a regressão pontual dias antes da nossa entrega — e ambas as erosões estão registradas com data e reescopo explícito, em vez de silenciadas; o pilar distribucional e a fronteira de estratégias permaneciam, em 04/10/2026, inéditos. Terceira, a tabela deixa visível que as três

Tabela 3.1: Mapa de lacunas por eixo da literatura. Caracterizações conforme verificações on-line datadas (13–20/07/2026; re-varredura em 04/10/2026), registradas nos memorandos citados na abertura do capítulo.

Eixo	O que existe	Lacuna	Onde atacamos
Benchmarks vs. DL	GBDT Protocolos consolidados (GRINSZTAJN; OYAL-LON; VAROQUAUX, 2022; MCELFRISH et al., 2023; GORISHNIY et al., 2021); benchmark vivo (TabArena)	Geração 2026 e família KAN ausentes; multicritério com custo medido sob o mesmo protocolo	Cap. 5
Avaliação de TFMs	Números do proponente (TabFM); avaliação distribucional dos <i>teachers</i> sem destilação (IZBICKI; RODRIGUES, 2026; LANDSGESELL; KNOLL; WENZEL, 2026)	Comparação neutra TabPFN $\times$ TabFM sob protocolo idêntico	Cap. 5
Família KAN em tabular	Avaliações independentes estreitas (POETA et al., 2024; YU; YU; WANG, 2024), sem GBDT/TFM nem eixos de custo	Teste contra o <i>slate</i> completo GBDT/DL/TFM em protocolo multicritério uniforme	Cap. 5
Aceleração/ <i>serving</i> de TFMs	Estratégias avaliadas isoladamente: TACO, CRUMB, MotherNet, quantização FP8 (ZABERGJA et al., 2026; HEREDGE et al., 2026; MÜLLER; CURINO; RAMAKRISHNAN, 2023; KÜBLER et al., 2026)	Fronteira cruzada destilar $\times$ comprimir $\times$ reduzir ensemble nos mesmos <i>hold-outs</i>	Cap. 7
Destilação de TFMs	Classificação (TANNA et al., 2026a,b; QIN et al., 2026); regressão pontual contemporânea (JEONG et al., 2026); motor comercial fechado (GRINSZTAJN et al., 2025)	Regressão <i>distribucional</i> : curvas de quantis, CRPS, cobertura; papel do OOF na calibração; TabFM como <i>teacher</i>	Cap. 7
Seleção de algoritmos	Meta-características desde RICE (1976); fragilidade na era TFM (HERRE et al., 2026)	Validação LODO honesta com N pequeno; política por restrições validada por <i>regret</i>	Cap. 6

frentes empíricas da dissertação (Capítulos 5, 6 e 7) atacam lacunas distintas mas encadeadas: o benchmark gera a evidência que o arcabouço de decisão organiza, e a inversão de custo que o benchmark quantifica é precisamente o problema que a destilação ataca.

Transição. Mapeadas as lacunas e fixado o posicionamento, o Capítulo 4 especifica o instrumento que as ataca: o protocolo experimental comum a toda a parte empírica — 14 modelos, 18 conjuntos, validação cruzada aninhada com *hold-out* intocado, inferência frequentista e bayesiana, medição de custo de ponta a ponta — com as limitações do desenho declaradas antes de qualquer resultado.

4

Metodologia Experimental

Resumo do capítulo. Este capítulo especifica o protocolo experimental que sustenta todos os resultados empíricos da dissertação: 14 modelos de três famílias (gradient boosting, aprendizado profundo e *foundation models*) avaliados em 18 conjuntos de dados públicos do OpenML sob validação cruzada aninhada (5 *folds* externos $\times$ 3 internos), com *hold-out* de 20% separado antes de qualquer seleção e jamais observado pelo *tuning*. O capítulo justifica cada decisão de desenho — orçamentos de otimização de 100/25 *trials*, assimetria *zero-shot* dos *foundation models*, pré-processamento por família, métricas primárias *threshold-free* — e declara o protocolo de inferência estatística, a política para células faltantes (250 de 252 células; duas exclusões estruturais), o protocolo de medição de custo, o contrato de conduta científica e, antes de qualquer resultado, as limitações do próprio desenho.

Material associado. A formulação condensada desta metodologia corresponde à seção *Methodology* do artigo individual AI-1 (`latex/ai1/main.tex` no repositório do projeto). A especificação estatística completa, com o registro da auditoria de corretude de julho de 2026, está em `docs/metodologia-estatistica.md`; os parâmetros exatos do protocolo estão versionados em `configs/experiment.yaml` e `configs/datasets.yaml`.

Este capítulo descreve o desenho experimental comum a toda a parte empírica da dissertação. A Seção 4.1 enuncia os princípios que organizam o protocolo; as Seções 4.2 e 4.3 apresentam os conjuntos de dados e os modelos, com os critérios de seleção e a proveniência de cada implementação; as Seções 4.4 a 4.6 detalham o protocolo de avaliação, o pré-processamento por família e as métricas; a Seção 4.7 declara o protocolo de aplicação dos testes estatísticos — cuja fundamentação foi apresentada no Capítulo 2 — incluindo a política para células faltantes; a Seção 4.8 especifica como custo de treinamento, custo de *tuning* e latência de inferência são medidos, além dos experimentos complementares; as Seções 4.9 e 4.10 documentam a infraestrutura de reprodutibilidade e o contrato de conduta científica; e a Seção 4.11 fecha o capítulo com as limitações do desenho, declaradas *antes* de qualquer resultado. O desenho experimental específico da destilação distribucional (AI-2) — pré-registrado em documento próprio, com hi-

póteses falsificáveis — é apresentado no Capítulo 7; aqui descrevemos apenas a infraestrutura compartilhada da qual ele herda dados, partições e hiperparâmetros.

4.1 Visão geral e princípios de desenho

A metodologia foi construída para responder às três perguntas de pesquisa enunciadas no Capítulo 1: se as famílias modernas de modelos tabulares diferem de forma praticamente relevante sob um protocolo uniforme (QP1); como a vantagem relativa varia com a estrutura do problema (QP2); e que arcabouço de decisão multicritério pode orientar a escolha quando o desempenho empata ou o líder é operacionalmente caro (QP3). Quatro princípios atravessam todas as decisões deste capítulo:

- **Separação estrita entre seleção e medição.** Nenhum dado usado para escolher hiperparâmetros, arquiteturas ou pré-processadores participa da estimativa final de desempenho. Este princípio materializa-se no *hold-out* prévio e na validação cruzada aninhada (Seção 4.4).
- **Paridade de condições entre modelos.** Todos os modelos veem as mesmas partições, as mesmas sementes e orçamentos de otimização equalizados em custo computacional — as assimetrias inevitáveis (regime *zero-shot* dos *foundation models*) são declaradas e justificadas, não escondidas.
- **Unidade de análise correta.** A inferência estatística opera sobre conjuntos de dados, nunca sobre *folds* — *folds* do mesmo conjunto não são independentes, e tratá-los como réplicas inflaria artificialmente o poder dos testes (pseudo-replicação; Seção 4.7).
- **Proveniência rastreável.** Todo número reportado na dissertação origina-se de um artefato versionado (CSV, JSON ou notebook executado) no repositório público do projeto (Seção 4.9).

4.2 Conjuntos de dados

O benchmark usa **18 conjuntos de dados públicos do OpenML** (VANSCHOREN et al., 2014): 10 de classificação binária, 3 de classificação multiclasse e 5 de regressão. A Tabela 4.1 lista os 18 conjuntos com seus identificadores OpenML, tamanhos aproximados e composição de atributos; a fonte canônica é `configs/datasets.yaml`, versionada no repositório.

A seleção obedeceu a quatro critérios, cada um ligado a uma necessidade da investigação:

Tabela 4.1: Os 18 conjuntos de dados OpenML do benchmark (tamanhos aproximados antes do teto; as execuções limitam cada conjunto a 100 mil amostras). Fonte: `configs/datasets.yaml`.

Conjunto	Tarefa	ID OpenML	n	d	Classes	Atributos
adult	binária	1590	49 000	14	2	mistos
amazon_employee	binária	4135	33 000	9	2	categóricos
bank_marketing	binária	1461	45 000	16	2	mistos
cardiovascular_disease	binária	45547	70 000	11	2	mistos
credit_g	binária	31	1 000	20	2	mistos
give_me_some_credit	binária	46929	150 000	10	2	numéricos
higgs	binária	23512	98 000	28	2	numéricos
magictlescope	binária	44125	19 000	10	2	numéricos
phoneme	binária	1489	5 400	5	2	numéricos
telco_customer_churn	binária	42178	7 000	19	2	mistos
covertime	multiclasse	1596	581 000	54	7	numéricos
helena	multiclasse	41169	65 000	27	100	numéricos
jannis	multiclasse	41168	84 000	54	4	numéricos
california_housing	regressão	44090	21 000	8	–	numéricos
kin8nm	regressão	44980	8 192	8	–	numéricos
superconduct	regressão	44064	21 000	81	–	numéricos
wine_quality	regressão	287	6 500	11	–	numéricos
year_prediction	regressão	44027	515 000	90	–	numéricos

- **Cobertura dos três tipos de tarefa.** Boa parte da literatura de benchmark tabular restringe-se à classificação; incluir regressão (5 conjuntos, com `kin8nm` e outros provenientes de suítes curadas como a OpenML-CTR23 (FISCHER; FEURER; BISCHL, 2023)) é condição para que o arcabouço de decisão da QP3 não seja um artefato de um único tipo de tarefa.
- **Três ordens de grandeza em tamanho amostral.** Os conjuntos variam de cerca de mil (`credit_g`) a 581 mil amostras (`covertime`). A QP2 pergunta onde a liderança troca de mãos ao longo do eixo de tamanho; sem variação ampla nesse eixo, a pergunta seria irrespondível por construção.
- **Diversidade de composição de atributos.** Conjuntos puramente numéricos, mistos e um caso extremo predominantemente categórico de alta cardinalidade (`amazon_employee`), porque o tratamento de categóricas é um dos eixos que historicamente separa as famílias (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; MCELFRISH et al., 2023).
- **Desbalanceamento realista.** Razões de desbalanceamento de 1:1 a cerca de 16:1 na classificação, o que condiciona a escolha das métricas primárias (Seção 4.6) e aproxima o benchmark de aplicações de crédito e risco.

A Figura 4.1 situa os 18 conjuntos no plano tamanho $\times$ dimensionalidade, evidenciando a cobertura obtida.




Figura 4.1: **O benchmark cobre três ordens de grandeza em amostras e mais de uma ordem em atributos.** Cada ponto é um conjunto de dados, posicionado pelo número de amostras (eixo vertical, escala logarítmica) e de atributos (eixo horizontal, escala logarítmica), colorido pelo tipo de tarefa (binária, multiclasse, regressão). A dispersão sem aglomeração em um único quadrante é a condição estrutural para a análise condicional da QP2. Fonte: `results/figures/dataset_landscape.pdf`, gerado a partir de `configs/datasets.yaml`.

4.2.0.0.1 Teto de 100 mil amostras. Conjuntos com mais de 100 mil amostras (`covertypes`, `year_prediction`, `give_me_some_credit`) são subamostrados de forma estratificada para 100 mil amostras *antes de qualquer particionamento*. A prática é padrão em benchmarks tabulares por viabilidade computacional (GORISHNIY et al., 2021; MCELFRESH et al., 2023) e, no nosso caso, é também uma delimitação honesta de escopo: com 14 modelos $\times$ 18 conjuntos sob validação cruzada aninhada em uma única GPU (Seção 4.9), o regime estudado é o de dados tabulares de pequeno a médio porte — exatamente o regime em que a disputa entre famílias permanece aberta. A integridade de cada conjunto é registrada por *hash* SHA-256 em cada experimento, o que permite detectar qualquer alteração silenciosa dos dados entre execuções.

4.2.0.0.2 Declaração sobre os dados. Todos os conjuntos são públicos e obtidos pelo OpenML por identificador numérico e versão fixados em configuração; nenhum dado pessoal ou sensível é processado além de sua forma pública. Um erro de rotulagem descoberto durante o estudo — a chave de configuração `diamonds` apontava, desde a origem, para o identificador OpenML

do conjunto `kin8nm` — foi retificado com trilha pública completa, e todo número desta dissertação é posterior à retificação.¹

4.3 Modelos avaliados

O benchmark compara **14 modelos em três famílias**. A Tabela 4.2 lista os modelos com suas referências e a proveniência de cada implementação.

Tabela 4.2: Os 14 modelos do benchmark, por família, com a proveniência de cada implementação. “Própria” indica reimplementação a partir do artigo original, motivada pela ausência de pacote maduro.

Família	Modelo	Referência	Implementação
Gradient boosting	XGBoost	CHEN; GUESTRIN (2016)	biblioteca oficial
	LightGBM	KE et al. (2017)	biblioteca oficial
	CatBoost	PROKHORENKOVA et al. (2018)	biblioteca oficial
Aprendizado profundo	MLP	GORISHNIY et al. (2021)	própria (modificada)
	RealMLP	HOLZMÜLLER; GRINSZTAJN; STEINWART (2024)	pacote oficial
	TabM	GORISHNIY; KOTELNIKOV; BABENKO (2025)	pacote oficial
	TabNet	ARIK; PFISTER (2021)	pacote da comunidade
	FT-Transformer	GORISHNIY et al. (2021)	própria
	SAINT	SOMEPALLI et al. (2021)	própria
	STab	VOSKOU; CHRISTOFOROU; CHATZIS (2024)	própria
	KAN	LIU et al. (2025)	<i>efficient-kan</i>
Foundation models	TabKAN	ESLAMIAN; Afzal Aghaei; CHENG (2025)	própria
	TabPFN v2.5	HOLLMANN et al. (2025); GRINSZTAJN et al. (2025)	pacote oficial
	TabFM	Google Research (2026)	pacote oficial

Três decisões de composição merecem justificativa explícita:

- **Por que estas três famílias.** Gradient boosting é o estado da prática consolidado para dados tabulares; o aprendizado profundo tabular é a família com maior volume de propostas recentes e maior heterogeneidade interna (do MLP regularizado aos modelos de atenção e às redes de Kolmogorov–Arnold); e os *foundation models* são a aposta paradigmática da geração 2025–2026. A comparação entre famílias — e não apenas entre modelos — é o que permite a decomposição de variância da Seção 4.7.
- **Por que declarar a proveniência das implementações.** Cinco modelos (MLP, FT-Transformer, SAINT, STab, TabKAN) usam implementações próprias — os três últimos reimplementados dos artigos originais por ausência de pacote maduro; o KAN

¹O registro canônico da errata está em `docs/errata-diamonds-kin8nm.md`; o episódio é retomado como lição de conduta científica na Seção 4.10 e nas limitações do Capítulo 8.

usa o *backbone efficient-kan* (licença MIT) vendorizado com adaptações documentadas. Isso afeta a interpretação: um desempenho fraco de modelo reimplementado confunde a qualidade do método com a da implementação. Mitigamos o risco com verificações de sanidade contra resultados publicados — por exemplo, a reimplementação do TabKAN atinge ROC-AUC de 0,914–0,915 no conjunto *adult*, compatível com o valor de aproximadamente 0,90 reportado pelos autores (ESLAMIAN; Afzal Aghaei; CHENG, 2025) — e com a declaração de todo desvio de protocolo (por exemplo, o TabKAN é treinado com AdamW e mini-lotes, em lugar do L-BFGS *full-batch* original, por uniformidade com os demais modelos profundos).

- **Por que os *foundation models* entram *zero-shot*.** TabPFN v2.5 e TabFM operam sem qualquer ajuste de hiperparâmetros: o “treinamento” consiste em condicionar o modelo pré-treinado ao conjunto de treino via aprendizado em contexto (Capítulo 2). Essa assimetria é deliberada — o regime *zero-shot* é precisamente a alegação paradigmática sob teste, e seus parâmetros de inferência (conjunto de 8 membros de *ensemble*; teto de contexto de 50 mil amostras, com política de subamostragem idêntica entre os dois modelos para comparabilidade) são políticas fixas das bibliotecas, não quantidades ajustadas aos nossos dados.

Ambos os *foundation models* têm limites arquiteturais declarados, dos quais decorre a única lacuna da matriz experimental: o conjunto *helen*a (100 classes) excede o limite de classes de ambos. As duas células TabPFN×*helen*a e TabFM×*helen*a são, portanto, *exclusões estruturais* — impossibilidades arquiteturais, não falhas de execução — e a matriz final tem 250 das 252 células possíveis. A política estatística para essas células é definida na Seção 4.7.

4.4 Protocolo experimental

A Figura 4.2 resume o protocolo de avaliação, cujos componentes são justificados a seguir.

- ***Hold-out final intocado* — por quê.** 20% de cada conjunto é separado *antes* de qualquer validação cruzada (estratificado em classificação; semente fixa 42). Todo resultado final reportado provém exclusivamente desse conjunto. A alternativa comum — reportar a média dos *folds* externos — é defensável, mas o *hold-out* prévio oferece uma garantia mais forte: mesmo um erro sutil de vazamento no laço de seleção não contamina o número final, porque nenhum estágio de seleção jamais observa esses dados.
- **Validação cruzada aninhada — por quê.** O laço externo (5 *folds*) mede o modelo; o laço interno (3 *folds*) seleciona hiperparâmetros. Selecionar e medir nos mesmos *folds* produz estimativas otimistas — o viés clássico de seleção; o aninhamento




Figura 4.2: **Separação estrita entre seleção e medição.** O *hold-out* de 20% é separado antes de qualquer validação cruzada e só é tocado uma única vez, na avaliação final; a seleção de hiperparâmetros ocorre exclusivamente no laço interno da validação cruzada aninhada, sobre a partição de desenvolvimento. Caixas sombreadas marcam os dados e a etapa que nenhum estágio de seleção observa.

elimina esse viés por construção, ao custo computacional de multiplicar o número de ajustes. Pagamos esse custo deliberadamente: o benchmark prioriza profundidade de protocolo sobre largura de N (discussão na Seção 4.11).

- **Estratificação em todas as partições de classificação.** *Hold-out*, *folds* externos, *folds* internos e a divisão 90/10 treino/validação do ajuste final; em regressão, K-Fold com embaralhamento. Sob desbalanceamento de até 16:1, partições não estratificadas podem deixar *folds* quase sem a classe minoritária.
- **Orçamentos de otimização 100/25 — por quê a assimetria.** A busca usa Optuna com amostrador TPE e MedianPruner (AKIBA et al., 2019): 100 *trials* para gradient boosting e 25 para aprendizado profundo. A assimetria nominal *equaliza o custo*: um *trial* de aprendizado profundo custa cerca de $4\times$ um *trial* de GBDT, e 25 *trials* de TPE capturam a maior parte do *landscape* de otimização (AKIBA et al., 2019). Orçamentos iguais em número de *trials* dariam aos GBDTs menos tempo de busca por unidade de custo — a paridade relevante é a de recursos, não a de contagem. Os espaços de busca por modelo estão no Apêndice B. A direção de otimização segue a métrica primária de cada tarefa (maximização de ROC-AUC; minimização de *log-loss* e RMSE), verificada em auditoria de código (Seção 4.7).
- **Regime de treinamento dos modelos profundos.** Máximo de 200 épocas com parada antecipada (paciência 20, monitorando a perda de validação), lote de 256,

otimizador AdamW e restauração do melhor estado — um regime único para toda a família, que evita que diferenças de agenda de treinamento se confundam com diferenças de arquitetura.

- **Isolamento e robustez operacional.** Cada experimento executa em subprocesso isolado; erros de memória disparam redução automática do lote e, no limite, poda do *trial* — uma configuração excessivamente custosa não derruba a fila de execução. O executor é resumível: resultados existentes são detectados e pulados, o que torna as longas execuções tolerantes a interrupções.
- **Sementes.** Semente global 42; cada *trial* recebe semente derivada determinística, de modo que qualquer célula da matriz é reproduzível isoladamente.

4.5 Pré-processamento por família

Cada família recebe a entrada no formato que sua literatura prescreve — impor um pré-processamento único seria penalizar artificialmente alguma delas. O ajuste de todo pré-processador ocorre *exclusivamente no treino de cada fold*, nunca na validação ou no teste, eliminando essa via clássica de vazamento:

- **Gradient boosting:** codificação ordinal de categóricas e imputação por mediana; o CatBoost recebe os índices das colunas categóricas e aplica seu tratamento nativo (PROKHORENKOVA et al., 2018).
- **Aprendizado profundo:** padronização das numéricas e *one-hot* das categóricas com teto de 50 categorias por coluna. O teto é necessário para evitar explosão dimensional: sem ele, o conjunto `amazon_employee` atingiria cerca de 6 900 colunas, excedendo a memória da GPU nos modelos de atenção.
- **Foundation models:** codificação ordinal; a normalização interna é dos próprios modelos, por desenho.

Duas adaptações específicas do KAN são registradas como decisões metodológicas: normalização de camada antes de cada camada KAN e faixa de *grid* $[-2, 2]$. Ambas decorrem de uma incompatibilidade concreta: B-splines só são definidas dentro do *grid*, e entradas padronizadas caem majoritariamente fora da faixa original $[-1, 1]$ proposta em LIU et al. (2025).

4.6 Métricas por tipo de tarefa

A regra geral: a métrica primária de cada tarefa é *threshold-free* e sensível à qualidade probabilística do modelo; as secundárias cobrem os ângulos que a primária não vê. A Tabela 4.3 resume o esquema.

Tabela 4.3: Métricas por tipo de tarefa. Setas indicam a direção de otimização. A acurácia é reportada por convenção, mas nunca fundamenta conclusões.

Tarefa	Primária	Secundárias	Justificativa da primária
Binária (10)	ROC-AUC ($\uparrow$)	KS, <i>log-loss</i> , F1, acurácia	independente de limiar e de prevalência; robusta ao desbalanceamento (até 16:1)
Multiclasse (3)	<i>log-loss</i> ($\downarrow$)	F1-macro, F1-ponderado, AUC-OvR, acurácia	única <i>proper scoring rule</i> que escala a K classes sem agregação arbitrária
Regressão (5)	RMSE ($\downarrow$)	MAE, R^2	na unidade do alvo; penalização quadrática de erros grandes

Três observações completam o quadro. Primeiro, a acurácia é enganosa sob desbalanceamento — um classificador trivial “acerta” 94% em um conjunto 16:1 — e descarta toda a informação probabilística, que é precisamente um dos eixos que distinguem as famílias; por isso é reportada, mas nunca usada em conclusões. Segundo, o KS (estatística de Kolmogorov–Smirnov sobre os escores) conecta o benchmark à prática de crédito e risco, onde é a métrica padrão da indústria; e a comparação $\text{RMSE} \times \text{MAE}$ expõe quando o erro é dominado por caudas. Terceiro, comparações de RMSE *entre* conjuntos são evitadas por não serem comensuráveis — o R^2 cumpre o papel de leitura livre de escala.

4.7 Protocolo de inferência estatística

Os testes empregados — Friedman, Nemenyi, Wilcoxon, a análise bayesiana com ROPE — foram apresentados em profundidade no Capítulo 2; esta seção declara *o protocolo de aplicação*: quais testes, em que ordem, com que correções e com que análises de sensibilidade. A cadeia segue a prática canônica para comparação de múltiplos classificadores em múltiplos conjuntos (DEMŠAR, 2006; BENAVALI et al., 2017), acrescida de uma camada bayesiana e de uma decomposição de variância. Toda a cadeia foi submetida a auditoria de corretude (julho de 2026), que incluiu a recomputação manual da estatística de Friedman (idêntica à da implementação: $\chi^2 = 31,309$ nos dados binários) e o cotejo linha a linha da implementação bayesiana com a formulação de referência; o registro completo está em `docs/metodologia-estatistica.md`.

1. **Unidade de análise: o conjunto de dados.** Os testes operam sobre $N = 10$ (binária), $N = 3$ (multiclasse) e $N = 5$ (regressão) conjuntos — nunca sobre *folds*, que não são independentes entre si (pseudo-replicação). Os *folds* alimentam apenas a variância intra-conjunto (bandas de incerteza e análise de robustez).
2. **Teste omnibus de Friedman** sobre os *ranks* por conjunto, que não assume normalidade nem comensurabilidade das métricas entre conjuntos. Reportamos o qui-quadrado clássico e a correção de Iman–Davenport, menos conservadora para N pequeno.

3. **Post-hoc de Nemenyi** com diagramas de diferença crítica, $CD = q_\alpha \sqrt{k(k+1)/6N}$ (DEMŠAR, 2006); a lógica de agrupamento dos diagramas foi verificada formalmente na auditoria (grupos são intervalos contíguos na ordem de *ranks*, com todo par interno distando menos que o CD).
4. **Wilcoxon signed-rank par a par com correção de Holm** (método exato para $N \leq 25$ sem empates), complementando o Nemenyi com as *magnitudes* das diferenças. **Limitação declarada:** com $N = 5$ conjuntos de regressão, o menor p-valor bilateral atingível é $2 \cdot (1/2^5) = 0,0625$ — rejeição a $\alpha = 0,05$ é matematicamente impossível, e após Holm todos os p-valores saturam em 1,0 (verificado empiricamente). Conclusões de regressão apoiam-se, portanto, em *ranks*, tamanhos de efeito e análise bayesiana.
5. **Tamanho de efeito:** d de Cohen na variante pareada (d_z), a forma correta para o desenho de medidas repetidas (os mesmos conjuntos avaliam todos os modelos).
6. **Intervalos de confiança:** *bootstrap* percentil com 10 000 reamostragens e semente fixa — coerente com o restante do arcabouço não paramétrico.
7. **Análise bayesiana com ROPE** (*signed-rank* de BENAVALI et al., 2017): o arcabouço frequentista não autoriza afirmar equivalência (não rejeição $\neq$ igualdade); a posterior bayesiana com região de equivalência prática autoriza. O ROPE primário é de $\pm 0,01$ de AUC — um ponto percentual como limiar de irrelevância prática, alinhado à granularidade típica de decisões de modelo na indústria — *com análise de sensibilidade pré-definida* em $\{0,005; 0,01; 0,02\}$, reportada integralmente no Capítulo 5.
8. **Decomposição de variância (η^2):** parcela da variância dos *ranks* explicada pela família, via razão de somas de quadrados entre-famílias e total. Uma ressalva de interpretação é declarada de antemão: no recorte da geração até 2025 (Ato I do Capítulo 5), as famílias são desbalanceadas — 3 GBDTs, 7 de aprendizado profundo e 1 *foundation model* — e, com famílias desbalanceadas, a parcela entre-famílias é mecanicamente conservadora.

4.7.0.0.1 Política para células faltantes. As duas exclusões estruturais (*foundation models* × *helen*; Seção 4.3) exigem uma política explícita, no espírito da prática de benchmarks abertos de declarar falhas em vez de omiti-las:

- **Exclusões são declaradas, nunca imputadas.** Imputar o pior *rank* puniria os *foundation models* por uma limitação arquitetural conhecida; imputar a média fabricaria dados. A célula inexistente permanece inexistente e visível.

- **Análises que exigem matriz completa** (Friedman, Nemenyi, diagramas CD na multiclasse) usam apenas os modelos com cobertura total *ou* excluem o *helen* — a escolha é explicitada caso a caso na análise, e a seção multiclasse é tratada como descritiva ($N = 3$) de qualquer forma.
- **A contabilidade é pública:** 250 das 252 células possíveis estão preenchidas, e os *ranks* multiclasse dos *foundation models* são médias sobre 2 conjuntos — fato repetido em toda tabela afetada.

4.8 Eixos de custo e experimentos complementares

A QP3 exige medir mais que desempenho preditivo. Três eixos de custo e dois experimentos complementares completam o protocolo:

- **Custo de treinamento e de *tuning*.** Tempo de parede registrado por experimento, decomposto em busca de hiperparâmetros e ajuste final, nas condições de hardware declaradas na Seção 4.9.
- **Latência de inferência — protocolo com dispositivo e regime declarados.** Medida em microssegundos por linha ($\mu\text{s}/\text{linha}$) sobre o *hold-out* completo do conjunto *adult*: mediana de 5 passadas após aquecimento, com sincronização CUDA, sob protocolo de lote idêntico para os 14 modelos. Cada modelo executa em seu dispositivo natural — GBDTs em CPU; modelos profundos e *foundation models* em GPU. As razões resultantes descrevem, portanto, o *regime amortizado de serviço em lote* em uma máquina declarada, e não a latência *online* de linha única, cujas diferenças são menores — a distinção é repetida sempre que o eixo de latência fundamenta uma conclusão.
- **Curvas de aprendizado (QP2).** Seis modelos representativos re-treinados em fatias crescentes da partição de desenvolvimento (de 500 amostras ao total disponível; 3 sementes; 5 conjuntos), com os hiperparâmetros fixados nos valores selecionados para o conjunto completo e o mesmo *hold-out* do benchmark — isolando o efeito do tamanho amostral a capacidade fixa. O re-uso de hiperparâmetros é declarado como limitação: re-otimizar por tamanho deslocaria níveis absolutos, não a direção dos cruzamentos.
- **Validação do arcabouço de decisão (LODO).** O recomendador meta-atributos→família é avaliado por *leave-one-dataset-out*, com métrica de *regret* normalizado contra políticas fixas — o desenho impede que uma árvore descritiva seja lida como preditor validado. O protocolo e os resultados estão no Capítulo 6.

- **Destilação distribucional (QP3/contribuição).** Desenho pré-registrado em documento próprio (`docs/desenho-experimental-destilacao.md`), com hipóteses falsificáveis, controles de capacidade (hiperparâmetros dos alunos fixados nos valores otimizados do benchmark), rotulagem *out-of-fold* e métricas distribucionais. O desenho completo é apresentado no Capítulo 7.

4.9 Infraestrutura computacional e reprodutibilidade

Todos os experimentos executam em uma única máquina: GPU NVIDIA RTX 5080 (16 GB de VRAM) e 32 GB de RAM. O TabFM opera com *backend* PyTorch em precisão bf16, com pesos fixados na versão v1.0.1 (Google Research, 2026); o hardware é declarado porque delimita o regime estudado (o teto de 100 mil amostras e o teto de 50 categorias no *one-hot* decorrem, em parte, dele) e porque medições de custo só são interpretáveis com a máquina explícita.

A reprodutibilidade apoia-se em seis mecanismos:

- **Sementes fixas** em todos os níveis (global 42; derivadas determinísticas por *trial*), com reprodutibilidade bit a bit onde o hardware permite.
- **Hash SHA-256 dos dados** registrado por experimento, contra alterações silenciosas dos conjuntos.
- **Configurações versionadas** (`configs/*.yaml`): identificadores e versões OpenML, orçamentos, partições e métricas são artefatos de configuração, não constantes no código.
- **Dependências com versões fixadas**, incluindo o commit exato de pacotes de pesquisa instalados diretamente de repositório.
- **Resultados brutos, agregados e notebooks executados versionados** em repositório público, de modo que cada número do texto é rastreável a um artefato.
- **Correções por retificação:** erros descobertos após o registro são corrigidos por commits de retificação que preservam o histórico — nunca por reescrita (Seção 4.10).

4.10 Contrato de conduta científica

O trabalho adota um contrato de conduta explícito, firmado no documento-mestre do programa de pesquisa antes da fase experimental e vinculante para todas as atividades:

- **Nenhuma afirmação de novidade sem verificação online datada.** Toda alegação de prioridade é precedida de busca registrada com data — precedente concreto: uma

checagem de julho de 2026 evitou reivindicar como inédito um resultado já publicado por trabalho contemporâneo.

- **Pré-registro de hipóteses e critérios de decisão** antes dos experimentos confirmatórios (o desenho da destilação, Capítulo 7, é o caso central); mudanças de desenho viram adendos datados com motivo, nunca substituições silenciosas.
- **Resultados negativos são reportados** com a mesma proeminência dos positivos — o Capítulo 6 abre com um resultado negativo.
- **Distinção explícita entre *smoke test*, piloto e resultado:** execuções qualitativas e pilotos decisórios não entram no texto como evidência.
- **Todo número citado tem origem rastreável** em artefato versionado (CSV, JSON ou notebook executado).
- **Erratas públicas e retificação sem reescrita.** O caso diamonds/kin8nm (Seção 4.2) seguiu esse rito: registro canônico da errata, commit de retificação preservando o histórico e re-derivação de todos os números afetados; o episódio é discutido entre as limitações no Capítulo 8.

Esse contrato não é ornamento: ele determinou decisões concretas de escopo e de texto ao longo da dissertação, e os capítulos de resultados o referenciam sempre que uma decisão editorial (um recorte de modelos, uma exclusão, uma correção) precisa de lastro.

4.11 Limitações do desenho experimental

Seguindo a boa prática de declarar as fragilidades do desenho *antes* de apresentar qualquer resultado, esta seção enumera as limitações conhecidas e as decisões tomadas diante delas.

- **Poder estatístico limitado por N pequeno.** Com 10/3/5 conjuntos por tarefa, o poder dos testes é baixo: o piso combinatório do Wilcoxon em regressão ($p \geq 0,0625$) e o caráter descritivo da multiclasse ($N = 3$) já foram declarados. A mitigação é tripla: não afirmar vencedor único, sustentar *equivalências* pela análise bayesiana com ROPE e explicitar o limite sempre que ele morde. A escolha de desenho subjacente é deliberada: profundidade de protocolo (validação cruzada aninhada honesta, *hold-out* intocado) sobre largura de N .
- **Potencial contaminação do pré-treino dos *foundation models*.** Os 18 conjuntos são públicos e amplamente usados — e *foundation models* são pré-treinados antes e fora do nosso protocolo, de modo que o *hold-out* intocado protege contra o nosso vazamento, não contra o deles. O risco é heterogêneo entre os dois modelos: o TabPFN é pré-treinado exclusivamente em dados sintéticos amostrados de um

prior (HOLLMANN et al., 2025), o que exclui a memorização direta dos conjuntos, mas não o ajuste iterativo do *prior* e das políticas de inferência ao desempenho em benchmarks públicos ao longo das versões — uma forma branda de sobreajuste da comunidade ao OpenML da qual nenhum benchmark público escapa. Para o TabFM, o relatório técnico declara pré-treino *exclusivamente sintético* — tabelas amostradas de modelos causais estruturais com dependências funcionais aleatorizadas (KONG et al., 2026) —, o que, como no TabPFN, exclui por construção a contaminação direta por conjuntos do OpenML (verificação na fonte primária em 05/10/2026). Permanece o risco mais fraco e não endereçável: *priors* desenhados por equipes que conhecem os benchmarks públicos. Tratamos esse risco residual com três cuidados: ele é declarado aqui e retomado na interpretação dos resultados; as conclusões sobre *foundation models* são enunciadas no nível de regime (consistência entre conjuntos), não de célula individual; e o eixo de custo — imune a contaminação — participa de toda conclusão prática.

- **Versão fixada e não revisada do TabFM.** O TabFM é avaliado na versão v1.0.1 fixada por commit (Google Research, 2026); seu relatório técnico oficial (KONG et al., 2026) apareceu apenas no fim de setembro de 2026 e não passou por revisão por pares. Os resultados referem-se a essa versão, e isso é declarado onde quer que o modelo apareça.
- **Exclusão dupla do *helen*.** O limite arquitetural de classes de ambos os *foundation models* faz com que seus *ranks* multiclasse sejam médias sobre 2 conjuntos (Seção 4.7). A alternativa — remover o *helen* do benchmark — esconderia precisamente o tipo de restrição arquitetural que um estudo de decisão prática deve expor.
- **Latência medida em um único conjunto e um único regime.** O protocolo de latência (Seção 4.8) usa o *adult* e o regime amortizado em lote, com cada modelo em seu dispositivo natural. Os números não se transferem para serviço *online* de linha única nem para outro hardware; o que se transfere — e é o que as conclusões usam — são as ordens de grandeza entre famílias.
- **Curvas de aprendizado com hiperparâmetros fixos.** O re-uso dos hiperparâmetros do conjunto completo em todas as fatias isola o efeito do tamanho a capacidade fixa, mas pode desfavorecer modelos cuja configuração ótima varia fortemente com n ; a limitação é declarada junto aos resultados.
- **Validade externa delimitada.** Dezoito conjuntos OpenML não esgotam o espaço de problemas tabulares; o teto de 100 mil amostras e a GPU única de 16 GB delimitam o regime estudado a dados de pequeno e médio porte. Conclusões são

enunciadas dentro desses limites — e o Capítulo 7 estende a validação de regressão a conjuntos adicionais da suíte OpenML-CTR23 (FISCHER; FEURER; BISCHL, 2023) precisamente para testar a sensibilidade a essa delimitação.

- **Validade de construto.** Métricas primárias *threshold-free* e um arcabouço multicritério explícito reduzem o risco de otimizar um *proxy* inadequado, mas qualquer métrica escalar comprime o que um operador real pondera; o arcabouço do Capítulo 6 trata custo e desempenho como eixos separados em vez de agregá-los prematuramente.

Transição. Com o protocolo fixado — dados, modelos, partições, métricas, testes e limitações declaradas —, o Capítulo 5 executa-o: 250 células experimentais organizadas em quatro atos, do empate estatístico da geração até 2025 à quebra desse empate pela geração 2026, passando pelos eixos de custo e pelas reversões condicionais que motivam o arcabouço de decisão do Capítulo 6.

5

O Benchmark Multicritério

Resumo do capítulo. Este capítulo apresenta os resultados do benchmark de 14 modelos tabulares sobre 18 conjuntos de dados do OpenML (250 das 252 células possíveis; duas exclusões estruturais), executado sob o protocolo único do Capítulo 4. A leitura tem dois movimentos. Primeiro, restrito ao núcleo de 11 modelos do estudo (os modelos anteriores à extensão de 2026 do benchmark), o topo da acurácia é um empate estatístico — 8 dos 10 modelos não-líderes são praticamente equivalentes ao líder sob uma região de equivalência prática (ROPE) de $\pm 0,01$ de AUC — e 80% da variância de rank é intrafamília ($\eta^2 = 0,20$): o modelo específico importa mais que a família, e a decisão migra para custo, latência, robustez e estrutura da tarefa. Segundo, a geração 2026 quebra o empate: o TabFM, *zero-shot*, lidera o rank médio nas três tarefas e é o melhor modelo em 13 dos 18 conjuntos — ao custo de quatro a cinco ordens de magnitude em latência de inferência (43.262 vs. 0,33 μ s/linha no *adult*). Como resultados complementares, o capítulo registra o teste independente desfavorável da família Kolmogorov–Arnold (KAN e TabKAN no último terço nas três tarefas) e as reversões condicionais que alimentam o arcabouço de decisão do Capítulo 6.

Material associado. Este capítulo corresponde ao primeiro trabalho individual do programa (AI-1), cuja versão em formato de artigo está em `latex/ai1/` no repositório do estudo. Todo número citado aqui rastreia a um artefato versionado; os caminhos estão registrados em comentários na fonte $\text{\LaTeX}$ do artigo e na tabela mestra (`notebooks/TABELA_RESULTADOS.m`).

O capítulo aplica os instrumentos estatísticos apresentados na Fundamentação (Capítulo 2) às estimativas produzidas pelo protocolo experimental do Capítulo 4, e organiza a evidência em quatro atos. A Seção 5.1 delimita a cobertura do benchmark e o roteiro da exposição. O Ato I (Seção 5.2) estabelece o empate estatístico do núcleo de 11 modelos e dissectiona sua anatomia; o Ato II (Seção 5.3) mostra que os modelos empatados em acurácia diferem em ordens de magnitude nos eixos de custo; o Ato III (Seção 5.4) mapeia as reversões condicionais — quando a estrutura do problema muda o vencedor — e o eixo do tamanho amostral; o Ato IV (Seção 5.5) registra a quebra do empate pela geração 2026 e o resultado negativo das redes

de Kolmogorov–Arnold. A Seção 5.6 encadeia os três fatos que motivam os dois capítulos seguintes.

5.1 Cobertura e organização da evidência

O benchmark completa **250 das 252 células** possíveis ($14 \text{ modelos} \times 18 \text{ conjuntos de dados}$). As duas ausências são exclusões estruturais documentadas, não falhas de execução: o conjunto *helen*, com 100 classes, excede o limite arquitetural de classes dos dois *foundation models* (TabPFN e TabFM), que portanto não produzem predição nele. Essa distinção importa para a leitura estatística: células ausentes por limite arquitetural são informação sobre o modelo — um critério de decisão em si, retomado no Capítulo 6 — e não dados faltantes a imputar. Registre-se também que o episódio de retificação de rótulo descrito no Capítulo 4 (o conjunto historicamente chamado “diamonds” é, na verdade, o *kin8nm*) precede todos os números reportados neste capítulo: cada valor aqui citado é posterior à errata.

Antes dos resultados, convém visualizar o espaço amostral sobre o qual eles se apoiam. A Figura 5.1 posiciona os 18 conjuntos no plano amostras $\times$ atributos.

A figura mostra que a amostra de conjuntos não se concentra em um único regime: há conjuntos pequenos e grandes, estreitos e largos, nas três tarefas — condição necessária para que as análises condicionais do Ato III (desbalanceamento, cardinalidade categórica, tamanho) tenham variação a explorar. A ressalva simétrica também fica visível: com 10 conjuntos binários, 3 multiclasse e 5 de regressão, o poder estatístico por tarefa é limitado, e o texto declara essa limitação em cada ponto em que ela é vinculante.

5.1.0.0.1 O núcleo de 11 modelos e a extensão de 2026. Ao longo do capítulo, duas grades de comparação coexistem e precisam ser distinguidas desde já. O *núcleo de 11 modelos* do estudo reúne os modelos anteriores à extensão de 2026 do benchmark: os três GBDTs (XGBoost, LightGBM, CatBoost), sete modelos de aprendizado profundo (MLP, FT-Transformer, SAINT, TabNet, STab, RealMLP, TabM) e um foundation model (TabPFN). A *grade completa de 14* acrescenta os três modelos incorporados na extensão: o foundation model TabFM (Google Research, 2026; KONG et al., 2026) e as duas redes de Kolmogorov–Arnold (KAN (LIU et al., 2025) e TabKAN (ESLAMIAN; Afzal Aghaei; CHENG, 2025)). Os Atos I a III leem o núcleo de 11 — é sobre ele que a máxima “*boosting* sempre vence” (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; MCELFRESH et al., 2023) foi formulada e é sobre ele que o empate se estabelece; o Ato IV lê a grade completa e mostra o que a extensão muda.

5.1.0.0.2 O protocolo em uma frase (e suas assimetrias declaradas). Para a leitura autocontida deste capítulo, vale recapitular o essencial do Capítulo 4: validação cruzada aninhada ($5 \text{ folds externos} \times 3 \text{ internos}$, com hiperparâmetros selecionados apenas nos internos), ajuste bayesiano via Optuna/TPE (AKIBA et al., 2019) com orçamento equalizado por família (100




Figura 5.1: Os 18 conjuntos cobrem quase três ordens de magnitude em tamanho amostral e uma ordem em dimensionalidade, nas três tarefas. Cada ponto é um conjunto de dados, posicionado pelo número de amostras (eixo vertical, escala logarítmica) e de atributos (eixo horizontal, escala logarítmica), com a cor indicando a tarefa (binária, multiclasse, regressão). Os extremos vão de `credit_g` (10^3 amostras) a `covertypes` e `year_prediction` (centenas de milhares, limitadas a 100 mil linhas por execução, conforme o Capítulo 4). Fonte: `results/figures/dataset_landscape.pdf`.

tentativas para GBDTs, 25 para DL), hold-out fixo de 20% (semente 42) que nenhuma etapa de seleção jamais observa, e pré-processamento por família (one-hot para atenção, ordinal para árvores, embeddings onde o modelo os define). Duas assimetrias do desenho são declaradas porque afetam a leitura dos resultados: os orçamentos de 100/25 tentativas equalizam o custo de relógio do ajuste (uma tentativa de DL custa aproximadamente $4\times$ uma de GBDT), e os foundation models entram *zero-shot* — sem ajuste algum — porque essa entrada é a própria alegação de paradigma sob teste; suas configurações de inferência (ensemble de 8 membros, teto de contexto de 50 mil linhas) são políticas fixas de biblioteca, não quantidades ajustadas aos nossos dados.

5.2 Ato I — o empate estatístico do núcleo de 11 modelos

5.2.0.0.1 O teste global rejeita a igualdade; o *post-hoc* não separa o topo. Restrita ao núcleo de 11 modelos, a classificação binária ($N=10$ conjuntos) exibe um topo estatisticamente indistinguível. O teste omnibus rejeita a igualdade global de ranks (Friedman $\chi^2 = 31,3$, $p = 5,2 \times 10^{-4}$; correção de Iman–Davenport $F = 4,1$, $p = 1,1 \times 10^{-4}$) — há, portanto, diferenças reais em algum lugar da grade — mas o post-hoc de Nemenyi (DEMŠAR, 2006) não separa o pelotão superior: os modelos do topo caem dentro de uma mesma distância crítica. A Figura 5.2 apresenta o diagrama de distância crítica, o instrumento visual canônico dessa análise, aqui exibido já sobre a grade completa de 14 modelos para evitar duplicação de figura; as estatísticas do Ato I são computadas sobre a restrição aos 11, cuja ordem relativa o diagrama preserva.

A interpretação exige a ressalva imediata: um post-hoc que não separa não é, por si só, evidência de equivalência — com k grande e N pequeno, a distância crítica é larga por construção, e “não separável” pode significar apenas “sem poder para separar”. É exatamente por isso que o protocolo pré-registrou instrumentos mais finos, apresentados no Capítulo 2 e aplicados a seguir.

5.2.0.0.2 A leitura bayesiana: equivalência prática, não ausência de poder. O teste bayesiano *signed-rank* com região de equivalência prática (ROPE) (BENAVOLI et al., 2017) responde à pergunta que o frequentista não alcança: qual a probabilidade de a diferença entre dois modelos ser *praticamente irrelevante*? Com ROPE de $\pm 0,01$ de AUC, o teste declara **8 dos 10** modelos não-líderes praticamente equivalentes ao líder de rank do núcleo (TabPFN). A análise de sensibilidade do limiar — pré-registrada precisamente para evitar que a conclusão dependa de uma escolha arbitrária — mostra a progressão $0,005/0,01/0,02 \rightarrow 2/8/10$ equivalentes: a conclusão de empate vale na margem de um ponto percentual de AUC. Lendo massa posterior acima de 0,5 como “mais provavelmente equivalente que não”, o XGBoost ($P(\text{equiv}) = 0,65$) supera essa barra mesmo no limiar estrito de 0,005, com o CatBoost no limite (0,54). O empate do topo, portanto, não é um artefato de baixo poder: é equivalência prática positivamente aferida.




Figura 5.2: **O post-hoc não separa o pelotão superior: as barras horizontais conectam grupos estatisticamente inseparáveis, e elas são largas.** Diagrama de distância crítica (Nemenyi) para a classificação binária, todos os 14 modelos ($N=10$ conjuntos, $CD = 6,27$). O eixo é o rank médio (menor é melhor); modelos a uma distância menor que a barra CD não são estatisticamente separáveis, e cada barra horizontal na parte inferior conecta um grupo inseparável — a largura dessas barras é a forma visual da cautela sobre o CD largo discutida na Seção 5.5. As estatísticas do Ato I no texto restringem-se ao núcleo de 11 modelos. Fonte: latex/ai1/figures/cd_diagram_binary.pdf.

Achado 1. *No núcleo de 11 modelos, o topo da classificação binária é um empate estatístico: 8 dos 10 modelos não-líderes são praticamente equivalentes ao líder sob ROPE de $\pm 0,01$ de AUC, e a conclusão sobrevive à variação do limiar.* O omnibus rejeita a igualdade global, mas o post-hoc não separa o pelotão superior e o instrumento bayesiano declara equivalência prática — a máxima “boosting sempre vence” não encontra, nessa geração, margem de acurácia que a sustente.

5.2.0.0.3 O escopo do empate: onde há poder para afirmá-lo. Uma delimitação honesta antes de prosseguir: o empate é estabelecido na classificação binária, a única tarefa com N suficiente ($N=10$) para que os instrumentos operem com poder útil. Na regressão, $N=5$ impõe um piso combinatório ao p-valor do teste de Wilcoxon pareado (0,0625 — nenhuma comparação pode cruzar o limiar convencional de 5% ali, por aritmética, não por ausência de efeito); na multiclasse, $N=3$ reduz qualquer análise ao plano descritivo. Essas limitações são declaradas em cada seção em que se tornam vinculantes, e nenhum achado numerado deste capítulo depende de significância em tarefa sem poder para aferi-la.

5.2.0.0.4 A anatomia do empate: a família é uma abstração fraca. Se o topo empata, resta perguntar o que, afinal, explica a variação de desempenho que existe. A decomposição de variância de ranks por família responde: $\eta^2 = 0,20$ — apenas 20% da variância de rank é explicada pelo pertencimento à família (GBDT, DL, foundation model), e **80% é intrafamília**. “GBDT vs. DL”, o eixo em torno do qual a literatura organizou a década, é uma abstração fraca para esses dados: o modelo específico importa mais que a família a que pertence. Uma ressalva de leitura acompanha o número: com as famílias desbalanceadas do núcleo (3 GBDTs, 7 DL, 1 foundation model), essa partição é mecanicamente conservadora — ainda assim, a ordem de grandeza da razão intra/entre-famílias sustenta a conclusão qualitativa.

Achado 2. *Oitenta por cento da variância de rank é intrafamília ($\eta^2 = 0,20$): escolher bem o modelo dentro da família importa mais do que escolher a família.* Esse achado reorienta a pergunta prática de “qual família?” para “qual modelo, sob quais restrições?” — a semente do arcabouço do Capítulo 6.

5.2.0.0.5 O que o agregado esconde: a visão por conjunto. O diagrama de distância crítica e o η^2 operam sobre ranks agregados; nenhum dos dois mostra as magnitudes absolutas nem onde, conjunto a conjunto, as diferenças moram. A Figura 5.3 complementa essa lacuna com o mapa de calor da classificação.

A leitura por conjunto confirma a do agregado — margens pequenas no topo das binárias — e adiciona o que o agregado não mostra: as duas células estruturalmente vazias ficam visíveis, e os poucos conjuntos em que um modelo abre vantagem nítida (como o CatBoost em `amazon_employee`, de alta cardinalidade categórica) antecipam as reversões condicionais




Figura 5.3: **As margens absolutas no topo são pequenas — em vários conjuntos binários, a diferença entre o melhor e a mediana dos modelos está na segunda casa decimal de AUC.** Métrica primária por modelo (colunas) e conjunto (linhas): ROC-AUC nas binárias (maior é melhor) e log-loss nas multiclasse (menor é melhor) — as duas métricas convivem na mesma grade, de modo que a comparação válida é dentro de cada linha, nunca entre linhas. As células vazias na linha *helen* são as duas exclusões estruturais (TabPFN e TabFM, 100 classes acima do limite arquitetural). Fonte: `results/figures/heatmap_classification.pdf`.

do Ato III. A ressalva permanece: valores de hold-out em uma única partição fixa não carregam, sozinhos, significância — eles ilustram; a inferência vem dos testes pareados sobre os folds.

5.2.0.0.6 O único sinal robusto do desempenho bruto está no fundo. Enquanto o topo empata, o fundo não: o TabNet (ARIK; PFISTER, 2021) é consistentemente o pior modelo da geração do núcleo, com ranks médios de 11,8 (binária), 11,7 (multiclasse) e 11,4 (regressão) na grade completa. É o único veredito de desempenho bruto que o benchmark autoriza sem qualificação dentro do núcleo — e um lembrete de que arquiteturas celebradas na literatura podem não sobreviver a um protocolo uniforme com orçamento de ajuste equalizado.

5.3 Ato II — os eixos de custo

Se a acurácia empata, a decisão entre os modelos do topo precisa de outros eixos — e é neles que os modelos diferem radicalmente. Esta seção percorre os três eixos de custo medidos pelo protocolo (tempo de treino, custo de ajuste de hiperparâmetros e latência de inferência) e os cruza com o desempenho na fronteira de Pareto.

5.3.0.0.1 Treino: duas ordens e meia de magnitude. O tempo de treino mediano varia cerca de $300\times$ dentro da grade: LightGBM e XGBoost ajustam o modelo final em $\sim 0,7$ s,

enquanto SAINT e STab consomem ~ 200 s por ajuste — e a diferença se multiplica pelo número de tentativas de ajuste de hiperparâmetros e de folds da validação cruzada aninhada. Os foundation models invertem o eixo: por serem *zero-shot*, o “treino” do TabFM custa 0,18 s e o do TabPFN 1,35 s, com custo de ajuste **zero** — não há busca de hiperparâmetros a pagar. Essa inversão, cujo outro lado aparece já no próximo parágrafo, é o fio que costura o capítulo.

5.3.0.0.2 Ajuste de hiperparâmetros: o custo escondido. O segundo eixo é o custo total do ajuste de hiperparâmetros, que o tempo de treino de um único ajuste subestima. Nas medianas entre conjuntos, os GBDTs pagam de 106 s (LightGBM) a 648 s (CatBoost) pelo ciclo completo de busca; o DL tipo-MLP paga de 1.150 s (MLP) a 3.515 s (TabM); e a atenção pesada chega a 12.245 s (SAINT) e 14.956 s (STab) — duas ordens de magnitude acima dos GBDTs mais baratos, para, como visto no Ato I, não sair do empate. Os foundation models pagam zero. Esse eixo raramente aparece nos benchmarks da literatura, mas é o que o praticante paga a cada reajuste do modelo em produção.

5.3.0.0.3 Inferência: cinco ordens de magnitude. A latência de inferência é o eixo mais dramático do benchmark. A Figura 5.4 apresenta a medição completa, feita sob protocolo idêntico para os 14 modelos: μ s por linha, mediana de 5 passadas sobre o hold-out completo do *adult*, cada modelo em seu dispositivo natural (GBDTs em CPU; modelos profundos e foundation models em GPU).

A estrutura da figura organiza-se em quatro camadas. Na base, o XGBoost serve a 0,33 μ s/linha. O *tier* rápido reúne os três GBDTs, os modelos profundos tipo-MLP e as duas KANs (CatBoost 1,4; RealMLP 1,5; LightGBM 1,9; TabKAN 2,3; MLP 2,4; KAN 3,1; TabM 3,5 μ s/linha) — um resultado em si: aprendizado profundo *não* é sinônimo de serving caro; a arquitetura é que decide. A atenção custa dezenas de microssegundos (TabNet 17; FT-Transformer 29; SAINT 45). E o extremo pertence aos paradigmas de inferência estruturalmente pesada: TabPFN 7.416, STab 8.645 e TabFM 43.262 μ s/linha — o custo do STab vem da inferência bayesiana que calcula a média de 64 passadas estocásticas; o dos foundation models, de carregar o conjunto de treino como contexto a cada predição. A ressalva de regime, dita na legenda, merece repetição no corpo: essas razões descrevem o serving em lote amortizado no hardware declarado no Capítulo 4; o serving online de linha única estreita as diferenças — mas não as ordens de magnitude.

5.3.0.0.4 O cruzamento: a fronteira de Pareto. Nenhum dos eixos isolados decide; o instrumento de decisão é o cruzamento desempenho $\times$ custo. Sobre rank médio $\times$ custo — sendo o rank o instrumento primário de comparação do estudo — o núcleo de 11 modelos resolve-se em uma fronteira de Pareto de {TabPFN, XGBoost, LightGBM} no eixo de custo de treino, que se estreita para {XGBoost, TabPFN} no eixo de latência (sobre AUC média em vez de rank, o CatBoost também se torna não-dominado); **todo o aprendizado profundo clássico é**




Figura 5.4: A latência de inferência atravessa cinco ordens de magnitude: GBDTs e DL tipo-MLP servem em microssegundos; atenção custa dezenas de μ s; os paradigmas de inferência pesada custam milhares. Latência em μ s por linha no hold-out do `adult` (mediana de 5 passadas, escala logarítmica, menor é melhor), com cores por família. Cada modelo roda em seu dispositivo natural (GBDTs em CPU; profundos e foundation models em GPU), de modo que as razões descrevem o regime de serving em lote amortizado em uma máquina declarada — não a latência online de linha única, cujas diferenças são menores. Fonte: `results/figures/inference_time.pdf` (dados em `results/latency/latency_adult.csv`).

dominado em ambos os cruzamentos. A Figura 5.5 apresenta o retrato completo, já com os 14 modelos.




Figura 5.5: **Na grade completa, o TabFM toma a fronteira treino-desempenho sozinho: é simultaneamente o ajuste mais barato e o melhor rank.** Rank binário médio $\times$ tempo mediano de treino sobre os conjuntos binários (escala logarítmica; o eixo de rank é invertido, de modo que acima-à-esquerda é melhor), todos os 14 modelos. O ponto estrelado é Pareto-ótimo sobre a grade completa (TabFM); a fronteira {TabPFN, XGBoost, LightGBM} citada no texto é a restrição ao núcleo de 11 modelos. As comparações sobre o eixo de latência de inferência são reportadas no texto. Fonte: `latex/ail/figures/pareto_binary.pdf`.

A figura mostra o que a latência isolada não mostra: no plano treino $\times$ rank, os foundation models ocupam o canto ótimo — e é só ao trocar o eixo de custo para a latência de serving que a imagem se inverte. Essa dupla leitura é o **achado-âncora do programa**: o paradigma de *in-context learning* compra treino de segundos e ajuste zero ao preço de serving proibitivo. É ela que motiva tanto o eixo de restrições do arcabouço de decisão (Capítulo 6) quanto a pergunta da destilação (Capítulo 7): quanto desse preço é removível?

Achado 3. *Modelos praticamente equivalentes em acurácia diferem em $\sim 300\times$ no tempo de treino e em cinco ordens de magnitude na latência de inferência; no núcleo de 11, a fronteira de Pareto rank $\times$ custo é {TabPFN, XGBoost, LightGBM} no eixo de treino — e todo o aprendizado profundo clássico é dominado.* Quando o desempenho empata, o custo decide — e o custo não empata.

5.4 Ato III — reversões condicionais e o eixo do tamanho

O empate do Ato I é um retrato agregado; ele não implica que todos os problemas sejam iguais. Este ato condiciona os resultados à estrutura da tarefa e ao tamanho amostral, e encontra reversões reais — a matéria-prima das perguntas de restrição do Capítulo 6.

5.4.0.0.1 Multiclasse: o DL recente assume o topo clássico. Na classificação multiclasse, os modelos profundos da geração mais recente (STab e TabM, ambos com rank médio 3,67 na grade completa) tomam o topo clássico dos GBDTs (XGBoost, o melhor deles, fica em 6,0). A ressalva de poder é vinculante e repetida sempre que a multiclasse aparece: com $N=3$ conjuntos, a análise é **descritiva** — não há teste com poder útil sobre três pontos — e por isso nenhum achado numerado se apoia exclusivamente nela.

5.4.0.0.2 Desbalanceamento severo: vantagem relativa dos GBDTs. A segunda reversão aparece ao estratificar os conjuntos de classificação pela razão de desbalanceamento. A Figura 5.6 apresenta os ranks médios agregados por família em três faixas de severidade.




Figura 5.6: **Conforme o desbalanceamento se agrava, os GBDTs melhoram seu rank relativo e o aprendizado profundo clássico piora; os foundation models permanecem à frente em todas as faixas.** Rank médio agregado por família (menor é melhor; eixo invertido) nos conjuntos de classificação, estratificados pela razão de desbalanceamento majoritária/minoritária: leve ($<2:1$), moderada ($2-5:1$) e severa ($\geq 5:1$). Ressalva: com poucos conjuntos por faixa, a figura é descritiva — ela indica direção de tendência, não significância. Fonte: `results/figures/imbalance_robustness.png` (notebooks/07_segmented_robustness.ipynb).

A tendência é monotônica e na direção que a intuição de praticantes sugere — árvores lidam melhor com classes raras do que redes treinadas por gradiente sobre perda média — mas a ressalva da legenda é parte do resultado: com poucos conjuntos por faixa, trata-se de direção descritiva, não de teste. Duas observações completam o quadro condicional: no extremo de cardinalidade categórica, a codificação one-hot penaliza os modelos de atenção (o caso `amazon_employee` visível na Figura 5.3); e o TabPFN combina, dentro do núcleo, o melhor rank médio com o melhor pior-caso — é o modelo que mais raramente falha de forma catastrófica, um atributo de robustez que rank médio sozinho não captura.

5.4.0.0.3 O eixo do tamanho: curvas de aprendizado. Nenhuma das análises anteriores responde à pergunta mais frequente do praticante: “com *meu* volume de dados, quem vence?”. As curvas de aprendizado — 6 modelos $\times$ 5 conjuntos $\times$ 3 sementes, varrendo de 500 amostras ao pool completo — dão forma a esse eixo. A Figura 5.7 apresenta a varredura completa.




Figura 5.7: **O cruzamento de liderança GBDT $\leftrightarrow$ DL é real, mas específico por conjunto — e o TabPFN lidera o regime de poucos dados em todos os cinco painéis.** Curvas de aprendizado (6 modelos $\times$ 5 conjuntos $\times$ 3 sementes, de 500 amostras ao pool completo). Cada painel nomeia sua métrica e direção ($\uparrow$ maior é melhor; $\downarrow$ menor, escala logarítmica); as bandas são ± 1 desvio-padrão sobre as sementes. Um cruzamento é o ponto em que a curva de uma família cruza permanentemente a da outra. Fonte: `latex/ail/figures/learning_curves.pdf` (`notebooks/10_learning_curves.ipynb`).

Três leituras saem da figura. Primeira: o cruzamento de liderança entre GBDTs e DL existe, mas é específico por conjunto — em 3 dos 5 conjuntos varridos (`higgs`, `jannis` e `year_prediction`), o DL ultrapassa os GBDTs e não devolve a liderança; no `adult`, o GBDT a retoma em $n \approx 4.000$; e em `give_me_some_credit`, o GBDT lidera do início ao fim. Não há, portanto, um “ n crítico” universal a recomendar: a resposta honesta ao praticante é que o cruzamento depende do conjunto, não apenas do tamanho. Segunda: o TabPFN tem a melhor métrica média de regime nos cinco conjuntos varridos para $n \leq 4.000$ (rank médio 1,0 nesse regime, contra 2,8 do XGBoost) — a quantificação do nicho de poucos dados do paradigma zero-shot. Terceira, a ressalva: a varredura cobre 6 dos 14 modelos e 5 dos 18 conjuntos; ela qualifica o eixo do tamanho, não o reordena.

Achado 4. A melhor família depende da estrutura do problema — o DL recente toma o topo multiclasse (descritivo), os GBDTs ganham vantagem relativa sob desbalanceamento severo,

o one-hot penaliza a atenção no extremo categórico — e o cruzamento GBDT↔DL por tamanho é real mas específico por conjunto, com o TabPFN dominando o regime $n \leq 4.000$ em todos os conjuntos varridos. As reversões não restauram a máxima de uma família vencedora: elas mostram que a resposta certa é condicional — e condições verificáveis a priori são exatamente o que um arcabouço de decisão pode codificar.

5.5 Ato IV — a quebra do empate: a geração 2026

5.5.0.0.1 A entrada do TabFM reorganiza a narrativa. A expansão para a grade completa de 14 modelos muda o retrato. O TabFM — foundation model lançado em junho de 2026, avaliado aqui *zero-shot*, sem qualquer ajuste por conjunto — lidera o rank médio **nas três tarefas**: 2,7 na binária, 1,0 na multiclasse (pontuação perfeita sobre seus dois conjuntos elegíveis; *helen*a é exclusão estrutural) e 1,2 na regressão. É o melhor modelo absoluto em **13 dos 18 conjuntos**, participando de 17. A Tabela 5.1 resume os ranks por tarefa e a Figura 5.8 apresenta o retrato visual.

Tabela 5.1: Rank médio por tarefa — geração 2026 vs. referências ($k=14$ modelos; binária $N=10$, multiclasse $N=3$, regressão $N=5$; menor é melhor, **negrito** = melhor da coluna). Os ranks multiclasse de TabFM e TabPFN são médias sobre os 2 conjuntos excluindo *helen*a (exclusão estrutural). A tabela mestra completa, com a métrica primária de cada modelo em cada um dos 18 conjuntos, está no Apêndice A. Fonte: `notebooks/TABELA_RESULTADOS.md`.

	Binária	Multiclasse	Regressão
TabFM	2,7	1,00	1,2
TabPFN	4,2	2,50	3,0
Melhor clássico	XGBoost 5,0	STab/TabM 3,67	XGBoost 5,0
KAN	11,0	12,0	9,8
TabKAN	11,4	13,3	11,8

Dois detalhes concretos dão escala à liderança. Na multiclasse, onde a margem é mais visível, o TabFM alcança log-loss de 0,0966 no `coverttype` e 0,5709 no `jannis`, contra 0,1644 e 0,6583 do segundo colocado (TabPFN) — margens visivelmente maiores que as que separam vizinhos de rank dentro do núcleo de 11 na mesma tabela (Apêndice A). E o TabPFN, por sua vez, consolida-se como o vice consistente da grade (ranks médios 4,2/2,5/3,0 nas três tarefas): a geração 2026 não é um ponto fora da curva, é uma família inteira — os dois foundation models ocupam os dois primeiros postos em todas as tarefas.

A consequência interpretativa é a re-escopagem do Ato I: o empate fica corretamente lido como *retrato da geração anterior*. Não foi o aprendizado profundo tunado que alcançou os GBDTs; foi o pré-treino que atropelou ambos. E a cautela estatística permanece dita: com $k=14$ e $N=10$, a distância crítica de Nemenyi é larga (Figura 5.2) — a separação do TabFM apoia-se na consistência entre conjuntos (13 vitórias em 18) e no instrumento bayesiano, **não**




Figura 5.8: A geração 2026 (TabFM) separa-se do pelotão nos painéis de binária e regressão; as KANs ocupam o último terço em todos. Ranks médios por tarefa. Os painéis de binária e regressão cobrem os 14 modelos; o painel multiclasse mostra os 12 modelos avaliados nos três conjuntos multiclasse, rankeados dentro desse subconjunto — e por isso não é diretamente comparável aos ranks de 14 modelos da Tabela 5.1, em que os foundation models (excluídos no heleno) são rankeados. Fonte: `latex/ail/figures/average_ranks.pdf`.

no post-hoc frequentista. Duas condições de contorno adicionais são declaradas: na regressão, $N=5$ põe o piso do p-valor de Wilcoxon em 0,0625 (piso combinatório — nenhum resultado pode ser “significativo a 5%” ali); e o TabFM é avaliado na versão fixada v1.0.1 (julho de 2026), cujo relatório técnico oficial apareceu apenas no fim de setembro de 2026 (KONG et al., 2026) e segue sem revisão por pares — os resultados são sobre essa versão, e isso fica registrado.

5.5.0.0.2 O contrapeso: o líder de acurácia é o pior em latência. O contrapeso é frontal, e é o achado-âncora do programa: o líder de acurácia é o pior modelo da grade em latência de serving — 43.262 μ s/linha sob o protocolo padrão, 131.097 $\times$ o XGBoost, e mais em contextos maiores, chegando a ~ 394 ms/linha no maior conjunto de regressão. A pergunta de decisão mudou de natureza: não é mais “qual família vence?”, e sim “a latência do foundation model cabe no caso de uso?”.

Achado 5. A geração 2026 quebra o empate: o TabFM lidera o rank médio nas três tarefas e é o melhor modelo em 13 dos 18 conjuntos, zero-shot — ao preço de quatro a cinco ordens de magnitude em latência de serving (43.262 vs. 0,33 μ s/linha). O empate não tornou o arcabouço multicritério obsoleto; a quebra o tornou mais necessário — e apontou seu único obstáculo.

5.5.0.0.3 O resultado negativo das redes de Kolmogorov–Arnold. No mesmo movimento da extensão, o benchmark produz o teste independente da família Kolmogorov–Arnold — e o resultado é o negativo de valor. KAN (ranks 11,0/12,0/9,8 em binária/multiclasse/regressão) e TabKAN (11,4/13,3/11,8) ocupam o último terço nas três tarefas, com o TabKAN atrás até do TabNet em multiclasse e regressão. Surpreendente à luz das alegações dos artigos originais (LIU et al., 2025; ESLAMIAN; Afzal Aghaei; CHENG, 2025), o resultado pede explicação:

sob protocolo uniforme com orçamento de ajuste equalizado, as alegações não se sustentam, e a explicação mais provável é que as comparações originais usaram *baselines* subajustados — leitura consistente com a literatura cética anterior (POETA et al., 2024; YU; YU; WANG, 2024). Até onde alcança nossa verificação datada de novidade, este é o primeiro teste da família contra a grade completa GBDT/DL/foundation-model em um benchmark tabular multicritério; as avaliações independentes anteriores (POETA et al., 2024; YU; YU; WANG, 2024) comparam KANs apenas contra MLPs e não medem eixos de custo. A contraparte de engenharia merece registro simétrico: ambas habitam o tier rápido de latência (2,3–3,1 μ s/linha) e custam VRAM desprezível — **o problema é o desempenho, não o custo**.

Achado 6. *Sob protocolo uniforme, KAN e TabKAN ficam no último terço nas três tarefas — as alegações dos artigos originais não se sustentam no primeiro teste independente contra a grade completa, até onde alcança nossa verificação datada — embora ambas sejam baratas de servir.* O resultado negativo é reportado com o mesmo estatuto dos positivos, conforme o contrato de conduta do estudo (Capítulo 4): um benchmark neutro existe precisamente para que resultados assim venham a público.

5.6 Síntese do capítulo

Três fatos encadeados emergem do benchmark. (i) Na geração do núcleo de 11 modelos, o desempenho bruto empata no topo — empate positivo, aferido por equivalência prática bayesiana e robusto à variação do limiar — e 80% da variância de rank é intrafamília; a decisão racional migra, portanto, para custo, latência, robustez e estrutura da tarefa, exatamente os eixos em que os modelos diferem por ordens de magnitude. (ii) A geração 2026 quebra o empate em acurácia: o TabFM lidera as três tarefas e vence em 13 de 18 conjuntos, zero-shot — ao preço de quatro a cinco ordens de magnitude em latência de serving, invertendo o eixo de custo (treino de segundos e ajuste zero; serving proibitivo). A quebra não aposenta a leitura multicritério: ela a torna mais necessária, porque a escolha ótima passa a depender de uma única restrição dominante. (iii) Essa restrição é atacável: a latência do foundation model não é uma lei, é um custo de arquitetura — e custos de arquitetura podem ser transferidos para modelos pequenos. As ressalvas do capítulo acompanham os fatos: N pequeno por tarefa (multiclasse descritiva; piso de p-valor na regressão), distância crítica larga na grade completa, latências medidas no regime de lote amortizado em dispositivo natural, e TabFM avaliado em versão fixada anterior à revisão por pares de seu relatório técnico.

Transição. O Capítulo 6 converte o fato (i) e as reversões do Ato III em um arcabouço de decisão por restrições — e o valida por *leave-one-dataset-out*, testando tanto a alternativa de roteamento por meta-atributos (resultado negativo) quanto a política fixa “foundation model primeiro, desviar por restrições” (resultado positivo). O obstáculo que resta a essa política

— as quatro a cinco ordens de magnitude de latência do fato (ii) — é o objeto do Capítulo 7: quanto dele a destilação remove, e sob quais condições verificáveis.

6

O Arcabouço de Decisão Validado

Resumo do capítulo. O benchmark do Capítulo 5 descreve; este capítulo decide. Elevamos o arcabouço de decisão de descritivo a *validado* por meio de três estudos sobre os mesmos 18 conjuntos: (i) um resultado negativo o roteamento por meta-features não generaliza sob validação *leave-one-dataset-out* (hit-rate de 0,11 contra um baseline de classe majoritária de 0,44 no estudo com 11 modelos; 0,72 contra 0,78 com 14) , corroborado por evidência independente contemporânea; (ii) um resultado positivo a política fixa “foundation model primeiro” é regret-ótima na métrica primária, com regret mediano zero na geração 2026; e (iii) um experimento pré-registrado de regret multicritério ponderado, que localiza o peso de latência em que essa recomendação se inverte: basta deslocar 10–20% do peso da acurácia para a latência para que a política FM deixe de ser ótima. O arcabouço resultante é um fluxograma de quatro restrições verificáveis *a priori*, no qual a primeira pergunta latência é agora quantitativamente justificada.

Material associado. Este capítulo corresponde à seção *The Validated Decision Framework* do trabalho individual AI-1 (`latex/ai1/`). A Seção 6.4 (regret multicritério ponderado) é contribuição nova desta dissertação, pré-registrada em `docs/desenho-melhorias-finais.md` (experimento E2, 05/10/2026) e inédita em relação ao artigo. Artefatos: `scripts/lodo_validation.py` `results/aggregated/lodo_validation{,_14}.csv` e `results/aggregated/lodo_weig`

Este capítulo está organizado em cinco movimentos. A Seção 6.1 parte dos instrumentos descritivos que o benchmark produz por construção a matriz multicritério e o fluxograma e explica por que descrever não basta: um arcabouço de decisão precisa ser testado contra dados que não viu. A Seção 6.2 apresenta o resultado negativo (roteamento aprendido por meta-features não generaliza) e a Seção 6.3, o positivo (a política fixa “FM primeiro” e sua evolução entre as gerações de modelos). A Seção 6.4 estende a validação para o cenário multicritério, respondendo à pergunta que as anteriores deixam em aberto: a política ótima em acurácia sobrevive quando o custo de inferência entra na conta? A Seção 6.5 consolida o arcabouço final quatro restrições verificáveis antes de qualquer treino e a Seção 6.6 declara suas limitações.

6.1 Do descritivo ao validado

O benchmark multicritério do Capítulo 5 produz, por construção, um artefato prático: dado um problema novo, que modelo usar? A primeira versão do arcabouço respondia com dois instrumentos descritivos. O primeiro é a matriz multicritério, que resume a posição de cada um dos 14 modelos em seis critérios medidos no benchmark desempenho, custo de treino, custo de ajuste de hiperparâmetros, latência de inferência, robustez e interpretabilidade. A Figura 6.1 apresenta essa matriz, e sua leitura motiva todo o restante do capítulo.




Figura 6.1: **Nenhum modelo domina todos os critérios: a decisão é um compromisso, não uma escolha de “melhor modelo”.** Matriz de decisão multicritério dos 14 modelos (linhas, ordenadas por desempenho) em seis critérios (colunas: desempenho, custo de treino, custo de ajuste, latência, robustez, interpretabilidade), com escores de 1 a 3 estrelas computados do benchmark do Capítulo 5 (3 = melhor; tom mais escuro = melhor). Os líderes de desempenho (famílias de foundation models, no topo) recebem 1 estrela justamente em latência e interpretabilidade; os GBDTs são os únicos com 3 estrelas simultâneas em latência e interpretabilidade. Fonte: `results/figures/decision_matrix.png`.

A matriz torna visível o padrão central: as linhas do topo (foundation models) e as do meio (GBDTs) têm perfis *complementares*, não ordenáveis — o que é ótimo em desempenho é fraco em latência, e vice-versa. O segundo instrumento, o fluxograma orientado a restrições (apresentado em sua forma final na Seção 6.5), codifica esse compromisso como uma sequência de perguntas verificáveis antes de qualquer treino.

Ambos os instrumentos, porém, são descritivos: resumem o que o benchmark mediu, mas não foram testados contra conjuntos que não participaram de sua construção. Um arcabouço de recomendação que nunca foi exposto a esse teste está sujeito à mesma crítica de *overclaiming* que atinge parte da literatura de recomendação de algoritmos. Este capítulo eleva o arcabouço de descritivo a **validado** com dois resultados complementares: um negativo (o que o arcabouço *não* deve tentar fazer) e um positivo (a política que os dados sustentam) e, em seguida, com um terceiro estudo, pré-registrado, que estende a validação ao cenário multicritério.

6.2 O resultado negativo: roteamento por meta-features não generaliza

A literatura de meta-learning, que remonta ao problema de seleção de algoritmos (RICE, 1976), sugere um caminho sedutor: prever o algoritmo vencedor a partir de meta-features do conjunto de dados: tamanho, dimensionalidade, desbalanceamento, fração de atributos categóricos. Se funcionasse, o arcabouço de decisão seria um modelo preditivo, não um fluxograma. Testamos essa promessa com o protocolo honesto disponível para $N=18$ conjuntos: validação *leave-one-dataset-out* (LODO), em que uma árvore de decisão de profundidade 2 – o mesmo modelo ilustrativo do Capítulo 5 – é treinada nos demais 17 conjuntos para prever a família vencedora do conjunto excluído, repetindo-se o procedimento para cada um dos 18.

O resultado contraria a expectativa criada pela literatura e por isso o reportamos com o protocolo à vista. No estudo com 11 modelos (o núcleo de 11 modelos do estudo original), a árvore atinge **hit-rate de 0,11 contra 0,44 do baseline de classe majoritária**; no estudo com 14 modelos (incluindo a geração 2026), 0,72 contra 0,78 do baseline. Em nenhuma das duas configurações o roteador aprendido supera a regra trivial “preveja sempre a família que mais vence”. Investigado o porquê, a atribuição é direta: com $N=18$ conjuntos, cada rodada do LODO treina com 17 exemplos – uma amostra em que qualquer partição por meta-features é dominada pelo ruído das reversões individuais, e em que o preço de errar uma folha é alto. O resumo honesto é este: aprender o roteamento por meta-features não é viável sob LODO com essa classe de modelo nesta escala de N e afirmar isso sob um protocolo explícito protege o arcabouço da crítica de *overclaiming* mencionada acima. A árvore permanece no trabalho como *ilustração descritiva da estrutura* das reversões entre famílias, jamais como preditor.

Evidência independente e contemporânea aponta na mesma direção: abordagens globais baseadas em meta-features não são robustas o suficiente para explicar ou selecionar entre modelos da era dos foundation models tabulares (HERRE et al., 2026). A convergência entre nosso protocolo LODO e um estudo externo, com metodologia distinta, reforça que o resultado negativo não é um artefato da nossa amostra de conjuntos.

Achado 6.1. Roteamento por meta-features não generaliza sob LODO. Com $N=18$ conjuntos, um roteador aprendido (árvore de profundidade 2) não supera o baseline de classe majoritária em nenhuma das duas gerações de modelos (0,11 vs. 0,44 com 11 modelos; 0,72 vs. 0,78 com 14). O arcabouço de decisão não deve conter um preditor de família vencedora conclusão corroborada por evidência independente (HERRE et al., 2026).

6.3 O resultado positivo: a política “FM primeiro” e sua evolução

Se o roteamento aprendido não funciona, a alternativa natural são *políticas fixas*: recomendar sempre a mesma família, independentemente do conjunto. Para compará-las, usamos a métrica de **regret normalizado** sobre a métrica primária de cada conjunto: 0 significa que a família recomendada contém o melhor modelo do conjunto; 1, que contém apenas o pior. A Tabela 6.1 resume o regret das quatro políticas a árvore sob LODO e as três políticas fixas nos dois estudos.

Tabela 6.1: Regret normalizado das políticas de recomendação sob LODO, nos estudos com 11 modelos (o núcleo de 11 modelos do estudo original) e 14 modelos (incluindo a geração 2026). Convenção: **negrito** = melhor política da coluna. Nota sobre os N s: as colunas da árvore e da política sempre-FM agregam sobre os 17 conjuntos em que a família FM participa (*helen*a é excluída por limite arquitetural de 100 classes); as colunas sempre-GBDT e sempre-DL agregam sobre todos os 18. Fonte: `results/aggregated/lodo_validation{ ,_14 }.csv`.

Política	média @11	mediana @11	média @14	mediana @14
Árvore (LODO)	0,228	0,145	0,051	0,000
Sempre-GBDT	0,249	0,168	0,305	0,291
Sempre-DL	0,189	0,132	0,313	0,349
Sempre-FM	0,115	0,018	0,021	0,000

Três leituras emergem da tabela. Primeiro, já na geração ≤ 2025 , “usar o foundation model por padrão” era a melhor política fixa (regret médio 0,115; mediano 0,018). Segundo, com a geração 2026, o regret mediano da política cai a **zero**: em metade ou mais dos conjuntos, a família FM contém o melhor modelo, ponto. A pergunta “qual família vence?” se dissolve e com ela o valor de qualquer roteador de desempenho. Terceiro, o aparente empate entre a árvore e a política sempre-FM na mediana @14 (ambas 0,000) merece explicação, e ela desfaz o empate: com 14 modelos, a árvore aprende a prever a família FM em quase todos os conjuntos, colapsando na política fixa mas mantendo hit-rate *abaixo* do baseline de classe majoritária (Seção 6.2). A política fixa atinge o mesmo regret sem esse modo de falha; o colapso da árvore é mais um sintoma de que não há estrutura aprendível, não uma vitória do roteador.

Achado 6.2. “*Foundation model primeiro*” é a política regret-ótima na métrica primária. Na geração 2026, a política fixa sempre-FM atinge regret médio 0,021 e mediano 0,000 sob LODO nenhuma política aprendida ou fixa a supera. A recomendação de desempenho deixou de depender do conjunto de dados; a ressalva é que esse resultado vale para a métrica primária isolada, questão que a próxima seção enfrenta.

6.4 Regret multicritério ponderado: quando a recomendação vira

O resultado positivo da seção anterior tem uma limitação declarada desde o artigo AI-1: o regret é calculado sobre a métrica primária, não sobre combinações multicritério ponderadas por preferências do usuário. A limitação não é cosmética. O Capítulo 5 mostrou que o líder de acurácia custa 4–5 ordens de magnitude mais para servir que um GBDT; um praticante cuja função de utilidade pondere acurácia e custo de inferência pode, legitimamente, chegar a outra recomendação. Esta seção fecha essa lacuna com o experimento E2, pré-registrado em `docs/desenho-melhorias-finais.md` (05/10/2026, antes da execução, conforme o contrato de conduta do programa de pesquisa): a política “FM primeiro” continua regret-ótima quando a métrica de decisão pondera acurácia e custo?

6.4.1 Desenho pré-registrado

O desenho define um score multicritério por modelo×conjunto:

$$S = w \cdot r_{\text{acc}} + (1 - w) \cdot r_{\text{lat}}, \quad (6.1)$$

em que r_{acc} é o rank normalizado em $[0, 1]$ do modelo na métrica primária do conjunto, r_{lat} é o rank normalizado da latência de inferência, e $w \in \{1, 0; 0, 9; \dots; 0, 0\}$ varre o espectro de preferências de “só acurácia importa” ($w=1$) a “só latência importa” ($w=0$). Para cada valor de w , calcula-se o regret normalizado de cada política fixa exatamente como no estudo original: 0 se a família recomendada contém o modelo de melhor score S no conjunto; 1 se contém apenas o pior.¹ Os N s espelham os da Tabela 6.1: 18 conjuntos para as políticas sempre-GBDT e sempre-DL, 17 para sempre-FM (*helen*a excluída por limite arquitetural). A hipótese pré-registrada H-W1 afirma: existe $w^* < 1$ a partir do qual “sempre-GBDT” passa a ter regret mediano menor que “sempre-FM” o que tornaria o fluxograma (pergunta 1 = latência) a forma correta da política, e não um refinamento cosmético.

¹As quatro políticas do pré-registro estão no artefato (`results/aggregated/lodo_weighted_regret.csv`): a árvore-LODO é avaliada pela recomendação por conjunto armazenada no estudo original (`lodo_validation_14.csv`), sem reajuste ela foi treinada para prever o vencedor de *acurácia* e aqui é pontuada sob o score ponderado. O resultado antecipa a Seção 6.2: a árvore nunca supera a melhor política fixa em nenhum w e colapsa na política sempre-FM nos pesos altos (mediana 0,000 apenas em $w \geq 0,9$).

Uma limitação do desenho foi declarada no próprio pré-registro e deve ser repetida aqui: a latência usa como *proxy* a medição padronizada no conjunto `adult` a única disponível para os 14 modelos sob protocolo idêntico. A latência relativa entre modelos é aproximadamente estável entre conjuntos para GBDTs e modelos de deep learning; para foundation models, porém, ela cresce com o tamanho do contexto, de modo que o proxy é conservador a favor dos FMs em conjuntos pequenos e contra eles em conjuntos grandes. As conclusões desta seção devem ser lidas com essa ressalva.

6.4.2 Resultados: o cruzamento

A Figura 6.2 mostra o que a Tabela 6.1 não pode mostrar: como o regret de cada política evolui à medida que o peso desloca-se da acurácia para a latência.




Figura 6.2: A política “FM primeiro” só é ótima quando a acurácia pesa 90% ou mais; com pesos menores, a recomendação inverte-se em favor dos GBDTs. Regret normalizado das três políticas fixas (14 modelos) em função do peso da acurácia w no score $S = w \cdot r_{\text{acc}} + (1 - w) \cdot r_{\text{lat}}$ (Eq. 6.1); o painel esquerdo mostra a mediana e o direito, a média sobre os conjuntos (18 para GBDT/DL; 17 para FM, *helena* excluída). Em $w=1,0$ (só acurácia), sempre-FM tem regret mediano zero; o cruzamento ocorre entre $w=0,9$ e $w=0,8$ na mediana, e entre $w=0,8$ e $w=0,7$ na média; para $w \leq 0,6$, sempre-GBDT tem regret mediano zero. Latência via proxy do `adult` (ver ressalva no texto). Fonte: `results/aggregated/lodo_weighted_regret.csv`.

A Tabela 6.2 dá os valores exatos da mediana em pontos selecionados da varredura, para que cada número citado a seguir tenha origem inspecionável.

A leitura conjunta da figura e da tabela estabelece três fatos. Primeiro, a **hipótese H-W1 é confirmada, e o cruzamento é precoce**: na grade de varredura, a política sempre-FM só mantém regret mediano zero em $w \in \{0,9; 1,0\}$. Já em $w^*=0,8$ apenas 20% do peso na latência tanto sempre-GBDT (0,067) quanto sempre-DL (0,035) têm regret mediano menor que sempre-FM (0,096); o cruzamento, portanto, ocorre entre $w=0,9$ e $w=0,8$. Pela média (painel direito da Figura 6.2), o quadro é ligeiramente mais favorável aos FMs: sempre-FM ainda é a melhor

Tabela 6.2: Regret normalizado mediano das três políticas fixas em função do peso da acurácia w (estudo com 14 modelos; valores selecionados da varredura completa $w \in \{1,0; 0,9; \dots; 0,0\}$). Convenção: **negrito** = melhor política da coluna. $N=18$ conjuntos para sempre-GBDT e sempre-DL; $N=17$ para sempre-FM (helená excluída). Fonte: `results/aggregated/lodo_weighted_regret.csv` (medianas recomputadas do artefato).

Política	$w=1,0$	$w=0,9$	$w=0,8$	$w=0,7$	$w=0,6$	$w=0,5$	$w=0,0$
Sempre-GBDT	0,231	0,147	0,067	0,007	0,000	0,000	0,000
Sempre-DL	0,154	0,088	0,035	0,000	0,096	0,232	0,154
Sempre-FM	0,000	0,000	0,096	0,248	0,383	0,526	0,846

política em $w=0,8$ (0,119 contra 0,143 do GBDT e 0,146 do DL) e só perde em $w=0,7$ (0,243 contra 0,105 do GBDT). Segundo, a partir de $w \leq 0,6$, “sempre-GBDT” tem regret mediano exatamente zero assim que a latência domina a função de utilidade, a família GBDT contém o melhor modelo em metade ou mais dos conjuntos, espelhando no extremo oposto o que a família FM faz em $w=1$. Terceiro, no extremo $w=0$ (só latência), o regret mediano de sempre-FM atinge 0,846: a família que contém o melhor modelo em acurácia contém quase o pior em custo de inferência, o retrato numérico do compromisso que a Figura 6.1 mostrava em estrelas.²

A interpretação pré-fixada no registro do experimento aplica-se diretamente: qualquer que fosse w^* , o resultado enriqueceria o arcabouço ao quantificar o trade-off que ele já codificava qualitativamente. O valor encontrado cruzamento entre $w=0,9$ e $w=0,8$ pela mediana faz mais que enriquecer: ele explica *por que a primeira pergunta do fluxograma é a latência*. Se a recomendação só se sustentasse com 99% do peso em acurácia, a pergunta de latência seria um detalhe de borda; como ela vira com 10–20% de peso na latência, a pergunta é o eixo da decisão. O fluxograma da próxima seção não é uma heurística decorativa em torno de uma política única é a codificação da fronteira que a Figura 6.2 mede. Dito de outro modo: antes de E2, sabíamos que a latência *importava* (a matriz da Figura 6.1 já o mostrava em estrelas); depois de E2, sabemos *quanto* ela precisa importar para mudar a resposta e a resposta é: pouco.

Achado 6.3. A recomendação “FM primeiro” inverte-se com 10–20% de peso na latência.

Sob o score ponderado $S = w \cdot r_{\text{acc}} + (1 - w) \cdot r_{\text{lat}}$, a política sempre-FM só é regret-ótima na mediana para $w \geq 0,9$; em $w=0,8$ já é superada por sempre-GBDT e sempre-DL, e para $w \leq 0,6$ “sempre-GBDT” tem regret mediano zero. A ressalva acompanha o achado: a latência usa o proxy padronizado do `adult`, conservador a favor dos FMs em conjuntos pequenos e contra eles em grandes.

²Em $w=1,0$, o score da Eq. 6.1 reduz-se ao rank da métrica primária; os valores diferem marginalmente dos da Tabela 6.1 (regret médio de sempre-FM 0,023 aqui contra 0,021 lá) porque o regret do estudo original é normalizado na escala da métrica primária, e o de E2, na escala de ranks. As medianas coincidem em 0,000.

6.5 O arcabouço resultante: decisão por restrições

Os três estudos convergem para uma mesma conclusão: o que resta de informativo na decisão e o que o fluxograma sempre codificou são **restrições verificáveis *a priori***, não predições de desempenho. A Figura 6.3 apresenta o fluxograma validado na sua forma final, com os 14 modelos do estudo completo.




Figura 6.3: **Quatro perguntas verificáveis antes de qualquer treino; só quando nenhuma restrição está ativa aplica-se o default regret-ótimo foundation model primeiro.** Fluxograma de decisão do praticante, validado pelos estudos de regret deste capítulo (estudo com 14 modelos). Cada losango é uma restrição verificável *a priori*: orçamento de latência, limites arquiteturais, exigência de interpretabilidade intrínseca; a ordem das perguntas é justificada quantitativamente pela Seção 6.4. Gerado por `scripts/figures_ail_display.py`.

As quatro restrições, na ordem em que o fluxograma as verifica:

1. **Latência e custo de inferência.** O líder de acurácia custa 4–5 ordens de magnitude mais para servir (Capítulo 5); se o orçamento de latência é de microssegundos, a família FM está excluída na forma nativa. O experimento E2 quantifica por que esta é a primeira pergunta: a recomendação inverte com apenas 10–20% do peso na latência (Seção 6.4). Recuperar a família FM dentro desse orçamento é precisamente o objeto do Capítulo 7.
2. **Limites arquiteturais.** Mais de 10 classes (limite do TabFM) ou estouro do limite de contexto são exclusões estruturais objetivas o caso *helena* (100 classes) no próprio benchmark.

3. **Interpretabilidade intrínseca exigida.** Quando a regulação do domínio exige modelos intrinsecamente interpretáveis, a recomendação são os GBDTs a única família com perfil simultaneamente forte em latência e interpretabilidade na matriz da Figura 6.1.
4. **Nenhuma restrição ativa.** Aplica-se o default regret-ótimo: foundation model, com o TabPFN (HOLLMANN et al., 2025) como opção madura e o TabFM (Google Research, 2026) como fronteira, com as ressalvas de maturidade discutidas no Capítulo 5.

A validação por regret confirma que essas quatro perguntas capturam o essencial: as restrições são o *conteúdo informativo real* da decisão, e o desempenho bruto deixou de discriminar dentro da família líder. O arcabouço resultante é deliberadamente modesto na forma um fluxograma, não um meta-modelo porque é essa a forma que os dados sustentam.

6.6 Limitações do arcabouço

As limitações deste capítulo são declaradas na mesma moeda dos seus resultados.

Tamanho da amostra de conjuntos. $N=18$ impede validação estatística fina do próprio arcabouço; o LODO é a ferramenta honesta possível nessa escala, e é exatamente por isso que o resultado negativo da Seção 6.2 é formulado como “não aprendível sob LODO com esta classe de modelo”, e não como impossibilidade geral.

Métrica do regret. O estudo original calcula o regret sobre a métrica primária. A extensão multicritério da Seção 6.4 fecha parte dessa lacuna, mas herda duas simplificações próprias: o score pondera apenas dois critérios (acurácia e latência) de uma função de utilidade que, na prática, pode incluir custo de treino, robustez e interpretabilidade; e a latência entra pelo proxy padronizado do `adult`, medido em uma única máquina declarada a direção do viés desse proxy é conhecida e foi declarada no pré-registro, mas sua magnitude por conjunto não foi medida.

Datação. A fronteira de modelos muda em ciclos de meses a diferença entre as colunas @11 e @14 da Tabela 6.1 é, ela própria, a demonstração. O arcabouço é datado por construção e versionado com o benchmark que o sustenta; recomendações derivadas dele devem citar a versão do estudo (11 ou 14 modelos) a que se referem.

Conclusão do capítulo

Este capítulo transformou os instrumentos descritivos do Capítulo 5 em um arcabouço validado por três estudos sob LODO: o roteamento aprendido por meta-features não generaliza (hit-rate 0,11 vs. 0,44 com 11 modelos; 0,72 vs. 0,78 com 14); a política fixa “foundation model primeiro” é regret-ótima na métrica primária (regret mediano 0,000 na geração 2026); e

o regret multicritério ponderado, pré-registrado como experimento E2, localiza o ponto em que essa recomendação vira entre $w=0,9$ e $w=0,8$ de peso na acurácia pela mediana e com isso justifica quantitativamente a arquitetura do fluxograma: a latência é a primeira pergunta porque é a que mais cedo muda a resposta.

Transição. O arcabouço validado deixa um único obstáculo entre o praticante e a política regret-ótima: a latência de inferência. Quando o orçamento é de microssegundos, a família de foundation models a melhor em acurácia em metade ou mais dos conjuntos está excluída na forma nativa, e a Seção 6.4 mostrou que basta um peso modesto nesse critério para a recomendação inverter. A pergunta que o Capítulo 7 enfrenta é, portanto, a que este capítulo torna inevitável: é possível *destilar* o conhecimento do foundation model em um aluno que viva no tier de microssegundos preservando não só a predição pontual, mas a distribuição preditiva completa?

7

Destilação Distribucional de Foundation Models

Resumo do capítulo. O Capítulo 6 deixou um único obstáculo entre o praticante e a política regret-ótima “foundation model primeiro”: o custo de servir. Este capítulo ataca esse obstáculo por destilação de conhecimento, com um recorte verificado como inédito — a *regressão distribucional*: transferir não a média, mas a distribuição preditiva completa do *teacher* para um aluno de microssegundos. Em 20 conjuntos de dados, sob desenho pré-registrado, quatro resultados estruturam o capítulo: (i) um negativo robusto — a destilação *pontual* falha em escala de pool realista, com qualquer um dos dois teachers; (ii) um positivo no eixo aberto — a transferência das curvas de quantis retém mediana de 19% da vantagem de CRPS do teacher, positiva em 16 de 20 conjuntos (teste de sinal $p = 0,006$), incluindo um caso *born-again* em que o aluno supera o próprio teacher; (iii) a primeira fronteira de três estratégias de serving — destilar $\times$ comprimir contexto $\times$ reduzir ensemble — medida de ponta a ponta, na qual o aluno destilado é o sistema CRPS-ótimo abaixo da configuração competitiva mais barata do teacher onde a vantagem deste é grande; e (iv) um experimento final pré-registrado (E1) contra baselines distribucionais clássicos (NGBoost e florestas quantílicas), que o aluno destilado vence em 17 de 20 conjuntos ($p = 0,0013$) — com três reverses instrutivos que enriquecem, em vez de enfraquecer, a regra de decisão prática que encerra o capítulo.

Material associado. Este capítulo corresponde ao segundo trabalho individual do programa (AI-2), cuja versão em formato de artigo está em `latex/ai2/` no repositório do estudo. O desenho experimental foi pré-registrado em `docs/desenho-experimental-destilacao.md` (julho de 2026) e as checagens de novidade datadas estão em `docs/memo-novidade-destilacao.md`. A Seção 7.8 (baselines distribucionais clássicos) é contribuição nova desta dissertação, pré-registrada em `docs/desenho-melhorias-finais.md` (experimento E1, 05/10/2026) e inédita em relação ao artigo; seus números foram recomputados do artefato `results/distillation/baselines_analysis.csv`.

O capítulo segue a ordem lógica do estudo. A Seção 7.1 estabelece a motivação — a latência como único obstáculo à política validada — e documenta a checagem de novidade datada que delimitou o recorte, incluindo a colisão parcial contemporânea de outubro de 2026 e sua reconciliação. A Seção 7.2 apresenta as hipóteses pré-registradas H1–H3 e os compromissos de conduta; a Seção 7.3, o método: teachers, rotulagem *out-of-fold*, famílias de alunos, métricas e o conjunto experimental. Os resultados vêm em quatro movimentos: a refutação da destilação pontual (Seção 7.4), o sucesso da destilação distribucional com sua tabela de retenção completa e ressalvas (Seção 7.5), a fronteira destilar $\times$ comprimir $\times$ reduzir ensemble (Seção 7.6) e a ablação que explica por que a rotulagem *out-of-fold* importa (Seção 7.7). A Seção 7.8 apresenta o experimento E1 — baselines distribucionais clássicos —, a Seção 7.9 converte duas hipóteses refutadas e o E1 na regra de decisão final, e a Seção 7.10 fecha com a discussão, as limitações e a síntese.

7.1 Motivação e checagem de novidade

7.1.1 O preço do novo líder

O Capítulo 5 estabeleceu que a geração 2026 de foundation models tabulares quebra o empate histórico de acurácia; o Capítulo 6, que a política fixa “foundation model primeiro” é regret-ótima na métrica primária, com regret mediano 0,000 sob validação *leave-one-dataset-out*. O único obstáculo a essa política é o custo de servir — e ele não é um detalhe de implementação, mas uma propriedade constitutiva do paradigma: modelos de aprendizado em contexto (*in-context learning*) carregam o conjunto de treino como contexto em cada predição. Sob protocolo padronizado no conjunto `adult`, medimos 7.416 μs /linha para o TabPFN e 43.262 μs /linha para o TabFM, contra 0,33 μs /linha do XGBoost tunado — fatores de aproximadamente $22.000\times$ e $131.000\times$, respectivamente. A Seção 6.4 mostrou, ademais, que basta deslocar 10–20% do peso da acurácia para a latência para que a recomendação se inverta: remover esse obstáculo não é otimização marginal, é a condição para que a política regret-ótima seja utilizável em produção.

A ferramenta clássica para esse ataque é a **destilação de conhecimento** (BUCILĂ; CARUANA; NICULESCU-MIZIL, 2006; HINTON; VINYALS; DEAN, 2015): treinar um aluno rápido nas saídas de um teacher caro. Para foundation models tabulares, a literatura a estabeleceu em *classificação* (TANNA et al., 2026a); a questão deste capítulo é o que ela pode e não pode transferir em *regressão* — em particular na regressão distribucional, em que a saída do teacher não é um número, mas uma distribuição preditiva completa, da qual se leem quantis, intervalos e incerteza calibrada. Três perguntas organizam o estudo, ecoando a QP3 da Introdução: o que a destilação transfere em regressão tabular (Seções 7.4 e 7.5); a que custo de serving (Seção 7.6); e sob quais condições verificáveis (Seções 7.7 a 7.9).

7.1.2 Checagem de novidade datada — e a colisão parcial de outubro

Conforme o contrato de conduta do programa (Capítulo 4), nenhuma afirmação de novidade é feita sem verificação online datada. A primeira varredura (15/07/2026, registrada em `docs/memo-novidade-destilacao.md`) concluiu que a formulação básica da ideia já estava publicada: o Pocket FM (TANNA et al., 2026a) destila foundation models de *classificação* (TabICLv2, TabPFNV2.6, LimiX, Orion-MSP) em alunos XGBoost/CatBoost/LightGBM/MLP sobre 153 conjuntos, retendo 96,5% da AUC do teacher com acelerações de 38–860×, e estabelece a rotulagem *out-of-fold* como necessária; um trabalho irmão estende a análise a dados clínicos (TANNA et al., 2026b). A Prior Labs comercializa um motor de destilação fechado junto ao TabPFN-2.5 (GRINSZTAJN et al., 2025), sem metodologia nem código públicos; o TabDistill (DISSANAYAKE; DUTTA, 2025) cobre apenas o regime *few-shot*; outra linha destila foundation models em modelos aditivos generalizados para interpretabilidade (JIA et al., 2026); e o GEAR (QIN et al., 2026) adiciona expansão sintética, só para classificação. No braço da aceleração *sem* destilação, TACO (ZABERGJA et al., 2026) e CRUMB (HEREDGE et al., 2026) comprimem o contexto, MotherNet (MÜLLER; CURINO; RAMAKRISHNAN, 2023) amortiza o ajuste em uma hiper-rede e TL-ANDI (LIN; LI, 2026) transfere para tarefas com contexto restrito — nenhum compara as estratégias entre si nos mesmos hold-outs. Três decisões foram herdadas dessa varredura: adotar a rotulagem *out-of-fold* do Pocket FM como base metodológica; jamais reivindicar “primeira destilação de foundation model tabular”; e ajustar o recorte para o que estava aberto — **regressão distribucional** (destilar a distribuição, não a média, avaliando com CRPS e cobertura), a **fronteira de três estratégias** de serving e o TabFM como teacher.

A re-varredura pré-entrega (04/10/2026, adendo datado no mesmo memorando) encontrou uma **colisão parcial contemporânea**: JEONG et al. (2026) (arXiv, 01/10/2026) destilam TabICLv2 e TabPFN v3 em alunos neurais e de árvore *incluindo regressão* — porém apenas com alvos pontuais (transferência por erro quadrático das médias do teacher) e avaliação restrita a RMSE, sem CRPS, quantis, calibração ou fronteira de custo. A reconciliação entre os ganhos pontuais que eles reportam e o nosso resultado negativo é tratada na Seção 7.4, onde a varredura de tamanho de pool isola exatamente o moderador sob o qual tais ganhos aparecem. A mesma re-varredura registrou que o TabFM ganhou relatório técnico oficial em 29/09/2026 (KONG et al., 2026) — ainda não revisado por pares —, que confirma a verificação arquitetural feita meses antes neste estudo (Seção 7.3.1). O pilar distribucional e a fronteira de três estratégias permanecem, até a data desta escrita, sem trabalho público anterior.

7.2 Desenho pré-registrado: hipóteses, critérios e conduta

Todo o desenho experimental foi registrado *antes* da execução, em julho de 2026 (`docs/desenho-experimental-destilacao.md`), com hipóteses falsificáveis, critérios de de-

cisão pós-piloto e o compromisso explícito de reportar resultados negativos com a mesma proeminência dos positivos. As três hipóteses:

- **H1 (ponto).** O aluno destilado retém $\geq 50\%$ do gap de RMSE (teacher — baseline tunado) em ≥ 3 dos 5 conjuntos centrais, com latência $\leq 10 \mu\text{s}/\text{linha}$.
- **H2 (distribuição).** O aluno-quantil destilado supera em CRPS o aluno-quantil treinado nos rótulos verdadeiros (controle), com cobertura de intervalos (PICP 80/90%) a ± 5 p.p. do nominal.
- **H3 (Pareto).** Existe faixa de latência em que o aluno destilado é Pareto-dominante sobre o teacher com contexto subamostrado.

Os critérios pós-piloto previam, inclusive, o cenário de retenção nula (“o trabalho vira o resultado negativo com análise de causa”) — um compromisso que a Seção 7.4 honra literalmente para o eixo pontual. Desvios de execução viraram adendos datados no próprio documento de desenho (cap de 50 mil linhas no contexto do teacher, espelhando a política do benchmark; predição em blocos por restrição de VRAM; encadeamento tolerante a falhas), e um erro de rotulagem de dataset descoberto no meio do estudo — a chave de configuração historicamente chamada `diamonds` apontava para o OpenML id do `kin8nm` — foi tratado por retificação registrada, nunca por reescrita de histórico (`docs/errata-diamonds-kin8nm.md`; ver Capítulo 4). A execução duplicada acidental que o episódio produziu reproduziu o pipeline de ponta a ponta com resultados idênticos — uma verificação involuntária, e por isso valiosa, de reprodutibilidade exata.

7.3 Método

7.3.1 Teachers: um distribucional, um pontual — por verificação, não por suposição

O **TabPFN v2.5** (HOLLMANN et al., 2025; GRINSZTAJN et al., 2025) é o teacher distribucional: sua API nativa devolve quantis arbitrários da distribuição preditiva (a cabeça de *bar distribution*: um histograma discretizado sobre a faixa do alvo), dos quais extraímos uma grade de 19 níveis ($\tau = 0,05, 0,10, \dots, 0,95$). Usamos a v2.5, e não os lançamentos mais recentes TabPFN-3/3.5 (GRINSZTAJN et al., 2026), por comparabilidade com a versão fixada no benchmark do Capítulo 5 e por operação verificada na GPU de 16 GB do estudo; nada no método depende da versão.

O **TabFM** (Google Research, 2026) é um teacher exclusivamente pontual, e esse é um resultado, não uma premissa. Verificamos *arquiteturalmente* que sua cabeça de regressão decodifica um único escalar — verificação feita sobre o código em julho de 2026 e desde então

confirmada em fonte primária pelo relatório técnico oficial (KONG et al., 2026), ainda não revisado por pares — e *empiricamente* que nenhuma distribuição utilizável pode ser improvisada a partir dele: a dispersão de seu ensemble de 8 membros, usada como distribuição preditiva no `california_housing`, produz CRPS 0,524 contra 0,069 do teacher TabPFN, com cobertura de 16,3% a nominal de 80% (`results/distillation/tabfm_spread.csv`). Ambos os teachers operam com ensemble de inferência de 8 membros e contexto limitado a 50 mil linhas — as mesmas políticas do benchmark; para o TabFM, 8 membros mediram-se equivalentes em acurácia ao default de 32 da biblioteca, a um quarto do custo, nos nossos conjuntos.

7.3.2 Rotulagem out-of-fold e famílias de alunos

Os alvos do teacher para cada linha do pool de treino vêm de um esquema *out-of-fold* (OOF) com $K=5$: o teacher condicionado em 4/5 do pool rotula o quinto retido, de modo que nenhuma linha é rotulada por um teacher que a tenha em contexto. Os rótulos são cacheados uma única vez por par (conjunto, teacher) e reutilizados por todas as variantes de aluno — o custo dominante do pipeline é pago uma vez. Todos os alunos herdam os hiperparâmetros tunados do baseline correspondente no benchmark: a capacidade fica fixa e *apenas o alvo de treino muda*, isolando o efeito da destilação de qualquer efeito de tuning. São três famílias:

- **XGBoost ponto** (CHEN; GUESTRIN, 2016): treinado nos rótulos verdadeiros (controle), na média OOF do teacher (*soft*) ou numa mistura 0,8/0,2;
- **XGBoost multiquantil**: a variante de controle usa o objetivo *pinball* nativo (KONKER; BASSETT, 1978) nos rótulos verdadeiros; a variante destilada ajusta as 19 curvas de quantis do teacher como regressão multissaída, com cruzamentos de quantis reparados por ordenação por linha;
- **MLP-quantil**: o corpo do MLP do benchmark com cabeça de 19 saídas; *pinball* nos rótulos (controle) ou erro quadrático nas curvas do teacher (destilado) — simétrico ao par XGBoost, para testar se a família do aluno importa.

A Figura 7.1 resume o pipeline e o papel de cada variante.

7.3.3 Métricas

Para a qualidade pontual, RMSE e MAE. Para a qualidade distribucional, o **CRPS** (*continuous ranked probability score* (GNEITING; RAFTERY, 2007): a regra de pontuação própria que generaliza o erro absoluto de predições pontuais para distribuições preditivas completas; menor é melhor), estimado como duas vezes a média das perdas *pinball* sobre a grade de 19 quantis (GNEITING; RANJAN, 2011) — o estimador de grade padrão na prática de previsão probabilística. Validamos esse estimador contra a forma fechada gaussiana: ele carrega uma




Figura 7.1: **O pipeline de destilação: o teacher rotula o pool fora de dobra, e alunos de capacidade idêntica diferem apenas no alvo de treino.** O teacher rotula cada linha do pool *out-of-fold* ($K=5$: condicionado em 4/5 do pool, rotula o quinto retido), produzindo, em cache, uma média e 19 curvas de quantis por linha. Os alunos compartilham a capacidade tunada do benchmark e diferem somente no alvo: as variantes de rótulos verdadeiros (*hard*) são os controles que toda variante destilada precisa superar. Todos os sistemas são avaliados no mesmo hold-out intocado de 20%. Diagrama portado do artigo AI-2 (`latex/ai2/main.tex`).

sobre-estimativa multiplicativa quase constante de $\sim 4\text{--}5\%$, aproximadamente independente de localização e escala nos cenários testados, de modo que todas as comparações internas e razões de retenção ficam preservadas — mas os valores absolutos de CRPS não devem ser comparados aos de outros trabalhos. Para calibração, PICP80/90 (a fração dos alvos de teste dentro do intervalo nominal de 80%/90%) com as larguras dos intervalos. A métrica-síntese é a **retenção do gap de CRPS**,

$$\text{ret} = \frac{\text{CRPS}_{\text{hard}} - \text{CRPS}_{\text{soft}}}{\text{CRPS}_{\text{hard}} - \text{CRPS}_{\text{teacher}}}, \quad (7.1)$$

em que 1 significa que o aluno destilado recupera toda a vantagem do teacher sobre o seu próprio controle de rótulos verdadeiros, valores negativos significam que a destilação prejudicou, e valores acima de 1 caracterizam o efeito *born-again* (BREIMAN; SHANG, 1996; VIDAL; SCHIFFER, 2020): o aluno supera o próprio teacher. A latência é medida em $\mu\text{s}/\text{linha}$ no hold-out do benchmark (mediana de 5 passadas para os alunos; passada única cronometrada para os teachers, cujo custo por passada é de minutos).

7.3.4 Conjuntos de dados e infraestrutura

O estudo usa os cinco conjuntos de regressão do benchmark (`wine_quality`, `california_housing`, `superconduct`, `kin8nm`, `year_prediction`; pools de 5,2 mil a 80 mil linhas) mais o **pool elegível completo de quinze conjuntos** da suíte OpenML-CTR23 (FISCHER; FEURER; BISCHL, 2023), sob restrições verificadas e fixadas por regra

antes de qualquer resultado: 3 mil a 100 mil linhas, ids de versão fixados, e dois conjuntos da suíte excluídos por vazamento de alvo descoberto na verificação (o alvo é soma de atributos em `brazilian_houses` e `wave_energy`). Os splits são idênticos aos do benchmark — hold-out fixo de 20% (semente 42) que nenhuma etapa de seleção jamais observa — com três sementes de aluno em todo o estudo. O hardware é a mesma RTX 5080 (16 GB) dos capítulos anteriores; os tetos de VRAM são tratados como medições, não como incômodos, e reaparecem como achado na Seção 7.6.

7.4 A destilação pontual é refutada — com qualquer teacher

O primeiro resultado é o negativo que o pré-registro se comprometeu a reportar. Nos 20 conjuntos, o aluno pontual treinado nas médias do teacher supera o seu controle de rótulos verdadeiros em apenas 4; H1 é refutada já nos cinco conjuntos centrais. A objeção natural — “o teacher não era forte o suficiente” — foi testada diretamente, replicando o experimento com o TabFM, cujo gap de âncora (a vantagem de RMSE do teacher sobre o controle compartilhado, o denominador da retenção) é quase $6\times$ o do TabPFN no `california_housing`: 0,028 contra 0,005 de RMSE. O quadro não muda: somente as duas células *soft* do `california` superam o controle, com melhor retenção intra-pipeline de 0,11 (`california/misto`), e as oito células restantes ficam no nível do controle ou abaixo. Em pool completo, um GBDT tunado extrai dos rótulos brutos tanta acurácia pontual quanto das opiniões do teacher sobre eles.

Surpreendentemente, um resquício de ganho aparecia nos experimentos exploratórios menores — e o contraste entre execuções *smoke* e piloto sugeriu a hipótese de que o ganho pontual é um fenômeno de poucos dados. Investigamos com uma varredura de tamanho de pool (caps de 800, 2.000 e 8.000 linhas): há um ganho genuíno de poucos dados no `wine_quality` ($\Delta = +0,026$ em $n=800$), que desaparece a partir de $n=2.000$ e *não* replica no `california_housing`. Atribuímos o resquício, portanto, a um moderador de poucos dados dependente do conjunto, e o reportamos como observação, não como efeito geral.

Essa varredura é também a chave da reconciliação com a colisão parcial da Seção 7.1.2: JEONG et al. (2026) reportam ganhos de destilação pontual em regressão com teachers mais novos (TabPFN v3 e TabICLv2), transferência por erro quadrático e avaliação apenas de RMSE, sob protocolo e suítes distintos. Nossa varredura isola exatamente o regime em que tais ganhos aparecem, e o nosso negativo é escopado com precisão: tamanhos de pool realistas (3 mil a 100 mil linhas), capacidade do aluno fixada pelo tuning do benchmark. As duas leituras são compatíveis; a nossa delimita onde a deles deixa de valer.

Achado 7.1. A destilação pontual falha em escala de pool realista, independentemente do teacher. O aluno pontual destilado supera o controle de rótulos verdadeiros em apenas 4 de 20 conjuntos; a replicação com um teacher quase $6\times$ mais forte (gap de âncora 0,028 vs. 0,005 de RMSE no `california_housing`) não altera o quadro, e a varredura de pool mostra que

o ganho residual é um fenômeno de poucos dados ($n \leq 800$) em alguns conjuntos apenas. H1 é refutada; o que o teacher sabe sobre a *média* o aluno aprende sozinho dos dados.

7.5 A destilação distribucional funciona — onde o teacher tem vantagem

Transferir as curvas de quantis do teacher — e não sua média — muda o desfecho. A Tabela 7.1 apresenta o resultado central do capítulo sobre o pool completo de 20 conjuntos: para cada um, a retenção do gap de CRPS (Eq. 7.1), a vantagem absoluta do teacher sobre o controle e a melhoria absoluta do aluno destilado, todas em unidades do alvo.

Tabela 7.1: Retenção do gap de CRPS do aluno multiquantil destilado nos 20 conjuntos (média de 3 sementes). n é o tamanho do pool de treino após o hold-out de 20%; a vantagem do teacher é $\text{CRPS}_{\text{hard}} - \text{CRPS}_{\text{teacher}}$ e $\Delta\text{CRPS} = \text{CRPS}_{\text{hard}} - \text{CRPS}_{\text{soft}}$ (melhoria absoluta do aluno destilado sobre o controle de rótulos verdadeiros), ambas em unidades do alvo — a retenção é a razão entre elas, instável quando a vantagem é próxima de zero. Positiva em 16/20; mediana +0,19. `diamonds_real` é o verdadeiro conjunto `diamonds` do OpenML, incluído quando a errata de rotulagem descrita no Capítulo 4 foi retificada. Fonte: `results/distillation/paper_retention.csv`.

Conjunto	Origem	n	Retenção	Vant. teacher	ΔCRPS
pumadyn32nh	CTR23	6.553	+1,057	0,001	+0,0006
california_housing	núcleo	16.507	+0,644	0,111	+0,072
abalone	CTR23	3.341	+0,595	0,095	+0,056
fps_benchmark	CTR23	19.699	+0,523	0,152	+0,080
cpu_activity	CTR23	6.553	+0,500	0,233	+0,117
cps88wages	CTR23	22.524	+0,465	0,345	+0,160
year_prediction	núcleo	80.000	+0,419	0,311	+0,130
superconduct	núcleo	31.715	+0,255	0,006	+0,0015
sarcos	CTR23	39.146	+0,225	0,474	+0,107
kings_county	CTR23	17.290	+0,213	7.253,4	+1.547
grid_stability	CTR23	8.000	+0,170	0,003	+0,0004
kin8nm	núcleo	6.553	+0,128	0,030	+0,0039
physiochemical_protein	CTR23	36.584	+0,086	0,573	+0,049
video_transcoding	CTR23	55.027	+0,086	0,092	+0,0079
space_ga	CTR23	2.485	+0,078	0,011	+0,0009
miami_housing	CTR23	11.145	+0,016	4.117,4	+67,7
health_insurance	CTR23	17.817	-0,255	0,150	-0,038
diamonds_real	CTR23	43.152	-0,315	9,422	-2,97
wine_quality	núcleo	5.197	-0,970	0,039	-0,037
fifa	CTR23	15.342	-1,287	42,96	-55,3

A leitura agregada: a retenção é positiva em **16 de 20** conjuntos, com mediana +0,19, máximo +1,06 (pumadyn32nh — um aluno *born-again* que supera o próprio teacher) e sequência de sucessos grandes em `california_housing` (+0,64), `abalone` (+0,59),

`fps_benchmark` (+0,52) e `cpu_activity` (+0,50). Os dois instrumentos frequentistas rejeitam a hipótese nula ao nível de 5% (teste de sinal unilateral $p = 0,006$; Wilcoxon $p = 0,045$) e o teste bayesiano de postos sinalizados (BENAVOLI et al., 2017) coloca 0,70 de massa posterior em retenção positiva com região de equivalência prática (ROPE) de $\pm 0,05$ — estável em 0,63–0,71 na varredura de ROPE de 0,02 a 0,10.

A honestidade da leitura exige três ressalvas, e elas estão embutidas na própria tabela. Primeiro, a retenção é uma *razão*, e fica instável quando a vantagem absoluta do teacher é pequena: o caso *born-again* do `pumadyn32nh` cavalga uma vantagem de apenas $\sim 0,001$ de CRPS (e `superconduct` e `grid_stability` são análogos) — por isso a tabela reporta a melhoria absoluta ao lado da razão, e por isso a manchete do capítulo se apoia no **teste de sinal e na mediana**, que são livres de escala, e nos sucessos de vantagem grande (`california_housing` +0,072 de CRPS, `cps88wages` +0,160, `year_prediction` +0,130). Segundo, nenhuma retenção é exatamente zero, mas positivos quase nulos como o `miami_housing` (+0,016) contam como sucesso sob o teste de sinal — a varredura de ROPE acima delimita o efeito de tratá-los como equivalências. Terceiro, as quatro falhas são diagnósticáveis, e o diagnóstico alimenta a regra de decisão da Seção 7.9: no `wine_quality`, o teacher fica atrás do baseline tunado em RMSE (o eixo do gate pré-registrado) e sua pequena vantagem de CRPS (+0,04) inverte na transferência; `fifa`, `diamonds_real` e `health_insurance` são alvos de escala de preço com cauda pesada, para os quais a Seção 7.9 mostra que a vantagem aparente do teacher é, em grande parte, reproduzível por uma transformação logarítmica.

A qualidade transferida não é só o CRPS agregado: a calibração acompanha — e, num caso, excede — a transferência, como as curvas de confiabilidade da Seção 7.7 (Figura 7.3) mostram em detalhe.

Achado 7.2. A destilação distribucional retém mediana de 19% da vantagem de CRPS do teacher, positiva em 16 de 20 conjuntos. A transferência das 19 curvas de quantis para um aluno multiquantil é positiva em 16/20 conjuntos (teste de sinal $p = 0,006$; Wilcoxon $p = 0,045$; massa posterior bayesiana 0,70 em ROPE $\pm 0,05$), com máximo de +1,06 — um aluno *born-again*, com a ressalva de que esse caso repousa sobre vantagem absoluta de $\sim 0,001$ de CRPS — a latências de microssegundos. As quatro falhas têm diagnóstico comum e verificável, convertido em regra de decisão na Seção 7.9.

7.6 A fronteira de serving: destilar, comprimir ou reduzir ensemble

A retenção diz o que o aluno preserva; não diz quando ele é a escolha certa contra as alternativas de engenharia que um praticante tem à mão. Para responder H3, medimos acurácia e latência de *todas* as estratégias nos mesmos hold-outs, em três conjuntos de vantagem positiva:

o TabPFN com contexto subamostrado para {1 mil, 5 mil, 10 mil, 25 mil, completo} (o braço “comprimir contexto”, na variante simples de subamostragem — CRUMB (HEREDGE et al., 2026) é o método representativo desse braço na literatura); o TabPFN com 1/4/8 membros de ensemble (o braço “reduzir ensemble”); os alunos destilados e de controle (o braço “destilar”); e o TabFM de contexto completo como âncora de acurácia. A Figura 7.2 apresenta a fronteira resultante.




Figura 7.2: No plano distribucional, o aluno destilado (estrela) é o sistema CRPS-ótimo abaixo da configuração competitiva mais barata do teacher nos dois conjuntos de vantagem grande; no `kin8nm`, de vantagem pequena, reduzir o ensemble já basta. Fronteira destilar × comprimir × reduzir ensemble em três conjuntos de vantagem positiva (colunas): RMSE (linha superior, acurácia pontual) e CRPS (linha inferior, acurácia distribucional) contra latência de inferência em $\mu\text{s}/\text{linha}$. Como ler: o eixo horizontal é *logarítmico* — distâncias horizontais iguais são fatores multiplicativos iguais — e melhor é abaixo e à esquerda. Círculos azuis: teacher TabPFN com contexto subamostrado (1 mil a completo); triângulos verdes: teacher com ensemble reduzido (1 e 4 membros); estrela rosa: aluno-quantil destilado; quadrado laranja e losango verde: alunos de controle (ponto e quantil, rótulos verdadeiros); cruz laranja: TabFM de contexto completo, a âncora de acurácia (4.905–394.301 $\mu\text{s}/\text{linha}$). O que importa é a distância vertical entre a estrela e a curva do teacher na latência medida mais próxima — discutida no texto. Rótulos internos em inglês, conforme a figura do artigo AI-2. Fonte: `results/distillation/pareto.csv`.

A figura separa três regimes. No plano **pontual** (linha superior), o aluno de controle com rótulos verdadeiros já ocupa o regime rápido (2,6–5,3 $\mu\text{s}/\text{linha}$) — é a refutação de H1 tornada visível: não há nada que a destilação pontual pudesse acrescentar ali. No plano **distribucional** (linha inferior), abaixo de ~ 250 $\mu\text{s}/\text{linha}$ no `california_housing` e de ~ 1.300 $\mu\text{s}/\text{linha}$ no `year_prediction`, os alunos estão sozinhos, e o destilado é o CRPS-ótimo entre eles:

CRPS 0,109 a 99 μ s/linha onde a configuração mais barata do teacher precisa de 245 μ s/linha para 0,094 — $2,5\times$ a latência do aluno — no `california_housing`; e CRPS 4,43 a 169 μ s/linha onde a configuração mais barata do teacher que o supera custa 4.576 μ s/linha — $27\times$ a latência — no `year_prediction`.

O terceiro conjunto inverte o quadro — e a inversão é instrutiva. No `kin8nm`, a vantagem do teacher é pequena (+0,030 de CRPS) e um TabPFN de *um único membro* entrega CRPS 0,040 a 150 μ s/linha — essencialmente a latência do aluno. Ali, a alavanca certa é a redução de ensemble, não a destilação: é a contraparte, no nível da fronteira, da regra de decisão da Seção 7.9 — quando a vantagem do teacher é pequena, o menu de engenharia barata resolve antes que a destilação entre em cena.

Dois achados colaterais têm valor independente. Primeiro, reduzir o ensemble do TabPFN de 8 para 1 membro *melhorou* o RMSE no `california_housing` (0,2521 contra 0,2555) a um sétimo da latência — a redução de ensemble é uma primeira alavanca subestimada, às vezes gratuita. Segundo, a última duplicação de contexto (25 mil $\rightarrow$ 50 mil) no `year_prediction` exige o modo de economia de memória da biblioteca na GPU de 16 GB e custa $3,3\times$ a latência (148,6 contra 45,1 ms/linha) por um ganho de RMSE de 0,05: em GPUs de porte comum, o teacher de contexto completo não se paga.

Achado 7.3. *Onde a vantagem do teacher é grande, o aluno destilado é o sistema distribucional CRPS-ótimo abaixo da configuração competitiva mais barata do teacher; onde é pequena, reduzir o ensemble basta.* Na fronteira medida de ponta a ponta, a configuração mais barata do teacher que supera o aluno destilado custa $2,5\times$ a latência dele no `california_housing` e $27\times$ no `year_prediction`; no `kin8nm`, de vantagem pequena, um teacher de um membro já opera à latência do aluno. Colaterais: 1 membro do TabPFN $\approx$ 8 membros a 1/7 da latência, e a última duplicação de contexto é desproporcionalmente cara em GPUs de 16 GB.

7.7 Por que rotular out-of-fold: calibração, não acurácia

A literatura de classificação (TANNA et al., 2026a) estabelece que rótulos do teacher *in-sample* colapsam em direção ao one-hot e devem ser evitados. A regressão, mostramos, se comporta de outro modo — e a diferença só aparece quando o confundidor é removido. Nossa ablação de três regimes compara: OOF (contexto de 80%, sem vazamento), *in-sample* com o *mesmo* contexto de 80% (com vazamento, contexto idêntico) e *in-sample* com contexto completo. O desenho desconfundre vazamento de tamanho de contexto — exatamente o que a comparação usual OOF vs. *in-sample* não separa.

O resultado: o vazamento, isolado, *não* degrada acurácia — o RMSE até melhora nos quatro conjuntos testados, e o CRPS em três — e o tamanho do contexto contribui pouco (embora, no `wine_quality`, custe 5,9 p.p. adicionais de cobertura). O dano concentra-se na **cobertura de intervalos**: a contexto idêntico, alunos rotulados *in-sample* perdem de 0,5 a

5,1 p.p. de PICP80 em todos os quatro conjuntos — artefato `ablation_insample.csv` em `results/distillation/`. A mecânica é legível: o teacher é superconfiante nas linhas que tem em contexto, e essa superconfiança — invisível às métricas de acurácia — transfere-se ao aluno como intervalos estreitos demais. Em regressão, a rotulagem OOF é uma salvaguarda de *calibração*, não de acurácia — um refinamento desconfundido do achado de classificação.

A Figura 7.3 fecha o eixo da calibração com as curvas de confiabilidade dos sistemas distribucionais — prometidas na Seção 7.5.




Figura 7.3: **O aluno destilado é o sistema mais próximo da diagonal nos dois painéis — no `california_housing`, mais bem calibrado que o controle e que o próprio teacher.** Confiabilidade dos quantis no hold-out: para cada nível nominal τ (eixo horizontal), a fração empírica de alvos abaixo do quantil τ predito (eixo vertical). Como ler: a diagonal tracejada é a calibração perfeita; curvas acima dela sobre-cobrem, abaixo dela sub-cobrem. No `california_housing` (esquerda), o controle de rótulos verdadeiros (losangos verdes) satura em sobrecobertura extrema e o teacher (círculos azuis) exibe a forma em S de caudas mal calibradas; o aluno destilado (estrelas rosas) é o mais próximo da diagonal. No `cpu_activity` (direita), os três sistemas são bem calibrados e o destilado permanece competitivo. A transferência de curvas com reparo por ordenação atua como regularizador de calibração, não como cópia. Rótulos internos em inglês, conforme a figura do artigo AI-2. Fonte: `scripts/plot_calibration.py`.

Achado 7.4. A rotulagem out-of-fold protege a calibração do aluno, não sua acurácia. Com contexto idêntico, rótulos *in-sample* não degradam RMSE nem CRPS, mas erodem a cobertura de intervalos em 0,5 a 5,1 p.p. de PICP80 nos quatro conjuntos testados: a superconfiança em contexto do teacher transfere-se ao aluno. E a destilação chega a *melhorar* a calibração: no `california_housing`, o aluno destilado é mais bem calibrado que o controle e que o próprio teacher.

7.8 E1 — baselines distribucionais clássicos: o nativo forte posto à prova

O artigo AI-2 declara, entre suas limitações, que baselines distribucionais clássicos fora das famílias comparadas — NGBoost (DUAN et al., 2020) e florestas aleatórias quantílicas (QRF) (MEINSHAUSEN, 2006) — não foram incluídos: os alunos-quantil de rótulos verdadeiros fazem o papel de baseline distribucional nativo *dentro* das famílias testadas. A limitação esconde um possível confundidor: se um aluno nativo clássico forte fechasse sozinho o gap que atribuímos à destilação, a contribuição inteira estaria superdimensionada. Esta seção fecha essa lacuna com o experimento E1, pré-registrado em `docs/desenho-melhorias-finais.md` em 05/10/2026, *antes* da execução, conforme o contrato de conduta do programa.

7.8.1 Desenho pré-registrado

Duas hipóteses falsificáveis foram fixadas, com gates de interpretação registrados para *ambos* os desfechos:

- **H-B1:** na maioria dos 20 conjuntos, o CRPS do aluno destilado é menor ou igual ao do melhor baseline clássico (teste de sinal unilateral; $\alpha = 0,05$);
- **H-B2:** os baselines clássicos não alteram a leitura da fronteira — suas latências são de microssegundos (o tier dos alunos), logo competem com o aluno destilado em acurácia, não em custo.

Os gates: se H-B1 confirmasse, a regra de decisão ganharia a nota “um nativo clássico forte não substitui a destilação onde a vantagem do teacher é grande”; se refutasse, *todas* as claims de vantagem do aluno destilado seriam reescopadas nos artigos e nesta dissertação, com o resultado negativo reportado com a mesma proeminência. O protocolo é idêntico ao do restante do capítulo — mesmos 20 conjuntos, mesmos splits (hold-out de 20%, semente 42), 3 sementes, o mesmo estimador de CRPS sobre a grade de 19 quantis — com uma assimetria declarada no próprio pré-registro: o NGBoost (distribuição Normal, parada antecipada em validação de 10% do pool) e a QRF (quantis nativos nas mesmas 19 τ) rodam com hiperparâmetros default documentados, *sem* tuning específico, de modo que a interpretação se limita a “default forte”. Um adendo datado do mesmo dia registra a única decisão de execução: o pacote da QRF não aceita valores faltantes (presentes em 3 conjuntos da CTR23; o NGBoost os trata nativamente), e adotou-se imputação por mediana ajustada no pool e aplicada ao teste, somente no caminho da QRF — política simples, sem vazamento, declarada.

7.8.2 Resultados: 17 de 20 para o aluno destilado — com três reverses instrutivos

Todos os números a seguir foram recomputados do artefato de análise `baselines_analysis.csv` (em `results/distillation/`), que o script `analyze_baselines.py` agrega do artefato bruto `classical_baselines.csv`. **H-B1 é confirmada:** o aluno destilado tem CRPS menor ou igual ao do melhor baseline clássico em **17 dos 20** conjuntos (teste de sinal unilateral $p = 0,0013$; Wilcoxon unilateral $p = 0,0008$). O melhor clássico é a QRF em 19 dos 20 conjuntos (o NGBoost só a supera no `cps88wages`). **H-B2 também:** as latências medianas por conjunto dos clássicos ficam entre 4,1 e 31,9 $\mu\text{s}/\text{linha}$ (QRF 4,1–21,4; NGBoost 12,2–31,9) — o tier dos alunos, três a quatro ordens de magnitude abaixo dos teachers. Os clássicos competem com o aluno destilado em acurácia, nunca em custo, e a leitura da fronteira da Seção 7.6 permanece intacta.

O gate pré-fixado exige a leitura honesta dos três reverses, e a Tabela 7.2 os expõe por extenso.

Tabela 7.2: Os três conjuntos (de 20) em que o melhor baseline clássico vence o aluno destilado em CRPS (média de 3 sementes; menor é melhor). Convenção: **negrito** = melhor sistema da linha entre os três sistemas rápidos e o teacher. No `wine_quality`, a QRF supera inclusive o teacher — o único conjunto, em 20, onde isso ocorre. Fonte: `results/distillation/baselines_analysis.csv` (valores recomputados do artefato em 05/10/2026).

Conjunto	Aluno destilado	Controle hard	QRF	Teacher
<code>california_housing</code>	0,109	0,180	0,084	0,069
<code>physiochemical_protein</code>	1,736	1,785	1,528	1,212
<code>wine_quality</code>	0,365	0,328	0,279	0,289

Três leituras emergem. Primeiro, os reverses não são aleatórios: o `wine_quality` é precisamente o conjunto em que o gate pré-registrado já desaconselhava destilar (o teacher atrás do baseline em RMSE; retenção $-0,97$ na Tabela 7.1), e lá a QRF default bate *inclusive o teacher* (CRPS 0,279 contra 0,289) — a demonstração mais nítida, em todo o estudo, de que o passo “teste um aluno nativo forte” da regra de decisão não é retórico. Segundo, mesmo nos dois outros reverses, a destilação continua funcionando no seu próprio recorte (retenções $+0,64$ e $+0,09$ sobre o controle da mesma família); o que o E1 acrescenta é que, nesses conjuntos, uma família nativa diferente chega mais longe sem teacher algum. Terceiro, o clássico vence o *controle* de rótulos verdadeiros (o XGBoost-pinball) em apenas 5 dos 20 conjuntos: o controle usado em todo o capítulo segue sendo um baseline representativo, e a vantagem do aluno destilado não é um artefato de controle fraco.

O saldo interpretativo segue o gate pré-fixado: a vantagem da destilação **não é redundante** com nativos distribucionais fortes em configuração default — mas a regra de decisão ganha uma instância concreta e um complemento. O passo “teste um aluno-quantil nativo forte”

agora nomeia a QRF explicitamente: ela custa segundos de treino, serve a microssegundos e, numa minoria previsível de conjuntos, resolve o problema antes que qualquer teacher precise ser carregado.

Achado 7.5. Um nativo distribucional clássico forte não substitui a destilação — mas deve ser tentado antes. O aluno destilado vence o melhor entre NGBoost e QRF em 17 de 20 conjuntos (teste de sinal $p = 0,0013$; Wilcoxon $p = 0,0008$), a latências do mesmo tier (clássicos em 4–32 μ s/linha). Os três reverses são diagnosticáveis — no `wine_quality`, onde o gate já desaconselhava destilar, a QRF default supera até o teacher — e convertem o passo “nativo forte” da regra de decisão em instrução concreta: tente a QRF primeiro; custa segundos.

7.9 Quando destilar: duas hipóteses refutadas e a regra de decisão

As condições de valor da destilação emergem de duas hipóteses testadas e refutadas — e é da refutação que sai a regra prática.

A família do aluno importa? Muito. O objetivo *pinball* do XGBoost é um aprendiz distribucional fraco, e a destilação o conserta de forma consistente — esse é, em parte, o espaço que ela ocupa. Um aluno MLP-quantil de rótulos verdadeiros, por contraste, iguala o XGBoost destilado *sem teacher algum* em conjuntos pequenos e numéricos (CRPS 0,110 contra 0,109 no `california_housing`; 0,047 contra 0,064 no `kin8nm`) — mas colapsa no `year_prediction` (CRPS 9,66, com sobrecobertura quase total), onde a destilação o resgata (CRPS $\rightarrow 4,91$). Nenhuma família de aluno domina; o que a destilação oferece é robustez entre regimes (`results/distillation/mlp_students.csv`).

A cauda pesada é o moderador de falha? Não — e a refutação é mais informativa que a hipótese. Re-executamos teacher e alunos sob $y' = \log(1 + y)$ nos três conjuntos de falha em escala de preço, mais dois controles positivos. A transformação *não* resgata as falhas (`fifa` persiste em $-1,69$); o que ela faz é colapsar a própria vantagem do teacher — os gaps de CRPS encolhem para 0,004–0,025 em espaço logarítmico — e encolher também os sucessos. A conclusão inverte a hipótese: boa parte da vantagem distribucional do foundation model sobre alvos de escala de preço é tratamento de escala, reproduzível de graça por uma transformação de uma linha (`results/distillation/ablation_logtarget.csv`).

Das duas refutações, do E1 e da fronteira, a regra de decisão final — a forma operacional da resposta à QP3:

Antes de destilar: (i) aplique transformações baratas de alvo (um log em alvos de escala de preço reproduz de graça boa parte da vantagem do teacher); (ii) teste um aluno distribucional nativo forte — uma QRF default custa segundos, e um MLP-quantil cobre os conjuntos pequenos e numéricos. Destile

quando uma vantagem genuína do teacher persistir após ambos — uma única rotulagem OOF, de custo de minutos, mede essa vantagem diretamente. Onde ela é grande, a destilação é a única estratégia medida que carrega parte dela para baixo da configuração competitiva mais barata do teacher; onde é pequena, a simples redução de ensemble pode encerrar o caso.

Cada cláusula da regra é um resultado deste capítulo: a cláusula (i) é a ablação do log; a (ii) é o aluno MLP mais o E1; a verificação por OOF é a Seção 7.7; e as duas pontas do veredito são a fronteira da Seção 7.6 — os casos `california_housing/year_prediction` de um lado e o `kin8nm` do outro.

Achado 7.6. A regra de decisão: transforme, teste um nativo forte, e destile somente a vantagem que sobrar — ela é verificável em minutos. As falhas da destilação distribucional não são aleatórias: concentram-se onde o teacher não tem vantagem genuína (gate de RMSE) ou onde sua vantagem é reproduzível por transformação de alvo. A pré-condição é mensurável por uma rotulagem OOF barata, e o E1 acrescenta o degrau intermediário: a QRF como nativo forte de custo desprezível.

7.10 Discussão, limitações e síntese

7.10.1 O que a destilação transfere — e o que isso diz sobre os teachers

O padrão consistente ao longo de 20 conjuntos, dois teachers, duas famílias de aluno e três ablações é que a informação *pontual* satura a partir dos rótulos brutos — um GBDT tunado não precisa das opiniões do teacher sobre a média — enquanto a informação *distribucional* (estrutura de quantis, largura calibrada) é portada pelo teacher e transferível. Não a média: a **forma**. E a forma é exatamente o componente que um aluno de rótulos pontuais não pode aprender do dado bruto na mesma medida, e o componente mais caro de servir em contexto.

O corolário institucional é direto: líder pontual não é líder distribucional. O TabFM vence todas as tabelas de acurácia do Capítulo 5 e não contribui nada para o eixo distribucional — a cabeça de regressão é arquiteturalmente pontual (verificação confirmada pelo relatório técnico oficial (KONG et al., 2026)) e a dispersão de seu ensemble é mensuravelmente inútil como estimativa de incerteza (cobertura de 16,3% a nominal de 80%). Entre os teachers medidos, a cabeça distribucional do TabPFN é o ativo arquitetural decisivo; os benchmarks independentes que hoje avaliam foundation models como estimadores de densidade condicional (IZBICKI; RODRIGUES, 2026; LANDSGESELL; KNOLL; WENZEL, 2026) apontam na mesma direção, e nossos resultados quantificam o que a ausência dessa cabeça custa. Para o praticante com GPU de 16 GB, a ordem das alavancas medidas é: reduzir o ensemble primeiro (às vezes gratuito), comprimir contexto depois, reservar o teacher completo para processamento em lote

— e, quando predições distribucionais precisam ser servidas abaixo da configuração competitiva mais barata do teacher, o aluno destilado é o único ocupante medido desse regime. A rota complementar que não medimos — calibração conformal pós-hoc do próprio teacher (PARK; PARK; CHANG, 2026) — entrega intervalos calibrados sem aluno rápido, mas não ataca a latência; a quantização FP8 da atenção (KÜBLER et al., 2026) é uma quarta alavanca emergente de serving, também não medida aqui.

7.10.2 Limitações

Na mesma moeda dos resultados. **Magnitudes heterogêneas:** 20 conjuntos dão significância a 5% nos dois instrumentos, mas a retenção varia de $-1,3$ a $+1,1$ e o posterior bayesiano deixa $\sim 25\%$ de massa em retenção negativa — o entregável honesto é a regra de decisão da Seção 7.9, não uma claim universal. **Capacidade herdada:** os alunos usam os hiperparâmetros tunados do benchmark, sem re-tuning por alvo de destilação. **Estimador de CRPS:** a grade de 19 quantis sobre-estima o CRPS exato em $\sim 4\text{--}5\%$ quase constantes — comparações internas preservadas, valores absolutos não comparáveis entre trabalhos. **Datação do TabFM:** os resultados referem-se à versão fixada v1.0.1 (julho de 2026); o relatório técnico oficial (KONG et al., 2026) apareceu no fim de setembro de 2026 e permanece sem revisão por pares. **Baselines clássicos:** a limitação declarada no artigo foi fechada pelo E1 desta dissertação, mas com o escopo registrado no pré-registro — NGBoost e QRF em configuração default documentada, sem tuning específico, com imputação por mediana no caminho da QRF; a interpretação é “default forte”, não “clássico tunado ao limite”. **Hardware:** medições em uma única GPU delimitam, não mapeiam, o espaço de hardware.

7.10.3 Síntese do capítulo

O capítulo delimita com precisão o espaço em que destilar foundation models tabulares para regressão funciona. O eixo pontual é um negativo robusto e independente do teacher: em pool realista, não há o que transferir. O eixo distribucional — o recorte sem trabalho público anterior — é positivo em 16 de 20 conjuntos (mediana de 19% de retenção do gap de CRPS, chegando ao *born-again*), a três ordens de magnitude menos latência, e sobrevive ao teste contra nativos clássicos fortes (17/20 no E1 pré-registrado). A fronteira de três estratégias localiza quando cada alavanca vence, a ablação OOF mostra que a salvaguarda certa protege calibração, e as três refutações — ponto, cauda pesada, redundância com clássicos — convertem-se numa regra de decisão cuja pré-condição se verifica em minutos. É a resposta da dissertação à QP3: o que o foundation model sabe e o baseline não aprende sozinho é a distribuição — e é isso que se destila.

Transição. Com este capítulo, as três perguntas de pesquisa têm resposta: o benchmark estabeleceu quem vence e a que custo (Capítulo 5), o arcabouço validado disse como escolher sob restrições (Capítulo 6), e a destilação distribucional mostrou como recuperar o líder dentro do orçamento de microssegundos — quando, e somente quando, há vantagem genuína a transferir. Resta consolidar: o Capítulo 8 reúne as contribuições, confronta cada pergunta de pesquisa com a evidência acumulada, declara as limitações e ameaças à validade do programa como um todo e aponta os trabalhos futuros que este estudo deixa armados.

8

Conclusão

Resumo do capítulo. Este capítulo encerra a dissertação em cinco movimentos: a recapitulação do arco argumentativo e a re-resposta explícita às três perguntas de pesquisa, cada uma confrontada com os números-síntese do capítulo que a respondeu (Seção 8.1); a lista numerada das contribuições, com o capítulo de origem e a natureza de cada uma — evidência, recorte ou regra —, incluindo os resultados negativos informativos (Seção 8.2); um *checklist* operacional de conselhos ao praticante, em que cada item rastreia a um resultado dos Capítulos 6 e 7 (Seção 8.3); as limitações e ameaças à validade do programa como um todo, organizadas por validade interna, externa e de construto (Seção 8.4); e os trabalhos futuros que a evidência acumulada deixa armados (Seção 8.5).

Material associado. As conclusões deste capítulo consolidam os dois trabalhos individuais do programa (AI-1 e AI-2, em `latex/ai1/` e `latex/ai2/` no repositório do projeto) e os dois experimentos complementares inéditos em relação a eles (E1 e E2, Seções 7.8 e 6.4), ambos pré-registrados em `docs/desenho-melhorias-finais.md`.

8.1 Considerações finais

Esta dissertação partiu da pergunta que organizou uma década de literatura sobre dados tabulares — “árvores ainda vencem?” — e terminou respondendo a uma pergunta diferente, porque a evidência coletada mostrou que a original expirou. O primeiro movimento do trabalho estabeleceu isso em duas etapas. Na geração de modelos anterior a 2026, a disputa de acurácia termina em empate positivo, não em vitória: sob protocolo uniforme com validação cruzada aninhada e *hold-out* intocado, 8 dos 10 modelos não-líderes do núcleo de 11 são praticamente equivalentes ao líder sob uma região de equivalência prática (ROPE) de $\pm 0,01$ de AUC (BENAVOLI et al., 2017), conclusão robusta à variação do limiar, e 80% da variância de *rank* é intrafamília ($\eta^2 = 0,20$) — o eixo “GBDT vs. aprendizado profundo” é uma abstração fraca para esses dados (Capítulo 5). Na etapa seguinte, a geração 2026 quebrou o empate pelo flanco que a controvérsia não previa: não foi o aprendizado profundo ajustado que alcançou as árvores,

foi o pré-treino que ultrapassou ambos. O TabFM, *zero-shot*, lidera o *rank* médio nas três tarefas e é o melhor modelo em 13 dos 18 conjuntos — ao preço de quatro a cinco ordens de magnitude em latência de serviço (43.262 contra 0,33 μ s/linha do XGBoost no protocolo padronizado).

Com o empate expirado, o custo virou o eixo da decisão — e o segundo movimento da dissertação deu a esse deslocamento forma validada. O roteamento aprendido por meta-atributos, a resposta clássica da literatura de seleção de algoritmos, não sobrevive à validação honesta no regime em que benchmarks reais operam: sob *leave-one-dataset-out* com $N=18$ conjuntos, a árvore de meta-atributos não supera o *baseline* de classe majoritária em nenhuma das duas gerações (taxa de acerto 0,11 contra 0,44 no estudo com 11 modelos; 0,72 contra 0,78 com 14). O que os dados sustentam é mais modesto e mais útil: uma política fixa — *foundation model* primeiro — com regret mediano zero na geração 2026, cercada por restrições verificáveis *a priori*. E o experimento E2, pré-registrado, quantificou a fragilidade dessa política ao custo: basta deslocar 10–20% do peso da acurácia para a latência para que a recomendação se inverta em favor dos GBDTs (Capítulo 6). A primeira pergunta do fluxograma de decisão — “o orçamento de latência comporta o *foundation model*?” — não é uma heurística decorativa: é a fronteira medida.

O terceiro movimento atacou o preço, e atacou-o seletivamente, porque a evidência mostrou que ele não é removível por inteiro. A destilação *pontual* — treinar um aluno rápido nas médias do professor — falha em escala de pool realista com qualquer um dos dois professores testados: o que o professor sabe sobre a média, um GBDT ajustado aprende sozinho dos rótulos brutos. O que o professor carrega e o aluno não aprende sozinho é a *forma* da distribuição preditiva — e é isso que se destila. A transferência das curvas de quantis do TabPFN para um aluno de microssegundos retém mediana de 19% da vantagem de CRPS do professor, positiva em 16 de 20 conjuntos (teste de sinal $p = 0,006$), sobrevive ao confronto com nativos distribucionais clássicos fortes (17 de 20 contra o melhor entre QRF e NGBoost, $p = 0,0013$, no experimento E1) e, onde a vantagem do professor é grande, é a única estratégia medida que a carrega para baixo da configuração competitiva mais barata do próprio professor (Capítulo 7). As falhas não são aleatórias: concentram-se onde não há vantagem genuína a transferir, e a pré-condição é verificável em minutos — o que converte o resultado em regra de decisão, não em promessa.

8.1.0.0.1 Re-respondendo as perguntas de pesquisa. As três perguntas enunciadas no Capítulo 1 recebem, ao final do percurso, respostas diretas.¹ **QP1** — *as famílias modernas de modelos tabulares diferem de forma praticamente relevante sob protocolo uniforme?* O Capítulo 5 responde em dois tempos: dentro da geração anterior a 2026, não — o topo é equivalência prática positivamente aferida (8/10 equivalentes sob ROPE $\pm 0,01$; sensibilidade 0,005/0,01/0,02 $\rightarrow$ 2/8/10), com 80% da variância de *rank* intrafamília; entre gerações, sim — o paradigma pré-treinado separa-se do pelotão (TabFM com *ranks* médios 2,7/1,0/1,2 nas

¹[VERIFICAR: alinhar a paráfrase das QPs abaixo com o enunciado final do Capítulo 1, em redação paralela a este capítulo; a formulação aqui segue a do Capítulo 4.]

três tarefas; TabPFN como vice consistente), sustentado pela consistência entre conjuntos e pelo instrumento bayesiano, não pelo *post-hoc* frequentista de baixo poder. **QP2** — *como a vantagem relativa varia com a estrutura do problema, e como usar essa variação para escolher?* As reversões condicionais são reais — o aprendizado profundo recente toma o topo multiclasse (descritivo, $N=3$), os GBDTs ganham vantagem sob desbalanceamento severo, o TabPFN domina o regime de poucos dados ($n \leq 4.000$), e o cruzamento GBDT $\leftrightarrow$ DL por tamanho é específico por conjunto —, mas o Capítulo 6 mostra que essa variação *não é roteável* por meta-atributos no regime de N pequeno: a forma validada de usá-la é um arcabouço de restrições verificáveis antes de qualquer treino (latência, limites arquiteturais, interpretabilidade), com a política “*foundation model* primeiro” como *default* regret-ótimo e o ponto de inversão por custo localizado pelo E2 entre $w=0,9$ e $w=0,8$ de peso na acurácia. **QP3** — *o líder caro pode ser recuperado dentro do orçamento de microssegundos?* O Capítulo 7 responde: parcialmente, e sob condições verificáveis — não a média (negativo robusto, 4/20), mas a distribuição (positivo, 16/20, mediana de 19% de retenção do gap de CRPS, com um caso *born-again*), com a rotulagem *out-of-fold* como salvaguarda de calibração (0,5–5,1 p.p. de PICP80) e uma regra prática — transformar o alvo, testar um nativo forte, destilar só a vantagem que sobrar — cuja pré-condição se mede com uma única rotulagem OOF de custo de minutos.

8.2 Contribuições

As contribuições são listadas com o capítulo de origem e a natureza de cada uma — *evidência* (resultado empírico sob protocolo declarado), *recorte* (delimitação verificada de lacuna) ou *regra* (prescrição operacional derivada da evidência). Os resultados negativos são listados com o mesmo estatuto dos positivos, conforme o contrato de conduta do programa (Capítulo 4).

1. **Benchmark multicritério neutro da geração 2026 (evidência; Capítulo 5).** 14 modelos $\times$ 18 conjuntos (250 das 252 células; duas exclusões estruturais), com validação cruzada aninhada, inferência frequentista e bayesiana com ROPE e análise de sensibilidade, e três eixos de custo sob o mesmo protocolo. Dele saem o empate positivo da geração anterior, a quebra pela geração 2026 e a primeira comparação neutra TabPFN $\times$ TabFM sob protocolo idêntico — enquadrada como replicação inter-laboratórios do paradigma, com versões fixadas e políticas espelhadas.
2. **Teste independente desfavorável da família Kolmogorov–Arnold (evidência negativa; Capítulo 5).** No primeiro confronto da família com a grade completa GBDT/DL/*foundation models* em protocolo multicritério — até onde alcançam as verificações datadas —, KAN e TabKAN terminam no último terço nas três tarefas (*ranks* 11,0/12,0/9,8 e 11,4/13,3/11,8), em linha com a literatura crítica (YU; YU; WANG, 2024; POETA et al., 2024) e contra as alegações dos proponentes; a contraparte registrada é que ambas são baratas de servir (2,3–3,1 μ s/linha) — o problema

é desempenho, não custo.

3. **Resultado negativo do roteamento por meta-atributos (evidência negativa; Capítulo 6).** Sob LODO com $N=18$, um roteador aprendido não supera o *baseline* de classe majoritária em nenhuma geração (0,11 vs. 0,44 com 11 modelos; 0,72 vs. 0,78 com 14) — corroborado por evidência independente contemporânea (HERRE et al., 2026). A consequência de desenho: o arcabouço não contém preditor de família vencedora.
4. **Arcabouço de decisão validado por regret (evidência + regra; Capítulo 6).** A política fixa “*foundation model* primeiro” é regret-ótima na métrica primária (regret mediano 0,000 na geração 2026 sob LODO), e o arcabouço final é um fluxograma de quatro restrições verificáveis *a priori* — deliberadamente modesto na forma, porque é essa a forma que os dados sustentam.
5. **Regret multicritério ponderado — E2 (evidência; Capítulo 6; inédito em relação ao AI-1).** O experimento pré-registrado que localiza o ponto de inversão da recomendação: “FM primeiro” só é ótima na mediana para $w \geq 0,9$ de peso na acurácia; com $w \leq 0,6$, “sempre-GBDT” tem regret mediano zero. É a justificativa quantitativa da arquitetura do fluxograma — a latência é a primeira pergunta porque é a que mais cedo muda a resposta.
6. **Destilação distribucional de *foundation models* tabulares (recorte + evidência; Capítulo 7).** O recorte — transferir curvas de quantis, avaliar por CRPS e cobertura — foi verificado como sem trabalho público anterior nas varreduras datadas de 13–20/07 e 04/10/2026. A evidência: retenção mediana de 19% do gap de CRPS, positiva em 16 de 20 conjuntos ($p = 0,006$; massa posterior bayesiana de 0,70 em retenção positiva), incluindo um aluno *born-again*, a latências de microssegundos.
7. **Refutação da destilação pontual em pool realista (evidência negativa; Capítulo 7).** O aluno pontual destilado supera o controle em apenas 4 de 20 conjuntos, com qualquer dos dois professores — inclusive um com gap de âncora quase $6\times$ maior —, e a varredura de tamanho de pool isola o moderador (ganho residual restrito a $n \leq 800$, dependente do conjunto), o que reconcilia o negativo com os ganhos pontuais contemporâneos de JEONG et al. (2026) delimitando onde eles deixam de valer.
8. **Fronteira de três estratégias de *serving* (evidência; Capítulo 7).** Destilar, comprimir contexto e reduzir *ensemble* medidos pela primeira vez nos mesmos *hold-outs*: onde a vantagem do professor é grande, o aluno destilado é o sistema distribucional CRPS-ótimo abaixo da configuração competitiva mais barata do professor ($2,5\times$ e

$27\times$ a latência do aluno nos dois casos medidos); onde é pequena, reduzir o *ensemble* basta. Dois achados colaterais de engenharia: um membro do TabPFN $\approx$ oito a um sétimo da latência, e a última duplicação de contexto é desproporcionalmente cara em GPUs de 16 GB.

9. **Ablação desconfundida da rotulagem *out-of-fold* (evidência e regra; Capítulo 7).** Em regressão, o vazamento do professor não degrada acurácia — degrada *calibração* (perda de 0,5 a 5,1 p.p. de PICP80 a contexto idêntico): um refinamento desconfundido do achado de classificação do Pocket FM (TANNA et al., 2026a).
10. **Confronto com nativos distribucionais clássicos — E1 (evidência; Capítulo 7; inédito em relação ao AI-2).** O aluno destilado vence o melhor entre QRF e NG-Boost em 17 de 20 conjuntos ($p = 0,0013$), com os três reverses diagnosticáveis — no `wine_quality`, onde o gate pré-registrado já desaconselhava destilar, a QRF *default* supera até o professor. O complemento negativo tem valor próprio: o passo “teste um nativo forte antes” da regra de decisão deixou de ser retórico.
11. **Negativo arquitetural do TabFM como professor distribucional (evidência negativa; Capítulo 7).** A cabeça de regressão do TabFM é pontual — verificação arquitetural de julho de 2026, confirmada pelo relatório técnico oficial (KONG et al., 2026) — e a dispersão de seu *ensemble* é mensuravelmente inútil como distribuição preditiva (CRPS 0,524 contra 0,069 do TabPFN; cobertura de 16,3% a nominal de 80%): líder pontual não é líder distribucional, e a cabeça distribucional é o ativo arquitetural decisivo para a destilação.
12. **Regra de decisão para destilar (regra; Capítulo 7).** Derivada de duas hipóteses refutadas (ponto e cauda pesada) e do E1: transformar o alvo, testar um nativo forte, e destilar somente a vantagem genuína que sobreviver — pré-condição mensurável por uma rotulagem OOF de minutos. É a forma operacional da resposta à QP3.
13. **Infraestrutura e conduta reutilizáveis (transversal; Capítulos 4 a 7).** Um protocolo versionado de ponta a ponta — configurações, sementes, *hashes* de dados, pré-registros com adendos datados, verificações de novidade datadas e errata pública — em que todo número do texto rastreia a um artefato. A contribuição aqui é de *processo*: o contrato de conduta determinou decisões concretas de escopo, e seus mecanismos de correção foram exercitados em casos reais.

8.3 Conselhos ao praticante

O destilado operacional dos Capítulos 6 e 7, na ordem em que as perguntas devem ser feitas — cada item rastreia ao resultado que o sustenta.

- **Comece pelas restrições, não pelo desempenho.** Quatro perguntas verificáveis antes de qualquer treino: orçamento de latência, limites arquiteturais, exigência de interpretabilidade, e só então o *default* (fluxograma da Seção 6.5). Não tente aprender um roteador por meta-atributos com poucas dezenas de conjuntos: sob LODO, ele não supera a regra trivial (Seção 6.2).
- **Se latência de microssegundos importa, GBDT.** Com 40% ou mais do peso da utilidade na latência, “sempre-GBDT” tem regret mediano zero; a recomendação “FM primeiro” já se inverte com 10–20% de peso na latência (E2, Seção 6.4).
- **Se nenhuma restrição está ativa, *foundation model* primeiro.** Regret mediano 0,000 na geração 2026 (Seção 6.3) — com o TabPFN como opção madura e o TabFM como fronteira, nas versões e com as ressalvas de maturidade declaradas no Capítulo 5.
- **Verifique os limites arquiteturais cedo.** Mais de 10 classes exclui o TabFM; 100 classes excluem ambos os *foundation models* (o caso *helen*a); estouro de contexto é restrição objetiva — são exclusões estruturais, não detalhes (Seção 6.5).
- **Em regressão com incerteza: transforme antes de destilar.** Em alvos de escala de preço, uma transformação logarítmica de uma linha reproduz de graça boa parte da vantagem distribucional do professor (Seção 7.9).
- **Teste a QRF antes de destilar.** Um nativo distribucional *default* custa segundos de treino, serve a microssegundos e, numa minoria previsível de conjuntos, resolve o problema antes que qualquer professor precise ser carregado — no conjunto *wine_quality*, venceu até o professor (E1, Seção 7.8); um MLP-quantil cobre os conjuntos pequenos e numéricos (Seção 7.9).
- **Destile quando o *edge* sobreviver às transformações e a um nativo forte — e meça-o antes.** Uma única rotulagem OOF, de custo de minutos, mede diretamente a vantagem genuína do professor; destile somente se ela persistir (Seção 7.9). Não destile a média: em pools realistas, não há o que transferir no eixo pontual (Seção 7.4).
- **Rotule sempre *out-of-fold*.** O custo é modesto, e a salvaguarda protege o que as métricas de acurácia não veem: a cobertura dos intervalos do aluno (0,5–5,1 p.p. de PICP80; Seção 7.7).
- **Antes de pagar o professor completo, reduza o *ensemble*.** Um membro do TabPFN aproximou oito a um sétimo da latência — às vezes sem custo em acurácia — e, quando a vantagem do professor é pequena, essa alavanca encerra o caso sem destilação alguma (Seção 7.6).

- **Em GPUs de 16 GB, desconfie do último dobro de contexto.** A duplicação final, de 25 mil para 50 mil linhas, custou $3,3\times$ a latência por ganho marginal de acurácia (Seção 7.6); reserve o professor de contexto completo para processamento em lote.

8.4 Limitações e ameaças à validade

Cada capítulo declarou suas limitações locais; esta seção consolida as do programa como um todo, organizadas pelos três tipos canônicos de validade. Nenhuma delas foi descoberta na escrita: todas foram declaradas nos capítulos de origem, a maioria antes dos próprios resultados (Seção 4.11).

8.4.1 Validade interna

Priors cientes de benchmarks — o risco residual não endereçável. Ambos os *foundation models* declaram pré-treino exclusivamente sintético, o que exclui por construção a memorização dos conjuntos OpenML; permanece, porém, o risco mais fraco de *priors* e políticas de inferência iterativamente ajustados, ao longo das versões, ao desempenho em benchmarks públicos — uma forma branda de sobreajuste da comunidade da qual nenhum benchmark público escapa. O tratamento foi declarar o risco, enunciar conclusões no nível de regime (consistência entre conjuntos, não células individuais) e manter o eixo de custo — imune a contaminação — em toda conclusão prática (Seção 4.11).

Assimetrias declaradas nos experimentos complementares. No E1, NGBoost e QRF rodam em configuração *default* documentada, sem ajuste específico, e a QRF recebe imputação por mediana (ajustada no pool, aplicada ao teste) nos três conjuntos com valores ausentes — a interpretação autorizada é “*default forte*”, não “clássico ajustado ao limite” (Seção 7.8). Nos alunos de destilação, a capacidade é herdada do *tuning* do benchmark, sem re-ajuste por alvo de destilação — um controle deliberado que isola o efeito do alvo, mas deixa aberto o teto do método com capacidade re-otimizada (Seção 7.10.2).

A errata diamonds/kin8nm — registro de processo. Um erro de rotulagem presente desde a origem (a chave `diamonds` apontava para o identificador OpenML do `kin8nm`) foi descoberto durante o estudo e tratado pelo rito do contrato de conduta: errata canônica pública, retificação sem reescrita de histórico e re-derivação de todos os números afetados — todo número desta dissertação é posterior à retificação (Seções 4.2 e 4.10). A leitura positiva do episódio merece registro: a execução duplicada acidental que ele produziu reproduziu o pipeline de ponta a ponta com resultados idênticos — uma verificação involuntária, e por isso particularmente convincente, de reprodutibilidade exata (Seção 7.2). A ameaça residual é a que erratas não removem: a possibilidade de erros análogos ainda não descobertos; a mitigação é estrutural (*hashes* de dados, configurações versionadas, números rastreáveis a artefatos).

8.4.2 Validade externa

N pequeno por tarefa e os pisos aritméticos. Com 10/3/5 conjuntos por tarefa, o poder dos testes é baixo por construção: em regressão, o menor p-valor bilateral do Wilcoxon é 0,0625 — significância a 5% é matematicamente impossível, antes de qualquer correção — e a multiclasse ($N=3$) é tratada como descritiva em todo o texto. As mitigações declaradas — equivalências sustentadas pela camada bayesiana, nenhuma conclusão apoiada em significância onde não há poder — limitam o dano, mas não o eliminam: as conclusões por tarefa têm a precisão que N permite, não mais (Seção 4.11).

A exclusão dupla do heleno. Os *ranks* multiclasse dos dois *foundation models* são médias sobre apenas 2 conjuntos — fato repetido em toda tabela afetada. A alternativa (remover o conjunto) esconderia exatamente o tipo de restrição arquitetural que um estudo de decisão prática deve expor; o preço é que a liderança multiclasse da geração 2026 repousa sobre a menor base amostral de todo o benchmark.

TabFM em versão fixada, com relatório técnico não revisado. Todos os resultados referem-se à versão v1.0.1 (julho de 2026, commit fixado); o relatório técnico oficial (KONG et al., 2026) apareceu no fim de setembro de 2026 e, até a escrita desta dissertação, não passou por revisão por pares (Google Research, 2026). As conclusões sobre o modelo são sobre *essa* versão — e a sensibilidade de versão é, ela própria, um trabalho futuro (Seção 8.5).

Regime delimitado. Dezoito conjuntos OpenML (mais os quinze da extensão CTR23 na destilação), teto de 100 mil amostras e uma única GPU de 16 GB delimitam o regime estudado a dados tabulares de pequeno e médio porte em hardware de porte comum. As ordens de grandeza entre famílias tendem a transferir; os valores absolutos, não.

O campo move-se em ciclos de meses. TabPFN-2.5 em novembro de 2025, Pocket FM em maio de 2026, TabFM em junho, a colisão parcial de JEONG et al. (2026) em outubro — a diferença entre as colunas @11 e @14 da validação LODO é a demonstração interna de quão rápido as conclusões datam. Por isso toda afirmação de novidade e toda caracterização de lacuna carrega data de verificação (13–20/07/2026; re-varredura em 04/10/2026), e deve ser lida como “aberta até onde verificamos, nas datas declaradas” — nunca como certeza atemporal (Capítulo 3).

8.4.3 Validade de construto

O proxy de latência do adult. A latência entra nas análises — inclusive no score ponderado do E2 — pela medição padronizada em um único conjunto e um único regime (lote amortizado, cada modelo em seu dispositivo natural). A direção do viés é conhecida e foi declarada no pré-registro (conservador a favor dos *foundation models* em conjuntos pequenos, contra eles em grandes), mas sua magnitude por conjunto não foi medida; o que as conclusões usam são as ordens de grandeza, que o regime não altera (Seções 4.11 e 6.4).

O estimador de CRPS em grade. A grade de 19 quantis sobre-estima o CRPS exato

em $\sim 4\text{--}5\%$ quase constantes, validado contra a forma fechada gaussiana: comparações internas e razões de retenção ficam preservadas, mas os valores absolutos de CRPS desta dissertação não devem ser comparados aos de outros trabalhos (Seção 7.3.3).

Métricas comprimem utilidades. A métrica primária *threshold-free* e o score do E2 (dois critérios, pesos lineares) são construtos deliberadamente simples de funções de utilidade que, na prática, incluem custo de treino, robustez, interpretabilidade e restrições regulatórias com pesos não lineares. O arcabouço mantém os eixos separados em vez de agregá-los prematuramente, mas qualquer recomendação escalar herda essa compressão (Seções 4.11 e 6.6).

8.5 Trabalhos futuros

Listam-se apenas direções com lastro direto na evidência dos capítulos — extensões que este estudo deixa armadas, não especulações.

- **Professores mais novos: sensibilidade de versão da destilação.** O estudo fixou o TabPFN v2.5 por comparabilidade com o benchmark; TabPFN-3 e 3.5 (GRINSZ-TAJN et al., 2026) já existem, e a colisão parcial de JEONG et al. (2026) — ganhos pontuais com professores mais novos, sob protocolo distinto — sugere que a fronteira professor-aluno é sensível à versão. Repetir o protocolo distribucional com os professores da geração seguinte mediria diretamente se a retenção de 19% cresce com a força do professor — e se o negativo pontual resiste.
- **Calibração conformal como complemento e competidor.** A rota conformal pós-hoc sobre o próprio professor (PARK; PARK; CHANG, 2026) entrega garantias de cobertura sem aluno rápido — ao preço da latência do *foundation model*. Incorporá-la à fronteira (e aplicá-la também sobre o aluno destilado) poria à prova a vantagem de calibração observada na Seção 7.7 contra um método com garantia formal.
- **Quantização como quarto braço da fronteira.** A quantização da atenção (KÜBLER et al., 2026) é a alavanca de *serving* emergente que não medimos; a fronteira de três estratégias da Seção 7.6 está construída para recebê-la como quarto braço nos mesmos *hold-outs*.
- **Regret multicritério com preferências elicitadas.** O E2 varreu pesos lineares sobre dois critérios com um *proxy* de latência; a extensão natural é medir latência por conjunto, incorporar custo de treino, robustez e interpretabilidade ao score e elicitar funções de utilidade de praticantes reais — testando se o ponto de inversão (10–20% de peso na latência) se move com critérios adicionais.
- **KANs sob ajuste dedicado.** O resultado negativo do Capítulo 5 usa o protocolo uniforme da grade — a leitura justa para a pergunta do benchmark, mas não a última

palavra sobre a família: um estudo dedicado, com orçamento de busca próprio, o otimizador original e variantes de base, separaria definitivamente método de receita — e diria se o último terço é teto ou artefato de protocolo.

- **Atualização viva do benchmark.** A infraestrutura resumível, com versões e sementes fixadas, está pronta para re-execução periódica à medida que a geração 2027 chegar; a integração com um benchmark vivo mantido pela comunidade, ao estilo TabArena (ERICKSON et al., 2025), é o caminho para que a profundidade de protocolo deste estudo sobreviva à sua datação — a principal ameaça externa declarada acima.

Ao fim, o que esta dissertação oferece não é um vencedor, e sim um mapa datado e verificável: a evidência de que a pergunta de uma década expirou, um arcabouço que converte essa evidência em decisões sob restrições explícitas, e uma regra — testada também nos seus fracassos — para transferir ao regime de microssegundos a única coisa que o novo líder sabe e os modelos baratos não aprendem sozinhos. Cada número aqui citado rastreia a um artefato versionado, cada alegação de novidade carrega a data em que foi verificada, e cada limitação declarada é um convite concreto de continuação. Num campo que se move em ciclos de meses, essa é a forma de contribuição que envelhece melhor: não a resposta definitiva, mas a resposta honesta — com o protocolo público que permite, a quem vier depois, corrigi-la.

- AKIBA, T. et al. Optuna: a next-generation hyperparameter optimization framework. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 25. **Proceedings...** [S.l.: s.n.], 2019.
- ARIK, S. Ö.; PFISTER, T. TabNet: attentive interpretable tabular learning. In: AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE. **Proceedings...** [S.l.: s.n.], 2021.
- ARNOLD, V. I. On the Representation of Continuous Functions of Three Variables as Superpositions of Continuous Functions of Two Variables. **Doklady Akademii Nauk SSSR**, [S.l.], v.114, n.4, p.679–681, 1957. Em russo; tradução: Amer. Math. Soc. Transl. (2) 28 (1963), 51–54.
- BENAVOLI, A. et al. Time for a Change: a tutorial for comparing multiple classifiers through Bayesian analysis. **Journal of Machine Learning Research**, [S.l.], v.18, n.77, p.1–36, 2017.
- BREIMAN, L. Random Forests. **Machine Learning**, [S.l.], v.45, n.1, p.5–32, 2001.
- BREIMAN, L. et al. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984.
- BREIMAN, L.; SHANG, N. **Born Again Trees**. [S.l.]: University of California, Berkeley, Statistics Department, 1996.
- BUCILĂ, C.; CARUANA, R.; NICULESCU-MIZIL, A. Model Compression. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 12. **Proceedings...** [S.l.: s.n.], 2006. p.535–541.
- CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22. **Proceedings...** [S.l.: s.n.], 2016. p.785–794.
- DEMŠAR, J. Statistical Comparisons of Classifiers over Multiple Data Sets. **Journal of Machine Learning Research**, [S.l.], v.7, p.1–30, 2006.
- DISSANAYAKE, P.; DUTTA, S. TabDistill: distilling transformers into neural nets for few-shot tabular classification. **arXiv preprint arXiv:2511.05704**, [S.l.], 2025.
- DUAN, T. et al. NGBoost: natural gradient boosting for probabilistic prediction. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 37. **Proceedings...** PMLR, 2020. v.119, p.2690–2700.
- ERICKSON, N. et al. TabArena: a living benchmark for machine learning on tabular data. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), DATASETS AND BENCHMARKS TRACK. **Anais...** [S.l.: s.n.], 2025. arXiv:2506.16791; spotlight.

- ESLAMIAN, A.; Afzal Aghaei, A.; CHENG, Q. TabKAN: advancing tabular data analysis using Kolmogorov–Arnold network. **Machine Learning for Computational Science and Engineering**, [S.l.], v.1, n.2, p.40, 2025. arXiv:2504.06559; doi:10.1007/s44379-025-00042-y.
- FISCHER, S. F.; FEURER, M.; BISCHL, B. OpenML-CTR23 – A curated tabular regression benchmarking suite. In: AUTOML CONFERENCE (WORKSHOP TRACK). **Anais...** [S.l.: s.n.], 2023.
- FRIEDMAN, J. H. Greedy Function Approximation: a gradient boosting machine. **The Annals of Statistics**, [S.l.], v.29, n.5, p.1189–1232, 2001.
- FRIEDMAN, M. The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance. **Journal of the American Statistical Association**, [S.l.], v.32, n.200, p.675–701, 1937.
- FROSST, N.; HINTON, G. Distilling a Neural Network Into a Soft Decision Tree. **arXiv preprint arXiv:1711.09784**, [S.l.], 2017.
- FURLANELLO, T. et al. Born Again Neural Networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 35. **Proceedings...** PMLR, 2018. v.80, p.1607–1616.
- GAO, W. et al. TabKANet: tabular data modeling with Kolmogorov–Arnold network and transformer. **arXiv preprint arXiv:2409.08806**, [S.l.], 2024.
- GNEITING, T.; BALABDAOUI, F.; RAFTERY, A. E. Probabilistic Forecasts, Calibration and Sharpness. **Journal of the Royal Statistical Society: Series B (Statistical Methodology)**, [S.l.], v.69, n.2, p.243–268, 2007.
- GNEITING, T.; RAFTERY, A. E. Strictly Proper Scoring Rules, Prediction, and Estimation. **Journal of the American Statistical Association**, [S.l.], v.102, n.477, p.359–378, 2007.
- GNEITING, T.; RANJAN, R. Comparing Density Forecasts Using Threshold- and Quantile-Weighted Scoring Rules. **Journal of Business & Economic Statistics**, [S.l.], v.29, n.3, p.411–422, 2011.
- Google Research. **TabFM**: a foundation model for tabular data. Version 1.0.1, pinned commit d8678b6; official technical report: arXiv:2609.37959 (Kong et al., September 2026), not peer-reviewed as of October 2026, Official blog post, Hugging Face model card and repository <https://github.com/google-research/tabfm>.
- GORISHNIY, Y. et al. Revisiting Deep Learning Models for Tabular Data. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS). **Anais...** [S.l.: s.n.], 2021.

- GORISHNIY, Y.; KOTELNIKOV, A.; BABENKO, A. TabM: advancing tabular deep learning with parameter-efficient ensembling. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR). **Anais...** [S.l.: s.n.], 2025. arXiv:2410.24210.
- GRINSZTAJN, L. et al. TabPFN-2.5: advancing the state of the art in tabular foundation models. **arXiv preprint arXiv:2511.08667**, [S.l.], 2025. Prior Labs technical report; 26 authors.
- GRINSZTAJN, L. et al. TabPFN-3: technical report. **arXiv preprint arXiv:2605.13986**, [S.l.], 2026. Technical report (Prior Labs), 41 authors; not peer-reviewed.
- GRINSZTAJN, L.; OYALLON, E.; VAROQUAUX, G. Why do tree-based models still outperform deep learning on typical tabular data? In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), DATASETS AND BENCHMARKS TRACK. **Anais...** [S.l.: s.n.], 2022.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning**: data mining, inference, and prediction. 2.ed. New York: Springer, 2009.
- HEREDGE, J. et al. CRUMB: efficient prior fitted network inference via distributionally matched context batching. **arXiv preprint arXiv:2606.11473**, [S.l.], 2026.
- HERRE, M. et al. Explaining Tabular Foundation Model Differences Through Meta-Features. **arXiv preprint arXiv:2605.28418**, [S.l.], 2026.
- HINTON, G.; VINYALS, O.; DEAN, J. Distilling the Knowledge in a Neural Network. **arXiv preprint arXiv:1503.02531**, [S.l.], 2015.
- HOLLMANN, N. et al. Accurate predictions on small data with a tabular foundation model. **Nature**, [S.l.], v.637, p.319–326, 2025.
- HOLM, S. A Simple Sequentially Rejective Multiple Test Procedure. **Scandinavian Journal of Statistics**, [S.l.], v.6, n.2, p.65–70, 1979.
- HOLZMÜLLER, D.; GRINSZTAJN, L.; STEINWART, I. Better by Default: strong pre-tuned MLPs and boosted trees on tabular data. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS). **Anais...** [S.l.: s.n.], 2024.
- HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multilayer Feedforward Networks Are Universal Approximators. **Neural Networks**, [S.l.], v.2, n.5, p.359–366, 1989.
- IMAN, R. L.; DAVENPORT, J. M. Approximations of the Critical Region of the Friedman Statistic. **Communications in Statistics — Theory and Methods**, [S.l.], v.9, n.6, p.571–595, 1980.

- IZBICKI, R.; RODRIGUES, P. L. C. Benchmarking Tabular Foundation Models for Conditional Density Estimation in Regression. **arXiv preprint arXiv:2603.26611**, [S.l.], 2026.
- JEONG, M. et al. Distillation of Tabular Foundation Models into Efficient Predictors. **arXiv preprint arXiv:2610.01435**, [S.l.], 2026.
- JIA, J. et al. Selecting Feature Interactions for Generalized Additive Models by Distilling Foundation Models. **arXiv preprint arXiv:2604.13332**, [S.l.], 2026.
- KE, G. et al. LightGBM: a highly efficient gradient boosting decision tree. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS). **Anais...** [S.l.: s.n.], 2017.
- KOENKER, R.; BASSETT, G. Regression Quantiles. **Econometrica**, [S.l.], v.46, n.1, p.33–50, 1978.
- KOHAVI, R. Scaling Up the Accuracy of Naive-Bayes Classifiers: a decision-tree hybrid. In: SECOND INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING (KDD). **Proceedings...** AAAI Press, 1996. p.202–207.
- KOLMOGOROV, A. N. On the Representation of Continuous Functions of Many Variables by Superposition of Continuous Functions of One Variable and Addition. **Doklady Akademii Nauk SSSR**, [S.l.], v.114, n.5, p.953–956, 1957. Em russo; tradução: Amer. Math. Soc. Transl. (2) 28 (1963).
- KONG, W. et al. TabFM: a zero-shot foundation model for tabular data. **arXiv preprint arXiv:2609.37959**, [S.l.], 2026.
- KÜBLER, J. M. et al. Attention Quantization for Tabular Foundation Models. **arXiv preprint arXiv:2609.13031**, [S.l.], 2026.
- LANDSGESELL, J.; KNOLL, P.; WENZEL, T. Distributional Regression with Tabular Foundation Models: evaluating probabilistic predictions via proper scoring rules. **arXiv preprint arXiv:2603.08206**, [S.l.], 2026.
- LIN, Y.; LI, S. Context-Constrained Transfer Learning for Tabular Foundation Models via Data Distillation. **arXiv preprint arXiv:2607.04809**, [S.l.], 2026. Framework name: TL-ANDI (Transfer Learning via ANchoring and DIstillation).
- LIU, Z. et al. KAN: Kolmogorov–Arnold networks. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR). **Anais...** [S.l.: s.n.], 2025. arXiv:2404.19756; oral presentation.

- LUO, S. et al. Memory Efficient Tabular Foundation Models. In: ICML WORKSHOP ON FOUNDATION MODELS FOR STRUCTURED DATA (FMSD), 2. **Anais...** [S.l.: s.n.], 2026. arXiv:2607.27546.
- MCELFRESH, D. et al. When Do Neural Nets Outperform Boosted Trees on Tabular Data? In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), DATASETS AND BENCHMARKS TRACK. **Anais...** [S.l.: s.n.], 2023.
- MEINSHAUSEN, N. Quantile Regression Forests. **Journal of Machine Learning Research**, [S.l.], v.7, p.983–999, 2006.
- MÜLLER, A.; CURINO, C.; RAMAKRISHNAN, R. MotherNet: fast training and inference via hyper-network transformers. **arXiv preprint arXiv:2312.08598**, [S.l.], 2023. Title per arXiv v2 (2025).
- MÜLLER, S. et al. Transformers Can Do Bayesian Inference. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR). **Anais...** [S.l.: s.n.], 2022. arXiv:2112.10510.
- NAGLER, T. Statistical Foundations of Prior-Data Fitted Networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 40. **Proceedings...** PMLR, 2023. v.202, p.25660–25676.
- NEMENYI, P. B. **Distribution-Free Multiple Comparisons**. 1963. Tese (Doutorado em Ciência da Computação) — Princeton University.
- PARK, S.; PARK, S.; CHANG, W. Conformal Prediction and Conditional Coverage for Tabular Foundation Models. **arXiv preprint arXiv:2609.34887**, [S.l.], 2026.
- POETA, E. et al. A Benchmarking Study of Kolmogorov–Arnold Networks on Tabular Data. **arXiv preprint arXiv:2406.14529**, [S.l.], 2024. doi:10.1109/AICT61888.2024.10740444.
- PROKHORENKOVA, L. et al. CatBoost: unbiased boosting with categorical features. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS). **Anais...** [S.l.: s.n.], 2018.
- QIN, Q. et al. GEAR: generative expansion and real anchoring for two-stage distillation of tabular foundation models. **arXiv preprint arXiv:2608.18849**, [S.l.], 2026.
- QU, J. et al. TabICL: a tabular foundation model for in-context learning on large data. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML). **Anais...** [S.l.: s.n.], 2025. arXiv:2502.05564.
- RICE, J. R. The Algorithm Selection Problem. **Advances in Computers**, [S.l.], v.15, p.65–118, 1976.

- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning Representations by Back-Propagating Errors. **Nature**, [S.l.], v.323, n.6088, p.533–536, 1986.
- SOMEPALLI, G. et al. SAINT: improved neural networks for tabular data via row attention and contrastive pre-training. **arXiv preprint arXiv:2106.01342**, [S.l.], 2021.
- TANNA, A. et al. Pocket Foundation Models: distilling TFMs into CPU-ready gradient-boosted trees. In: ICML WORKSHOP ON FOUNDATION MODELS FOR STRUCTURED DATA (FMSD), 2. **Anais...** [S.l.: s.n.], 2026. arXiv:2605.18654.
- TANNA, A. et al. Distilling Tabular Foundation Models for Structured Health Data. **arXiv preprint arXiv:2605.18702**, [S.l.], 2026.
- VANSCHOREN, J. et al. OpenML: networked science in machine learning. **ACM SIGKDD Explorations Newsletter**, [S.l.], v.15, n.2, p.49–60, 2014.
- VASCONCELOS, J. G. d. A.; VASCONCELOS, G. C. **Does “GBDT Always Win”? A Multi-Criteria Benchmark of 14 Tabular Models and a Validated Decision Framework**. [S.l.]: Centro de Informática, Universidade Federal de Pernambuco, 2026. Individual coursework report (Trabalho Individual), Available in the project repository.
- VASWANI, A. et al. Attention Is All You Need. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS). **Anais...** [S.l.: s.n.], 2017.
- VIDAL, T.; SCHIFFER, M. Born-Again Tree Ensembles. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML). **Anais...** [S.l.: s.n.], 2020. p.9743–9753.
- VOSKOU, A.; CHRISTOFOROU, C.; CHATZIS, S. Transformers with Stochastic Competition for Tabular Data Modelling. In: ICML 2024 WORKSHOP ON STRUCTURED PROBABILISTIC INFERENCE & GENERATIVE MODELING (SPIGM). **Anais...** [S.l.: s.n.], 2024. arXiv:2407.13238; workshop attribution per OpenReview TfGUqFlhiU. Corrige a citacao anterior (Hajiramezanali et al. 2022, STab homonimo autossupervisionado) o metodo implementado (LWTA, Gumbel-softmax, media bayesiana N=64) corresponde a este paper (verificado 06/10/2026).
- WILCOXON, F. Individual Comparisons by Ranking Methods. **Biometrics Bulletin**, [S.l.], v.1, n.6, p.80–83, 1945.
- YU, R.; YU, W.; WANG, X. KAN or MLP: a fairer comparison. **arXiv preprint arXiv:2407.16674**, [S.l.], 2024. Technical report; not peer-reviewed.
- ZABÈRGJA, G. et al. End-to-End Compression for Tabular Foundation Models. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML). **Anais...** [S.l.: s.n.], 2026. arXiv:2602.05649; spotlight. Method name: TACO.

ZENG, Y. et al. TabFlex: scaling tabular learning to millions with linear attention. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML). **Anais...** [S.l.: s.n.], 2025. arXiv:2506.05584.

Apêndice



Tabelas Completas de Resultados por Data-set

Este apêndice apresenta a tabela mestra do benchmark em forma desagregada: a métrica primária de cada um dos 14 modelos em cada um dos 18 conjuntos de dados, no *hold-out* de teste (20%, semente 42), conforme o protocolo do Capítulo 4. São as Tabelas A.1, A.2 e A.3 — uma por tarefa, porque a métrica primária difere entre tarefas e valores de métricas distintas não são comparáveis entre si.

Como ler as tabelas. Cada linha é um conjunto de dados; cada coluna, um modelo, na ordem canônica do benchmark (os três GBDTs, os modelos profundos, as redes KAN e os dois *foundation models*). A métrica primária segue a definição do protocolo:

- **classificação binária** (10 conjuntos): AUC-ROC — maior é melhor (Tabela A.1);
- **classificação multiclasse** (3 conjuntos): *log-loss* — menor é melhor (Tabela A.2);
- **regressão** (5 conjuntos): RMSE sobre o alvo padronizado — menor é melhor (Tabela A.3).

O melhor valor de cada linha está em **negrito**. Os valores têm quatro casas decimais, com vírgula como separador decimal. As duas células marcadas “—” (*helena* × TabPFN/TabFM) são as exclusões estruturais do estudo: o conjunto tem 100 classes, acima do limite arquitetural de ambos os *foundation models*. O estado completo é, portanto, de 250 células medidas em $14 \times 18 = 252$ possíveis.

Proveniência e reprodutibilidade. Todos os números provêm de `results/aggregated/test_res` o agregado versionado do benchmark; as tabelas em si são geradas automaticamente por `scripts/gen_ag` a partir desse artefato (nenhum valor é transcrito à mão). Os resultados por *fold* da validação cruzada interna, que fundamentam as análises estatísticas do Capítulo 5, estão em `results/aggregated/f` — arquivo de ~ 300 MB que permanece no repositório local (fora do controle de versão remoto por tamanho), reproduzível a partir de `results/raw` e das sementes registradas.

Nota de layout. Com 15 colunas (o conjunto de dados mais os 14 modelos), as tabelas não cabem na orientação de retrato; optou-se por páginas rotacionadas (`sidewaystable`, pacote `rotating`) com os nomes dos modelos rotacionados no cabeçalho, mantendo os 14 modelos lado a lado — a comparação por linha, que é a leitura principal, fica íntegra numa única tabela por tarefa.

Tabela A.1: Classificação binária — AUC-ROC no teste (maior é melhor). Métrica primária por modelo em cada *dataset*; **negrito** = melhor da linha; “—” = célula estruturalmente ausente. Fonte: results/aggregated/test_results.csv.

Dataset	FT-Transformer													
	XGBoost	LightGBM	CatBoost	MLP	RealMLP	SAINT	STab	TabNet	TabM	KAN	TabKAN	TabPFN	TabFM	
adult	0,9301	0,9299	0,9297	0,9128	0,9190	0,9165	0,9201	0,9172	0,9121	0,9161	0,9151	0,9140	0,9322	
amazon_employee	0,8401	0,8435	0,8869	0,8208	0,8068	0,7835	0,7793	0,6769	0,7888	0,8108	0,8171	0,8125	0,8604	
bank_marketing	0,9339	0,9292	0,9333	0,9294	0,9303	0,9357	0,9326	0,9344	0,9268	0,9369	0,9274	0,9252	0,9442	
cardiovascular_disease	0,8002	0,8001	0,8001	0,7981	0,7980	0,7993	0,7998	0,7991	0,7805	0,7991	0,7979	0,7955	0,8023	
credit_g	0,7667	0,7656	0,7720	0,7744	0,7362	0,7873	0,7651	0,7695	0,7462	0,7837	0,7494	0,7770	0,7763	
give_me_some_credit	0,8640	0,8640	0,8646	0,8212	0,8625	0,8270	0,8273	0,8274	0,8175	0,8268	0,8190	0,8187	0,8678	
higgs	0,8117	0,8111	0,8107	0,8133	0,8140	0,8096	0,8119	0,8184	0,8059	0,8193	0,8018	0,7908	0,8403	
magiclelescope	0,9297	0,9284	0,9314	0,9291	0,9366	0,9278	0,9338	0,9278	0,9352	0,9328	0,9165	0,9139	0,9566	
phoneme	0,9429	0,9416	0,9454	0,9213	0,9482	0,9362	0,9358	0,9138	0,9232	0,9388	0,8952	0,8939	0,9717	
telco_customer_churn	0,8465	0,8446	0,8431	0,8391	0,8417	0,8465	0,8460	0,8413	0,8314	0,8425	0,8456	0,8421	0,8490	
													0,8233	

Tabela A.2: Classificação multiclasse — log-loss no teste (menor é melhor). Métrica primária por modelo em cada *dataset*; **negrito** = melhor da linha; “—” = célula estruturalmente ausente. Fonte: results/aggregated/test_results.csv.

<i>Dataset</i>	XGBoost	LightGBM	CatBoost	MLP	RealMLP	FT-Transformer	SAINT	STab	TabNet	TabM	KAN	TabKAN	TabPFN	TabFM
covertime	0,1934	0,2009	0,2035	0,2118	0,1894	0,2076	0,2289	0,1786	0,2423	0,2067	0,2496	0,2577	0,1644	0,0966
helena	2,6010	2,6265	2,5800	2,5260	2,5144	2,5420	2,6090	2,5342	2,6758	2,5097	2,6376	2,7187	—	—
jannis	0,6801	0,6836	0,6836	0,6874	0,6817	0,6774	0,6887	0,6698	0,7027	0,6572	0,7080	0,7257	0,6583	0,5709

Tabela A.3: Regressão — RMSE no teste (menor é melhor). Métrica primária por modelo em cada *dataset*; **negrito** = melhor da linha; “—” = célula estruturalmente ausente. Fonte: `results/aggregated/test_results.csv`.

<i>Dataset</i>	XGBoost	LightGBM	CatBoost	MLP	RealMLP	FT-Transformer	SAINT	STab	TabNet	TabM	KAN	TabKAN	TabPFN	TabFM
california_housing	0,2637	0,2641	0,2653	0,3002	0,2801	0,2851	0,2873	0,2905	0,3326	0,2798	0,3371	0,3324	0,2570	0,2346
kin8nm	0,1117	0,1075	0,0859	0,0821	0,0630	0,0677	0,0653	0,0820	0,0808	0,0656	0,1513	0,1526	0,0667	0,0652
superconduct	0,8308	0,8320	0,8331	0,8523	0,8401	0,8432	0,8464	0,8415	0,8594	0,8482	0,8457	0,8460	0,8284	0,8269
wine_quality	0,5975	0,6131	0,6005	0,6629	0,6728	0,6774	0,6869	0,7077	0,6993	0,6607	0,6597	0,6941	0,6129	0,5747
year_prediction	8,6801	8,6727	8,6949	9,3563	8,6269	8,8727	8,8207	8,8357	8,8622	8,9224	8,7864	8,8662	8,5952	8,3634

B

Espaços de Busca de Hiperparâmetros

Este apêndice transcreve, para cada modelo ajustado do benchmark, o espaço de busca de hiperparâmetros exatamente como definido no artefato versionado `configs/models.yaml` — a fonte única que o *runner* (`scripts/run_all.py`) consome. A otimização segue o protocolo do Capítulo 4: Optuna com amostrador TPE e *MedianPruner*, com orçamento assimétrico de **100 trials** para os GBDTs e **25 trials** para os modelos de aprendizado profundo, sobre a validação cruzada interna de 3 *folds* (a justificativa da assimetria está na Seção correspondente do Capítulo 4, junto à discussão do protocolo).

Convenções das tabelas: “int” e “float” denotam amostragem uniforme no intervalo fechado indicado (na escala logarítmica quando marcado “log”); “cat.” denota escolha categórica no conjunto listado. Os nomes dos parâmetros são os literais do arquivo de configuração, para rastreabilidade direta.

Os dois *foundation models* — **TabPFN** e **TabFM** — são aplicados em regime *zero-shot* e, por definição do protocolo, **não têm espaço de busca**: nenhum hiperparâmetro é otimizado por conjunto de dados. Para o TabPFN, as configurações de ensemble por subamostragem estão em `configs/experiment.yaml`; para o TabFM, o teto de 50 mil linhas de contexto e o tamanho do ensemble são fixos no *wrapper* (`src/models/tabfm_model.py`), espelhando a política do TabPFN. Essa assimetria de orçamento (busca completa para os demais, nenhuma para os FMs) é parte do desenho experimental e é discutida no Capítulo 4.

Duas notas de escopo, registradas como comentários no próprio `configs/models.yaml`: no **KAN**, ficam *fixos* (fora da busca) a ordem do *spline* (3), a função-base SiLU e o *grid range* $[-2, 2]$ após *LayerNorm* por camada (ver `src/models/kan_model.py`); no **TabKAN**, a variante ChebyKAN é fixa e as faixas seguem a seção de NAS do artigo original, aparadas para o orçamento de 25 *trials* (ver `src/models/tabkan_model.py`).

Tabela B.1: Espaços de busca dos GBDTs (100 *trials*). Fonte: `configs/models.yaml`.

Parâmetro	Tipo	Faixa / valores
XGBoost		
<code>n_estimators</code>	int	[100, 2000]
<code>max_depth</code>	int	[3, 12]
<code>learning_rate</code>	float (log)	[0,005; 0,3]
<code>subsample</code>	float	[0,5; 1,0]
<code>colsample_bytree</code>	float	[0,5; 1,0]
<code>min_child_weight</code>	float	[1,0; 10,0]
<code>reg_alpha</code>	float (log)	[10^{-8} , 10]
<code>reg_lambda</code>	float (log)	[10^{-8} , 10]
LightGBM		
<code>n_estimators</code>	int	[100, 2000]
<code>max_depth</code>	int	[3, 12]
<code>learning_rate</code>	float (log)	[0,005; 0,3]
<code>num_leaves</code>	int	[16, 256]
<code>subsample</code>	float	[0,5; 1,0]
<code>colsample_bytree</code>	float	[0,5; 1,0]
<code>min_child_samples</code>	int	[5, 100]
<code>reg_alpha</code>	float (log)	[10^{-8} , 10]
<code>reg_lambda</code>	float (log)	[10^{-8} , 10]
CatBoost		
<code>iterations</code>	int	[100, 2000]
<code>depth</code>	int	[3, 10]
<code>learning_rate</code>	float (log)	[0,005; 0,3]
<code>l2_leaf_reg</code>	float	[1,0; 10,0]
<code>bagging_temperature</code>	float	[0,0; 1,0]
<code>random_strength</code>	float	[0,0; 10,0]

Tabela B.2: Espaços de busca de MLP, RealMLP e TabM (25 *trials*). Fonte: `configs/models.yaml`.

Parâmetro	Tipo	Faixa / valores
MLP		
<code>n_blocks</code>	int	[1, 4]
<code>d_hidden</code>	cat.	{64, 128, 256, 512}
<code>dropout</code>	float	[0,0; 0,5]
<code>learning_rate</code>	float (log)	[10^{-5} , 10^{-3}]
<code>weight_decay</code>	float (log)	[10^{-6} , 10^{-3}]
RealMLP		
<code>learning_rate</code>	float (log)	[0,02; 0,3]
<code>hidden_width</code>	cat.	{64, 256, 512}
<code>n_hidden_layers</code>	int	[1, 5]
<code>dropout</code>	cat.	{0,0; 0,15; 0,3}
<code>weight_decay</code>	cat.	{0,0; 0,02}
<code>activation</code>	cat.	{selu, mish, relu}
<code>num_emb_type</code>	cat.	{none, pbld, pl, plr}
<code>add_front_scale</code>	cat.	{true, false}
<code>ls_eps</code>	cat.	{0,0; 0,1}
TabM		
<code>arch_type</code>	cat.	{tabm, tabm-mini}
<code>k</code>	int	[8, 64]
<code>d_block</code>	cat.	{128, 256, 512}
<code>n_blocks</code>	int	[1, 4]
<code>dropout</code>	float	[0,0; 0,5]
<code>learning_rate</code>	float (log)	[10^{-5} , 10^{-3}]
<code>weight_decay</code>	float (log)	[10^{-6} , 10^{-3}]

Tabela B.3: Espaços de busca de FT-Transformer, SAINT, STab e TabNet (25 trials). Fonte: `configs/models.yaml`.

Parâmetro	Tipo	Faixa / valores
FT-Transformer		
<code>n_blocks</code>	int	[1, 6]
<code>d_block</code>	cat.	{64, 128, 192, 256}
<code>attention_n_heads</code>	cat.	{4, 8}
<code>attention_dropout</code>	float	[0,0; 0,5]
<code>ffn_d_hidden_multiplier</code>	float	[1,333; 2,666]
<code>ffn_dropout</code>	float	[0,0; 0,5]
<code>residual_dropout</code>	float	[0,0; 0,2]
<code>learning_rate</code>	float (log)	[10^{-5} , 10^{-3}]
<code>weight_decay</code>	float (log)	[10^{-6} , 10^{-3}]
SAINT		
<code>depth</code>	int	[1, 6]
<code>heads</code>	cat.	{4, 8}
<code>dim</code>	cat.	{32, 64, 128, 256}
<code>attn_dropout</code>	float	[0,0; 0,4]
<code>ff_dropout</code>	float	[0,0; 0,4]
<code>learning_rate</code>	float (log)	[10^{-5} , 10^{-3}]
<code>weight_decay</code>	float (log)	[10^{-6} , 10^{-3}]
STab		
<code>depth</code>	int	[2, 7]
<code>dim</code>	cat.	{64, 96, 128, 192, 256}
<code>heads</code>	cat.	{4, 8}
<code>attn_dropout</code>	float	[0,0; 0,3]
<code>ff_dropout</code>	float	[0,0; 0,3]
<code>cases</code>	cat.	{4, 8, 16}
<code>learning_rate</code>	float (log)	[10^{-5} , 10^{-3}]
<code>weight_decay</code>	float (log)	[10^{-5} , 10^{-3}]
TabNet		
<code>n_d</code>	cat.	{8, 16, 32, 64}
<code>n_a</code>	cat.	{8, 16, 32, 64}
<code>n_steps</code>	int	[3, 10]
<code>gamma</code>	float	[1,0; 2,0]
<code>lambda_sparse</code>	float (log)	[10^{-6} , 10^{-3}]
<code>learning_rate</code>	float (log)	[0,005; 0,05]
<code>mask_type</code>	cat.	{sparsemax, entmax}

Tabela B.4: Espaços de busca de KAN e TabKAN (25 *trials*). Fonte: `configs/models.yaml`.

Parâmetro	Tipo	Faixa / valores
KAN		
<code>n_layers</code>	int	[1, 3]
<code>d_hidden</code>	cat.	{32, 64, 128, 256}
<code>grid_size</code>	cat.	{3, 5, 10, 20}
<code>learning_rate</code>	float (log)	$[10^{-4}, 10^{-2}]$
<code>weight_decay</code>	float (log)	$[10^{-6}, 10^{-3}]$
<code>reg_lambda</code>	float (log)	$[10^{-8}, 10^{-2}]$
TabKAN		
<code>n_layers</code>	int	[1, 4]
<code>d_hidden</code>	cat.	{16, 32, 64, 128}
<code>degree</code>	int	[2, 5]
<code>learning_rate</code>	float (log)	$[10^{-4}, 10^{-2}]$
<code>weight_decay</code>	cat.	{0; 10^{-6} ; 10^{-5} ; 10^{-4} }



Resultados Suplementares e Registro de Processo

Este apêndice reúne dois tipos de material: as tabelas desagregadas das duas ablações da destilação discutidas no Capítulo 7 (Seção C.1) e o registro de processo do trabalho — hipóteses que não sobreviveram ao contato com os dados e desvios operacionais documentados (Seção C.2).

C.1 Ablações da destilação: tabelas desagregadas

Os valores a seguir são médias sobre as 3 sementes (0, 1, 2) do protocolo de destilação, agregadas com `pandas` diretamente dos artefatos versionados citados em cada tabela.

C.1.1 Rotulagem OOF vs. *in-sample*

A Tabela C.1 desagrega a ablação da Seção 7.7: o aluno XGBoost-quantil treinado com alvos do teacher TabPFN rotulados em três regimes — *out-of-fold* (OOF), *in-sample* com contexto fixado em 80% do pool (*ctx-80*, que isola o efeito do vazamento mantendo o tamanho de contexto do OOF) e *in-sample* pleno. O padrão documentado no capítulo é legível nas colunas: RMSE e CRPS *não* degradam com o vazamento (chegam a melhorar levemente), mas a cobertura dos intervalos (PICP 80%, nominal 0,80) cai de forma consistente nos quatro conjuntos quando se passa de OOF para *ctx-80* — o efeito puro do vazamento sobre a calibração do aluno.

Para o aluno XGBoost-ponto (sem componente distribucional), o mesmo artefato mostra o mesmo não-dano em RMSE: *in-sample* fica igual ou levemente melhor que OOF nos quatro conjuntos (`california_housing` 0,262 vs. 0,268; `kin8nm` 0,109 vs. 0,111; `superconduct`

Tabela C.1: Ablação OOF vs. *in-sample* — aluno XGBoost-quantil, teacher TabPFN; média de 3 sementes. PICP 80% nominal = 0,80. Fonte: `results/distillation/ablation_insample.csv`.

Dataset	OOF			In-sample ctx-80			In-sample		
	RMSE	CRPS	PICP	RMSE	CRPS	PICP	RMSE	CRPS	PICP
california_housing	0,277	0,109	0,596	0,270	0,111	0,545	0,268	0,111	0,532
kin8nm	0,110	0,064	0,617	0,108	0,064	0,571	0,107	0,064	0,574
superconduct	0,860	0,454	0,770	0,858	0,453	0,765	0,857	0,453	0,767
wine_quality	0,683	0,365	0,707	0,629	0,338	0,661	0,615	0,336	0,602

0,833 vs. 0,835; wine_quality 0,617 vs. 0,667) — o custo do vazamento em regressão está na calibração, não na acurácia.

C.1.2 Transformação logarítmica do alvo

A Tabela C.2 desagrega a ablação da Seção 7.9: teacher TabPFN e alunos XGBoost-quantil re-executados sob $y' = \log(1 + y)$ nos três conjuntos de falha da extensão (alvos em escala de preço) e em dois controles positivos. As métricas são medidas no espaço logarítmico. A coluna de retenção usa a definição do Capítulo 7, $(\text{CRPS}_{\text{hard}} - \text{CRPS}_{\text{soft}}) / (\text{CRPS}_{\text{hard}} - \text{CRPS}_{\text{teacher}})$, calculada sobre as médias exibidas. A leitura documentada: o log *não* recupera as falhas (fifa segue fortemente negativo) e os gaps teacher–aluno colapsam para a casa de 0,004–0,025 — boa parte da vantagem distribucional do *foundation model* nesses alvos é tratamento de escala.

Tabela C.2: Ablação da transformação logarítmica do alvo — CRPS em espaço log, média de 3 sementes (teacher determinístico, 1 execução). “Hard” = aluno de rótulos verdadeiros; “soft” = aluno destilado. Fonte: `results/distillation/ablation_logtarget.csv`.

Grupo	Dataset	Teacher	Aluno hard	Aluno soft	Retenção
Falha	fifa	0,3405	0,3499	0,3656	−1,69
	diamonds_real	0,0411	0,0449	0,0451	−0,03
	health_insurance	0,5713	0,5961	0,5951	+0,04
Controle	kings_county	0,0783	0,0862	0,0859	+0,04
	miami_housing	0,0654	0,0736	0,0724	+0,15

C.2 Cemitério de hipóteses e desvios

Na tradição do apêndice de transparência de GRINSZTAJN; OYALLON; VAROQUAUX (2022), registramos aqui as hipóteses que foram testadas e não sobreviveram, e os desvios de processo que afetaram artefatos do trabalho — cada um com a rubrica *o que era / o que aconteceu / por que está aqui* e o ponteiro para o registro primário. O contrato de conduta do programa

de pesquisa exige que resultados negativos sejam reportados e que correções sejam feitas por retificação datada, nunca por reescrita de histórico; este registro é a consolidação desses episódios.

C.2.0.0.1 1. H1 — destilação pontual. *O que era:* hipótese pré-registrada (docs/desenho-experi-
g1) de que um aluno GBDT destilado reteria $\geq 50\%$ do gap de RMSE do teacher em ≥ 3 dos 5 conjuntos de regressão. *O que aconteceu:* refutada nos cinco conjuntos centrais com o teacher TabPFN; a refutação replicou com o teacher TabFM, de gaps pontuais maiores, e no experimento confirmatório E1 em escala $N=20$, no qual o aluno pontual destilado supera o controle de rótulos verdadeiros em apenas 4 de 20 conjuntos. *Por que está aqui:* é o resultado negativo mais importante do Capítulo 7 (Seção 7.4) — em pool completo, o aluno não absorve a vantagem pontual do *foundation model*, independentemente do tamanho do gap; o que se transfere é a distribuição. Registros: docs/desenho-experimental-destilacao.md (pré-registro), docs/relatorio-ai2.md (fases 1–2), Seções 7.4 e 7.8.

C.2.0.0.2 2. Cauda pesada como moderador de falha (log-target). *O que era:* com a extensão a $N=15$, três das quatro falhas de retenção distribucional concentravam-se em alvos de cauda pesada/escala de preço; a hipótese viva era que a transformação $\log(1+y)$ recuperaria a retenção. *O que aconteceu:* a ablação dedicada refutou a hipótese — o log não resgata as falhas (fifa $-1,69$) e ainda encolhe os sucessos, porque colapsa a própria vantagem do teacher no espaço logarítmico (Tabela C.2). *Por que está aqui:* a refutação é mais útil que a hipótese — virou a cláusula (i) da regra de decisão “quando destilar” (Seção 7.9): antes de destilar, aplique transformações baratas de alvo. Registros: docs/relatorio-ai2.md (fase 6a), results/distillation/ablation_logtarget.csv.

C.2.0.0.3 3. Roteamento por meta-features. *O que era:* a promessa, herdada da literatura de meta-learning, de que meta-features do conjunto de dados poderiam prever a família vencedora — o arcabouço de decisão seria um preditor, não um fluxograma. *O que aconteceu:* sob validação *leave-one-dataset-out*, a árvore de profundidade 2 não supera o baseline de classe majoritária em nenhuma das duas gerações de modelos (hit-rate 0,11 vs. 0,44 com 11 modelos; 0,72 vs. 0,78 com 14). *Por que está aqui:* o resultado negativo é o que justifica a forma final do arcabouço (decisão por restrições, não por predição); a árvore permanece no trabalho apenas como ilustração descritiva. Registros: Seção 6.2 do Capítulo 6, results/aggregated/lodo_validation.csv e lodo_validation_14.csv, scripts/1

C.2.0.0.4 4. A claim retratada do OOM “determinístico” no year_prediction. *O que era:* durante a medição da fronteira de Pareto, afirmou-se que o ponto teacher TabPFN com contexto de 50 mil linhas no *year_prediction* era imensurável na GPU de 16 GB por OOM determinístico. *O que aconteceu:* a análise forense da sessão mostrou que a claim estava

errada — o culpado era a estimativa do modo automático de memória; com `memory_saving_mode` forçado, o ponto foi medido (148,6 ms/linha, $\sim 3,3\times$ a latência do ponto de 25 mil, por um ganho de RMSE de apenas $8,661 \rightarrow 8,610$). A claim foi retratada conforme a política de correção, e a medição virou argumento adicional *contra* o teacher de contexto completo em GPUs de 16 GB. *Por que está aqui:* retratações públicas fazem parte do contrato de conduta; o episódio também ilustra que “imensurável” exige verificação exaustiva dos modos de operação antes de ser afirmado. Registros: commit 64b410a (“ai2: correction — year@50K WAS measurable”), docs/relatorio-ai2.md (fase 3), comentário em scripts/pareto_strategies.py.

C.2.0.0.5 5. Errata diamonds/kin8nm. *O que era:* a entrada diamonds de configs/datasets apontava, desde a criação do projeto, para o openml_id 44980 — que é o kin8nm (8.192 amostras), não o diamonds (44979; 53.940 amostras). *O que aconteceu:* o erro foi descoberto em 20/07/2026, quando a análise consolidada da extensão CTR23 acusou métricas idênticas até a 4ª casa entre “kin8nm (extensão)” e “diamonds (núcleo)”; um indício anterior (pool de 6.553 linhas, incompatível com ~ 43 mil) havia sido incorretamente aceito como aproximação de configuração — lapso registrado. A validade experimental não foi afetada (apenas o rótulo estava errado); os rótulos foram corrigidos por commit de retificação com histórico preservado, a duplicata involuntária virou teste de reprodutibilidade ponta-a-ponta (extension_kin8nm_repro_check.csv: números reproduzidos exatamente sob as mesmas sementes) e o diamonds verdadeiro entrou na extensão como diamonds_real. *Por que está aqui:* é o desvio de registro mais sério do trabalho e a origem de duas salvaguardas (verificação nome $\leftrightarrow$ ID $\leftrightarrow$ dimensões no download; divergência de approx_samples como sinal de investigação obrigatória). Registro canônico: docs/errata-diamonds-kin8nm.md; commits d1168fa (erratum) e c407ef6 (reexecução das análises).

C.2.0.0.6 6. Troca year_prediction $\rightarrow$ cpu_activity na figura de calibração. *O que era:* a figura de calibração da destilação usaria california_housing e year_prediction como exemplos. *O que aconteceu:* a passada do teacher com contexto de 50 mil linhas no year_prediction excedeu o orçamento de tempo da sessão de geração de figuras (time-box); o conjunto foi substituído por cpu_activity, que carrega a mesma mensagem — retenção distribucional forte (+0,50) — a cerca de 1/50 do custo computacional. *Por que está aqui:* é um desvio operacional, não científico, mas altera um artefato apresentado; a decisão e sua justificativa estão comentadas no próprio script gerador. Registro: comentário em scripts/plot_calibration.py (definição de DATASETS); retenção do cpu_activity em docs/relatorio-ai2.md (fase 6a).